ĐẠI HỌC BÁCH KHOA HÀ NỘI

TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG



IT3940E - Project III

Soi: Đọc, kiểm chứng và tự sửa số liệu báo cáo tài chính Việt Nam

Đề tài: Ứng dụng Agentic AI trong Chứng khoán: Stock Report Agent

(Báo cáo kỹ thuật sơ bộ)

Giảng viên hướng dẫn:

PGS. TS. Cao Tuấn Dũng

Sinh viên thực hiện:

Hoàng Văn Nhân - 20235542

Hà Nội - Việt Nam

2026

Mục lục

Danh mục thuật ngữ và viết tắt **i**

1 Giới thiệu **1**

1.1 Đặt vấn đề 1

1.2 Mục tiêu nghiên cứu 2

1.3 Phạm vi và đóng góp 2

1.3.1 Phạm vi 2

1.3.2 Đóng góp 2

1.4 Cấu trúc báo cáo 3

2 Cơ sở lý thuyết và công nghệ **4**

2.1 Cấu trúc báo cáo tài chính Việt Nam 4

2.2 Nhiều mẫu biểu cùng tồn tại 5

2.3 Ràng buộc kế toán 6

2.4 Làm sạch số liệu bằng ràng buộc: phương pháp Fellegi–Holt 7

2.5 Mô hình ngôn ngữ đọc ảnh 8

2.6 Công nghệ sử dụng 8

3 Các sản phẩm và nghiên cứu liên quan **9**

3.1 Hệ thống của khóa trước 9

3.2 Nền tảng dữ liệu tài chính trong nước 10

3.3 Sản phẩm “AI chứng khoán” 10

3.4 Sản phẩm quốc tế 10

3.5 Đánh giá khoảng trống 10

4 Phân tích, thiết kế và cài đặt **11**

4.1 Phân tích yêu cầu . . . 11

4.1.1 Tác nhân . . . 11

4.1.2 Biểu đồ use case . . . 12

4.1.3 Đặc tả các use case chính . . . 13

4.1.4 Yêu cầu chức năng . . . 14

4.1.5 Yêu cầu phi chức năng . . . 14

4.2 Kiến trúc tổng thể . . . 15

4.2.1 Nguyên tắc thiết kế . . . 15

4.2.2 Các thành phần . . . 16

4.2.3 Phân rã module . . . 16

4.2.4 Triển khai . . . 17

4.2.5 Vòng đời một tài liệu . . . 18

4.2.6 Luồng xử lý một BCTC mới . . . 19

4.3 Thiết kế cơ sở dữ liệu . . . 19

4.4 Thu thập tài liệu . . . 22

4.4.1 Lấy danh sách và nhận dạng tiêu đề . . . 22

4.4.2 Lưu trữ và phiên bản . . . 22

4.5 Đọc và kiểm chứng BCTC . . . 24

4.5.1 Quy trình . . . 24

4.5.2 Mô hình chỉ chép, code mới hiểu số . . . 24

4.5.3 Giả thuyết rẻ trước khi gọi lại mô hình . . . 25

4.5.4 Thang leo thang khi còn lệch . . . 26

4.5.5 Duyệt tay . . . 27

4.5.6 Bằng chứng cho từng ô . . . 28

4.6 Công nghệ lõi: tự định vị và tự sửa ô đọc sai . . . 28

4.6.1 Ý tưởng . . . 28

4.6.2 Thuật toán định vị . . . 29

4.6.3 Xác nhận bằng đọc lại . . . 30

4.6.4 Chuẩn bị ảnh cho bước đọc lại . . . 30

4.6.5 Mở rộng sang ràng buộc giữa các BCTC . . . 31

4.7 Quản lý token và chi phí . . . 31

4.7.1 Giảm token vào . . . 32
4.7.2 Giới hạn token ra . . . 32
4.7.3 Đo và giới hạn chi phí . . . 32
4.8 Thẻ KQKD và giao diện . . . 33
4.8.1 Thẻ KQKD . . . 33
4.8.2 Bảng xếp hạng mùa BCTC . . . 35
4.8.3 Lịch công bố và ảnh chia sẻ . . . 36
4.8.4 Người dùng và quyền riêng tư . . . 37

5 Kết quả thực nghiệm và đánh giá 38
5.1 Tỷ lệ BCTC đạt kiểm chứng . . . 38
5.2 Độ đúng theo từng ô . . . 39
5.3 Chi phí . . . 39
5.3.1 Cách tính . . . 39
5.3.2 Ước tính chi phí vận hành . . . 40
5.4 Định vị ô đọc sai . . . 41
5.4.1 Bộ đề và cách thử . . . 41
5.4.2 Bốn loại kết quả . . . 41
5.4.3 Phân tích các ca ngoài tầm, ca sót và đề xuất sai . . . 42
5.5 Chép lại cả báo cáo . . . 43
5.6 Chuẩn bị ảnh cho bước đọc lại . . . 44
5.7 Đối chiếu với nguồn dữ liệu công khai . . . 45
5.8 Tốc độ và các thước đo khác . . . 46

6 Kết luận và hướng phát triển 47
6.1 Kết luận . . . 47
6.2 Hướng phát triển . . . 47
6.2.1 Chạy thật mùa BCTC quý 3/2026 cho VN30 . . . 47
6.2.2 Chỉ số tài chính: biên lợi nhuận gộp, ROE, tăng trưởng lũy kế . . . 48
6.2.3 Agent báo cáo so sánh (lập kế hoạch, gọi công cụ, kiểm tra số khi viết) . . . 48
6.2.4 Bộ kiểm tra số và từ chỉ hướng trong văn bản sinh ra . . . 48
6.2.5 Bộ dữ liệu vàng và benchmark vnpdf . . . 48

6.2.6 Phép thử so với trợ lý AI đa năng 48
6.2.7 Mở rộng lên VN100 48
6.2.8 Tìm nguyên nhân biến động trong thuyết minh và công văn giải trình 48
6.2.9 Sàng lọc doanh nghiệp tăng trưởng và kiểm định lịch sử (backtest) 48
6.2.10 Radar sự kiện công bố thông tin và bản tin sáng theo danh mục . . 49
6.2.11 Kênh phân phối: Facebook, Zalo, MCP 49
6.2.12 Triển khai lên máy chủ và số liệu người dùng thật 49

Tài liệu tham khảo **50**

Tóm tắt nội dung

Báo cáo tài chính (BCTC) là nguồn số liệu gốc của mọi phân tích cổ phiếu. Ở Việt Nam, phần lớn BCTC được công bố dưới dạng ảnh scan. Số trong đó phải được "đọc" bằng OCR hoặc mô hình thị giác, và mọi công cụ đọc đều có lúc nhầm chữ số. Một chữ số sai trên dòng lợi nhuận đủ làm sai hẳn một nhận định đầu tư.

Báo cáo này trình bày **Soi**, hệ thống đọc BCTC ngay khi doanh nghiệp công bố và tự kiểm chứng từng con số bằng các ràng buộc kế toán có sẵn trong chính BCTC, ví dụ tổng tài sản bằng tổng nguồn vốn, hay lợi nhuận sau thuế bằng lợi nhuận trước thuế trừ thuế. Khi một ràng buộc bị lệch, hệ thống tự tìm ô nào bị đọc sai theo tinh thần phương pháp Fellegi–Holt trong thống kê chính thức, rồi đọc lại riêng ô đó. Số mới chỉ được nhận khi lần đọc lại ra đúng con số mà ràng buộc đòi hỏi. Chỉ số liệu đã qua kiểm chứng mới được dùng để tính thẻ kết quả kinh doanh (thẻ KQKD), gắn cờ cảnh báo và xếp hạng. Mỗi con số trên giao diện đều mở được đúng trang BCTC gốc.

Đến ngày 14/10/2026, trên nhóm VN30, hệ thống đã đọc 120 BCTC (quý 4/2025, quý 1 và quý 2/2026, bán niên 2026). Trong đó 119 BCTC đạt kiểm chứng hoặc được duyệt tay, và 93% trong khoảng 35.000 ô số được ràng buộc kế toán xác nhận. Chi phí gọi mô hình để đọc một BCTC trung bình khoảng 0,12 USD (trung vị 0,08 USD), chưa tính chi phí phát triển. Khi đối chiếu với một nguồn dữ liệu công khai, 208/211 ô khớp; ở cả 3 ô lệch, số của Soi khớp với phép cộng trong chính BCTC. Các phần agent phân tích, chỉ số tài chính mở rộng, đánh giá trên bộ dữ liệu vàng và triển khai cho người dùng thật được liệt kê ở Chương 6 dưới dạng đề mục, sẽ hoàn thiện ở các giai đoạn sau.

Danh mục thuật ngữ và viết tắt

Viết tắt	Nghĩa
BCTC	Báo cáo tài chính
BCĐKT (BS)	Bảng cân đối kế toán (Balance Sheet)
KQKD (IS)	Báo cáo kết quả hoạt động kinh doanh (Income Statement)
LCTT (CF)	Báo cáo lưu chuyển tiền tệ (Cash Flow)
LNTT, LNST	Lợi nhuận trước thuế, lợi nhuận sau thuế
TT200, TT99	Thông tư 200/2014/TT-BTC và Thông tư 99/2025/TT-BTC: mẫu BCTC doanh nghiệp thường
TCTD	Tổ chức tín dụng (ngân hàng), mẫu BCTC theo TT49/2014/TT-NHNN
CTCK	Công ty chứng khoán, mẫu BCTC theo TT334/2016/TT-BTC
CBTT	Công bố thông tin
OCR	Nhận dạng ký tự quang học
VLM	Mô hình ngôn ngữ có khả năng đọc ảnh (vision-language model)
Ràng buộc bắt buộc (gate)	Phép kiểm tra kế toán mà BCTC phải thỏa mới được coi là đã kiểm chứng
Thẻ KQKD	Trang tóm tắt kết quả kinh doanh một quý của một mã, kèm cờ cảnh báo

Chương 1

Giới thiệu

1.1 Đặt vấn đề

Mỗi mùa BCTC quý, hơn 1.600 doanh nghiệp niêm yết và đăng ký giao dịch công bố BCTC trong vài tuần. Theo quy định công bố thông tin [4], BCTC quý phải công bố trong 20 ngày sau khi hết quý; công ty mẹ lập BCTC hợp nhất được 30 ngày. Vì vậy mỗi mùa có hai đỉnh công bố, khoảng ngày 20 và ngày 30 của tháng đầu quý sau.

Nhà đầu tư cá nhân cần biết nhanh và đúng: doanh nghiệp lãi bao nhiêu, tăng hay giảm so với cùng kỳ, và mức tăng đó có "thật" không. Có thể đó chỉ là nhờ nền so sánh thấp, nhờ thu nhập bất thường, hay nhờ hoàn nhập dự phòng.

Hiện đã có nhiều sản phẩm "AI chứng khoán" như trợ lý hỏi–đáp của các công ty chứng khoán, tóm tắt tin tức, hay các trợ lý AI đa năng. Nhưng gần như không sản phẩm nào cho người dùng kiểm chứng từng con số: số lấy từ đâu, đã được kiểm tra chưa. Trong tài chính, một mô hình ngôn ngữ "đoán" sai một con số là rủi ro thật.

Bài toán cụ thể gồm ba phần:

1. **Đọc đúng số từ BCTC dạng scan.** Khoảng 52/58 file BCTC quý 2/2026 của VN30 là ảnh scan, hoặc có lớp chữ (text layer) hỏng, không dùng được.
2. **Biết khi nào số đọc ra là sai**, và sửa được mà không cần người kiểm tra từng ô.
3. **Biến số liệu thành thông tin có ích:** tăng trưởng tính đúng cách, cờ cảnh báo, xếp hạng mùa BCTC. Mọi con số phải có nguồn.

1.2 Mục tiêu nghiên cứu

- Xây dựng quy trình đọc BCTC lấy **đủ các cột** so sánh: quý này, cùng kỳ, lũy kế, đầu năm.
- Xây dựng bộ **ràng buộc kế toán khai báo theo từng mẫu** BCTC để tự kiểm chứng số đọc được.
- Phát triển bộ máy **tự định vị và tự sửa ô đọc sai** dựa trên ràng buộc, giảm tối đa duyệt tay.
- Xây dựng **sản phẩm web** trình bày số liệu đã kiểm chứng, có nguồn cho từng số.

1.3 Phạm vi và đóng góp

1.3.1 Phạm vi

- **Dữ liệu:** nhóm VN30 gồm doanh nghiệp thường, 13 ngân hàng và 2 công ty chứng khoán; các kỳ quý 4/2025, quý 1/2026, quý 2/2026 và bán niên 2026. Từ mùa quý 3/2026 hệ thống chạy thật, sau đó mở rộng lên VN100.
- **Nguyên tắc:** số do code tính, mô hình ngôn ngữ chỉ đọc ảnh và viết lời. Không có nguồn thì không nói. Kiểm chứng xong mới công bố.
- **Ranh giới pháp lý:** Soi là dịch vụ thông tin, không đưa khuyến nghị mua, bán, giá mục tiêu hay tín hiệu giao dịch; nội dung do AI tạo được gắn nhãn [11].

1.3.2 Đóng góp

1. **Trích xuất đủ các cột** của từng báo cáo. Hệ thống khóa trước [1] chỉ lưu một giá trị cho mỗi chỉ tiêu.
2. **Bộ ràng buộc kế toán khai báo theo từng mẫu** TT200, TT99, TCTD và CTCK. Mẫu được nhận dạng từ chính nội dung BCTC, không suy ra từ năm.
3. **Bộ máy tự định vị và tự sửa ô đọc sai** dựa trên ràng buộc (mục 4.6). Hệ thống chỉ đọc lại đúng những ô bị nghi, và chỉ nhận số mới khi hai nguồn độc lập cùng chỉ một con số.

4. **Bằng chứng cho từng ô số:** khớp phép cộng trong BCTC, khớp giữa các kỳ, hay bị doanh nghiệp hoặc kiểm toán sửa giữa hai bản BCTC.
5. **Sản phẩm web chạy được:** thẻ KQKD có cờ cảnh báo, bảng xếp hạng mùa BCTC, lịch công bố, ảnh thẻ để chia sẻ.

1.4 Cấu trúc báo cáo

- Chương 2 trình bày kiến thức nền về BCTC Việt Nam, ràng buộc kế toán và các công nghệ sử dụng.
- Chương 3 điểm lại hệ thống của khóa trước, các sản phẩm hiện có và các nghiên cứu liên quan, từ đó chỉ ra khoảng trống mà đề tài nhắm tới.
- Chương 4 mô tả phân tích, thiết kế và cài đặt hệ thống, trong đó có công nghệ lõi tự định vị và tự sửa ô đọc sai.
- Chương 5 trình bày kết quả thực nghiệm và đánh giá.
- Chương 6 kết luận và liệt kê các phần dự kiến làm tiếp.

Chương 2

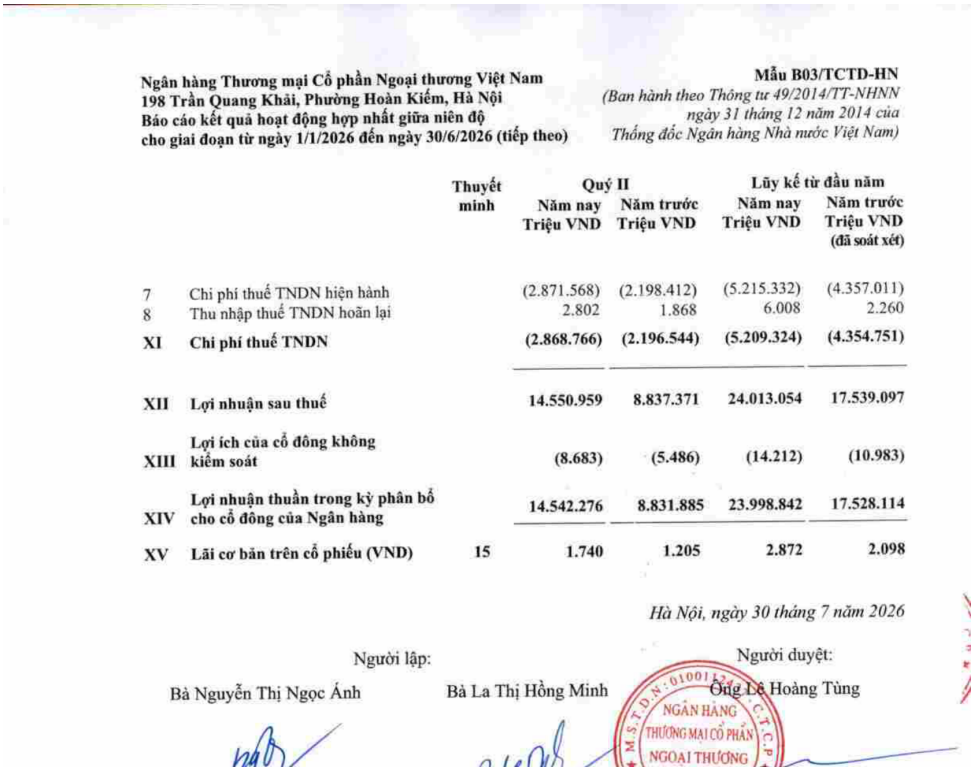
Cơ sở lý thuyết và công nghệ

2.1 Cấu trúc báo cáo tài chính Việt Nam

Một bộ BCTC quý gồm ba báo cáo chính và phần thuyết minh. Mỗi dòng của các báo cáo này có một **mã số** do thông tư quy định [2, 5]. Nhờ mã số mà ta viết được ràng buộc kế toán dưới dạng phép cộng giữa các mã.

Bảng 2.1: Các báo cáo chính và các cột số liệu cần lấy

Báo cáo	**Các cột**	**Ghi chú**
BCĐKT	cuối kỳ, đầu năm	Số dư tại một thời điểm
KQKD	quý này, cùng kỳ năm trước, lũy kế năm nay, lũy kế năm trước	Cột cùng kỳ giúp so sánh ngay
LCTT	lũy kế năm nay, lũy kế năm trước	Quý đơn lẻ = lũy kế kỳ này − lũy kế kỳ trước



Ngân hàng Thương mại Cổ phần Ngoại thương Việt Nam
198 Trần Quang Khải, Phường Hoàn Kiếm, Hà Nội
Báo cáo kết quả hoạt động hợp nhất giữa niên độ
cho giai đoạn từ ngày 1/1/2026 đến ngày 30/6/2026 (tiếp theo)

Mẫu B03/TCTD-HN
(Ban hành theo Thông tư 49/2014/TT-NHNN ngày 31 tháng 12 năm 2014 của Thống đốc Ngân hàng Nhà nước Việt Nam)

		Thuyết minh	Quý II		Lũy kế từ đầu năm	
			Năm nay Triệu VND	Năm trước Triệu VND	Năm nay Triệu VND	Năm trước Triệu VND (đã soát xét)
7	Chi phí thuế TNDN hiện hành		(2.871.568)	(2.198.412)	(5.215.332)	(4.357.011)
8	Thu nhập thuế TNDN hoãn lại		2.802	1.868	6.008	2.260
XI	**Chi phí thuế TNDN**		**(2.868.766)**	**(2.196.544)**	**(5.209.324)**	**(4.354.751)**
XII	**Lợi nhuận sau thuế**		**14.550.959**	**8.837.371**	**24.013.054**	**17.539.097**
XIII	**Lợi ích của cổ đông không kiểm soát**		**(8.683)**	**(5.486)**	**(14.212)**	**(10.983)**
XIV	**Lợi nhuận thuần trong kỳ phân bổ cho cổ đông của Ngân hàng**		**14.542.276**	**8.831.885**	**23.998.842**	**17.528.114**
XV	**Lãi cơ bản trên cổ phiếu (VND)**	**15**	**1.740**	**1.205**	**2.872**	**2.098**

Hà Nội, ngày 30 tháng 7 năm 2026

Người lập: Bà Nguyễn Thị Ngọc Ánh

Bà La Thị Hồng Minh

Người duyệt: Ông Lê Hoàng Tùng

Hình 2.1: Một phần trang KQKD hợp nhất quý 2/2026 của VCB (bản scan, đơn vị triệu đồng). Bốn cột số, mỗi dòng có ký hiệu La Mã thay vì mã số. Đây là đầu vào điển hình của hệ thống.

2.2 Nhiều mẫu biểu cùng tồn tại

Từ năm 2026, Thông tư 99/2025 [5] thay Thông tư 200/2014 [2] cho doanh nghiệp thường và đánh lại một số mã. Ngân hàng [9] và công ty chứng khoán [3] có mẫu riêng (Bảng 2.2).

Bảng 2.2: Các mẫu BCTC hệ thống đang hỗ trợ

Mẫu	Áp dụng	Điểm cần lưu ý
TT200	DN thường, năm tài chính ≤ 2025	Tổng tài sản mã 270
TT99	DN thường, từ quý 1/2026	Tổng tài sản đổi sang mã 280; doanh thu, chi phí tài chính dịch từ 21–23 sang 22–24. Khoảng 11% BCTC quý 2/2026 vẫn in mã 270
TCTD	Ngân hàng	Cấu trúc khác hẳn; nhiều ngân hàng không in mã số mà chỉ có số thứ tự La Mã
CTCK	Công ty chứng khoán	Tài sản tài chính FVTPL, cho vay ký quỹ…

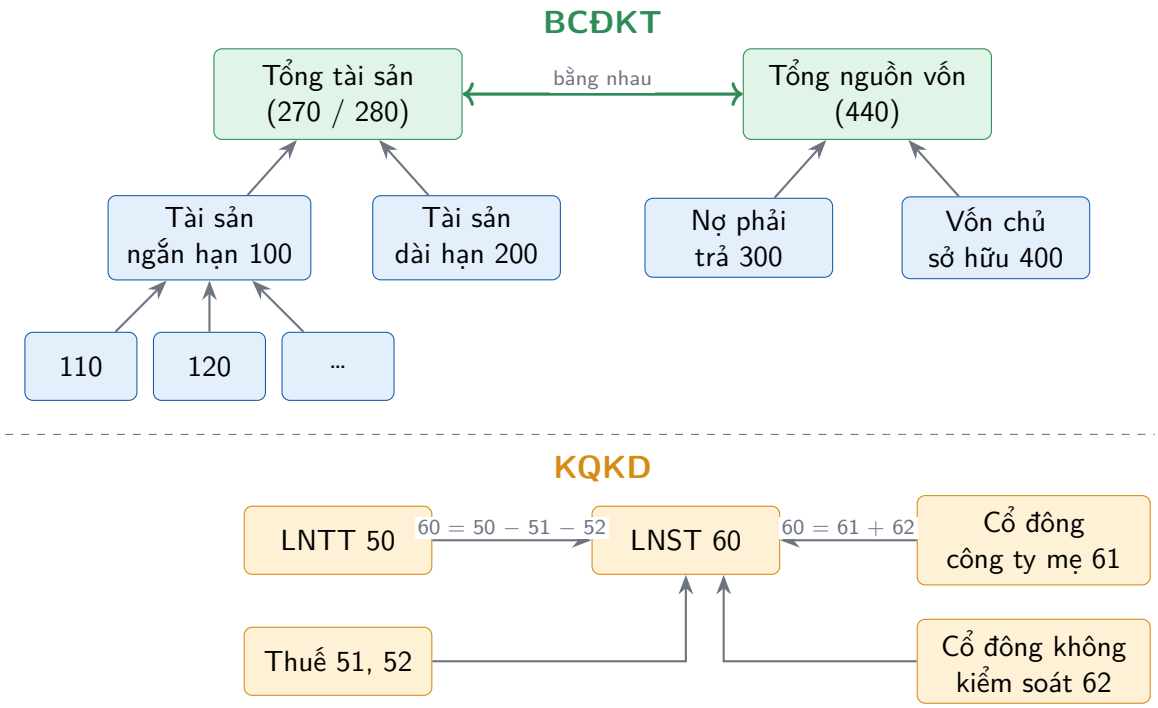
Những khó khăn thực tế khi đọc, rút ra từ việc rà khoảng 940 BCTC quý 2/2026:

- Khoảng 1/4 BCTC viết `1,234,567` thay vì `1.234.567`, nên phải suy ra dấu phân cách theo từng tài liệu.

- Đơn vị có thể là đồng, nghìn đồng hoặc triệu đồng.
- Cột thuyết minh cũng là số nhỏ, dễ nhầm với cột mã số. Cột số thứ tự và cột mã số đôi khi bị đọc đảo cho nhau.
- BCTC thật không luôn theo đúng mẫu: có file in mã 270 cho dòng tổng theo mẫu mới, có dòng không in mã, có nhiều dòng LCTT trùng mã, cùng dòng lợi nhuận chưa phân phối nhưng công ty này in mã 421a/421b, công ty khác in 420a/420b.
- Một số file scan có trang bị lộn ngược, hoặc có độ phân giải rất thấp (72 dpi). File đăng trên trang của chính công ty cũng là đúng file đó, nên không có bản nét hơn để thay.

2.3 Ràng buộc kế toán

Mỗi BCTC tự chứa nhiều phép cộng, đủ để kiểm tra chéo các con số trong chính nó (Hình 2.2). Sai số cho phép là ± 1 đơn vị làm tròn cho mỗi số hạng.



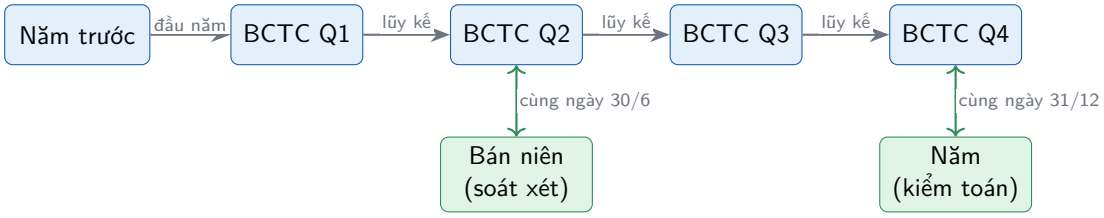
Hình 2.2: Hình minh họa một phần lưới ràng buộc của BCTC doanh nghiệp thường. Mũi tên chỉ từ số hạng tới tổng của phép cộng. Một ô số thường nằm trong nhiều phép cộng cùng lúc, nên khi đọc nhầm một ô, các phép cộng chứa nó cùng lệch một lượng như nhau.

Bảng 2.3: Số mẫu ràng buộc đã khai báo (mỗi mẫu được áp cho từng cột số liệu)

Mẫu	Theo mã	Bắt buộc	Theo vị trí	Ví dụ
TT200	43	43	LCTT	$270 = 100 + 200$, $60 = 50 - 51 - 52$
TT99	48	44	LCTT	$280 = 440$, $130 = 131 + \ldots + 139$
TCTD	17	16	BCĐKT, LCTT	thu nhập lãi thuần = thu nhập lãi − chi phí lãi
CTCK	23	20		theo TT334

Cột "theo vị trí" là phép kiểm dành cho các dòng không in mã số: dòng tổng phải bằng tổng các dòng nằm ngay trên nó, tính tới dòng tổng trước đó. Ngân hàng hiếm khi in mã cho dòng chi tiết; một số doanh nghiệp bỏ mã ở phần đầu LCTT. Một ràng buộc chỉ được đưa vào nhóm "bắt buộc" sau khi đã đo trên toàn bộ BCTC đã đọc và thấy nó khớp ở mọi BCTC, trừ những chỗ đã xác nhận là đọc sai. Các ràng buộc chi tiết của mẫu TT99 được đưa vào nhóm bắt buộc theo cách này.

Ngoài ràng buộc trong một BCTC, còn có **ràng buộc giữa các BCTC** của cùng công ty (Hình 2.3).



Hình 2.3: Hình minh họa ràng buộc giữa các kỳ: số đầu năm phải bằng số cuối năm trước; quý = lũy kế kỳ này − lũy kế kỳ trước; BCTC quý 2 và bán niên (hay quý 4 và năm) cùng ngày nên phải khớp. Khi hai bản khác nhau, đó hoặc là đọc nhầm, hoặc là doanh nghiệp, kiểm toán đã sửa số.

2.4 Làm sạch số liệu bằng ràng buộc: phương pháp Fellegi–Holt

Trong thống kê chính thức, số liệu điều tra thường được kiểm tra bằng các quy tắc (edit rules), ví dụ tổng các khoản chi phải bằng tổng chi. Fellegi và Holt [7] đề xuất nguyên lý: khi một bản ghi vi phạm quy tắc, hãy tìm **tập trường nhỏ nhất** cần thay đổi để mọi quy tắc cùng thỏa, thay vì sửa tùy ý từng trường. Bước này gọi là định vị lỗi (error localization) và là nền của các hệ thống làm sạch số liệu ở cơ quan thống kê [6].

BCTC có cấu trúc rất giống: các ô số liên kết với nhau bằng phép cộng. Điểm khác

là lỗi ở đây chủ yếu do *đọc ảnh* nhầm 1–2 chữ số, và ta có thể quay lại ảnh gốc để xác nhận. Mục 4.6 trình bày cách Soi tận dụng hai đặc điểm này.

2.5 Mô hình ngôn ngữ đọc ảnh

Các mô hình ngôn ngữ đa phương thức (VLM) nhận ảnh trang tài liệu và trả về văn bản có cấu trúc, ví dụ JSON theo schema. So với OCR truyền thống, VLM đọc được bảng nhiều cột, dòng tên bị xuống dòng và chữ tiếng Việt có dấu mà không cần bước nhận diện vùng bảng riêng. Nhược điểm là đôi khi "bịa" hoặc đọc nhầm số, và không cho điểm tin cậy cho từng ô. Vì vậy Soi chỉ dùng VLM để *định vị trang* và *chép nguyên văn*; độ tin cậy đến từ ràng buộc kế toán chứ không từ mô hình.

2.6 Công nghệ sử dụng

Bảng 2.4: Công nghệ sử dụng

Thành phần	**Lựa chọn**
Ngôn ngữ, web	Python 3.12, FastAPI, Jinja2 (giao diện tạm; trang công khai dự kiến Next.js)
CSDL	PostgreSQL 16 + pgvector, migration đánh số
Đọc PDF, vẽ ảnh	PyMuPDF
Mô hình đọc ảnh	Mô hình thị giác qua API kiểu OpenAI (hiện dùng một mô hình cỡ nhỏ, giá rẻ), đầu ra JSON theo schema
Chạy	Docker Compose: `db`, `web`, `watcher`, `app`
Kiểm thử	pytest, 117 bài kiểm thử; dữ liệu mẫu là tiêu đề và BCTC thật

Chương 3

Các sản phẩm và nghiên cứu liên quan

3.1 Hệ thống của khóa trước

Đề tài kế thừa hệ thống *Stock Report Agent* của khóa trước [1] (giấy phép MIT). Hệ thống đó dùng LangGraph gồm các bước hiểu yêu cầu, lấy link BCTC từ Vietstock [12], OCR kết hợp Tesseract và Surya ("Hybrid OCR"), rồi trích xuất bằng mô hình ngôn ngữ. Trên 401 trang BCTC, Hybrid OCR đạt Number F1 khoảng 85%, mỗi báo cáo mất khoảng 5 phút. Bảng 3.1 so sánh hai hệ thống.

Bảng 3.1: So sánh với hệ thống của khóa trước

	Khóa trước	**Soi**
Khi nào đọc	Khi người dùng hỏi (khoảng 5 phút mỗi báo cáo, cần GPU)	Ngay khi BCTC được công bố; người dùng xem kết quả có sẵn
Số cột	Một giá trị cho mỗi chỉ tiêu	Đủ các cột cùng kỳ, lũy kế, đầu năm
Đọc số	Hybrid OCR, Number F1 $\approx$ 85%	Mô hình thị giác chép nguyên văn; code phân tích số
Kiểm tra	Không	Ràng buộc kế toán theo mẫu, tự định vị và sửa ô sai
Mẫu biểu	Một mẫu	TT200, TT99, TCTD, CTCK
Đầu ra	Bảng số trong giao diện chat	Thẻ KQKD, cờ cảnh báo, xếp hạng, lịch, ảnh chia sẻ

3.2 Nền tảng dữ liệu tài chính trong nước

Các cổng thông tin như Vietstock, CafeF cung cấp BCTC dạng PDF, số liệu tổng hợp, biểu đồ và tin tức. Số liệu tổng hợp thường chỉ có số riêng từng quý, không kèm cột cùng kỳ, lũy kế hay nguồn đến từng trang. Ngày trong kho tài liệu là ngày đăng lại, không phải giờ công bố chính thức.

3.3 Sản phẩm "AI chứng khoán"

Nhiều nền tảng đầu tư và công ty chứng khoán đã có trợ lý AI hỏi–đáp, tóm tắt tin tức hay tóm tắt BCTC. Theo thông tin công khai, các sản phẩm này chủ yếu *bị động* (chờ người dùng hỏi), hiếm khi trích nguồn đến từng ô số, và nhiều trợ lý gắn với tài khoản của một công ty chứng khoán. Trợ lý AI đa năng tìm được web và đọc được PDF, nhưng không có kho số liệu đã kiểm chứng để đối chiếu.

3.4 Sản phẩm quốc tế

Ở thị trường quốc tế, Daloopa trích số liệu từ BCTC, mỗi số có link về nguồn; Fiscal.ai và AlphaSense trích dẫn đến từng câu. Đây là hình mẫu gần nhất của "lớp số liệu kiểm chứng được" mà Soi hướng tới cho thị trường Việt Nam.

3.5 Đánh giá khoảng trống

- Chưa có hệ thống nào cho BCTC Việt Nam dạng scan *tự kiểm chứng* số đọc được bằng ràng buộc kế toán và tự sửa lỗi đọc.
- Chưa có nguồn miễn phí cung cấp số liệu kèm nguồn đến từng trang, đủ cột so sánh, ghi đúng thời điểm công bố.
- Các sản phẩm hiện có ít cảnh báo về chất lượng lợi nhuận: nền thấp, thu nhập bất thường, lãi nhưng dòng tiền âm.

Chương 4

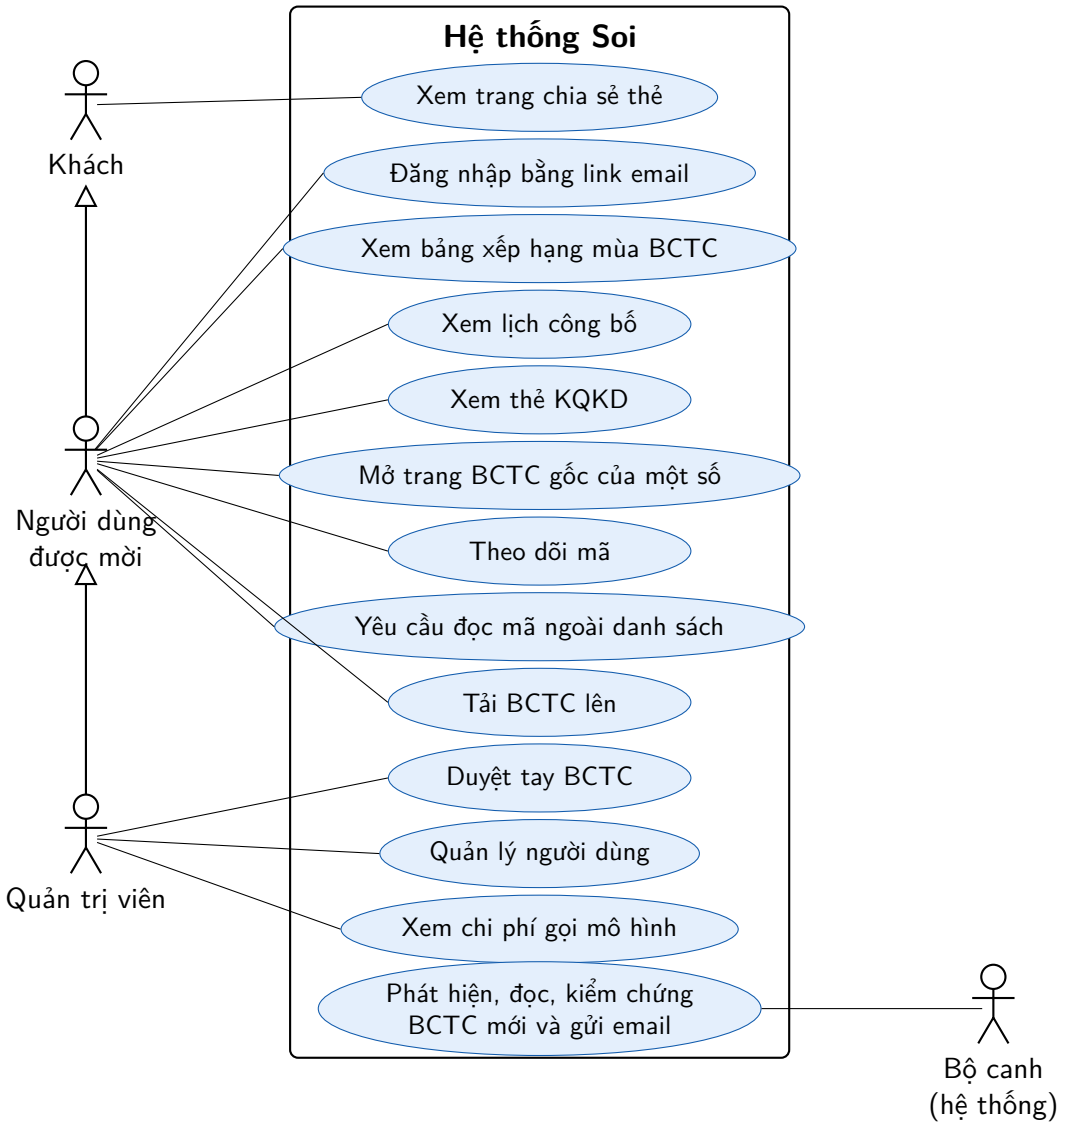
Phân tích, thiết kế và cài đặt

4.1 Phân tích yêu cầu

4.1.1 Tác nhân

- **Khách:** người chưa đăng nhập, chỉ xem được trang chia sẻ thẻ KQKD đã kiểm chứng (ví dụ khi bấm link trên Facebook, Zalo).
- **Người dùng được mời:** nhà đầu tư cá nhân đã được mời trong giai đoạn thử nghiệm, đăng nhập bằng link gửi qua email.
- **Quản trị viên:** có mọi quyền của người dùng, thêm quyền duyệt tay BCTC và quản lý người dùng.
- **Bộ canh (hệ thống):** tác nhân chạy theo lịch, tự phát hiện BCTC mới, gọi quy trình đọc và gửi email.

4.1.2 Biểu đồ use case



Hình 4.1: Biểu đồ use case tổng quát. Đường nối là quan hệ giữa tác nhân và use case; mũi tên tam giác rỗng là quan hệ khái quát hóa: người dùng được mời làm được mọi việc của khách, quản trị viên làm được mọi việc của người dùng.

4.1.3 Đặc tả các use case chính

Bảng 4.1: Đặc tả use case "Xem thẻ KQKD"

Tác nhân	Người dùng được mời
Tiền điều kiện	Đã đăng nhập
Luồng chính	1. Người dùng chọn mã (từ bảng xếp hạng, lịch công bố hoặc đường dẫn `/ma/<mã>`) và kỳ. 2. Hệ thống chọn BCTC quý dùng cho thẻ: ưu tiên hợp nhất, bản đăng sau cùng. 3. Hệ thống tính thẻ từ số đã kiểm chứng: các chỉ tiêu, tăng trưởng, cờ cảnh báo, nguồn của từng số. 4. Người dùng bấm vào một số để mở đúng trang BCTC gốc.
Luồng thay thế	2a. Chưa có BCTC của kỳ đó: báo chưa có. 3a. BCTC chưa đạt kiểm chứng: hiện trạng thái, không hiện số. 3b. Mẫu BCTC chưa hỗ trợ (công ty chứng khoán): báo thẻ chưa hỗ trợ.
Hậu điều kiện	Không thay đổi dữ liệu

Bảng 4.2: Đặc tả use case "Yêu cầu đọc mã ngoài danh sách"

Tác nhân	Người dùng được mời; bộ canh (xử lý hàng chờ)
Tiền điều kiện	Đã đăng nhập
Luồng chính	1. Người dùng nhập mã và kỳ. 2. Hệ thống kiểm tra kho; chưa có thì kiểm tra hạn mức trong ngày của người dùng. 3. Hệ thống ghi yêu cầu vào hàng chờ. 4. Ở lượt kế tiếp (tối đa 15 phút), bộ canh tìm BCTC trên Vietstock, tải về, đọc và kiểm chứng. 5. Hệ thống gửi email báo kết quả; BCTC mới vào kho dùng chung.
Luồng thay thế	2a. Kho đã có BCTC đã đọc: trả kết quả ngay, không tính vào hạn mức. 2b. Hết hạn mức trong ngày: từ chối và báo cho người dùng. 4a. Chi phí đọc theo yêu cầu đã chạm trần tháng: yêu cầu nằm chờ sang tháng sau. 4b. Không tìm thấy mã hoặc BCTC: từ chối kèm lý do.
Hậu điều kiện	Yêu cầu có trạng thái `done` hoặc `rejected`

Bảng 4.3: Đặc tả use case "Duyệt tay BCTC"

Tác nhân	Quản trị viên
Tiền điều kiện	BCTC ở trạng thái `needs_review`
Luồng chính	1. Quản trị viên mở hàng duyệt và chọn một BCTC. 2. Hệ thống hiện bảng số đã đọc, các ràng buộc còn lệch và ảnh trang gốc. 3. Quản trị viên đối chiếu với ảnh, nhập số đúng cho ô đọc sai kèm ghi chú. 4. Hệ thống ghi lịch sử sửa và kiểm tra lại ràng buộc; đạt thì chuyển `verified`.
Luồng thay thế	3a. Ảnh cho thấy chính BCTC tự in lệch: quản trị viên duyệt xuất bản; hệ thống chuyển `approved` và gửi email cho người theo dõi mã. 4a. Vẫn còn lệch: quay lại bước 2.
Hậu điều kiện	Mỗi lần sửa được lưu (người sửa, số cũ, số mới), dùng làm dữ liệu vàng để đánh giá

4.1.4 Yêu cầu chức năng

Bảng 4.4: Các yêu cầu chức năng chính và trạng thái

Mã	Yêu cầu	Trạng thái
F1	Tự phát hiện BCTC mới của các mã theo dõi, tải về, nhận dạng loại và kỳ	Đã làm
F2	Đọc BCTC (kể cả bản scan), lấy đủ các cột, kiểm chứng bằng ràng buộc kế toán	Đã làm
F3	Tự định vị và sửa ô đọc sai; chuyển duyệt tay khi không tự sửa được	Đã làm
F4	Thẻ KQKD có cờ cảnh báo, mỗi số có nguồn tới trang BCTC	Đã làm
F5	Bảng xếp hạng mùa BCTC, lịch công bố, ảnh thẻ để chia sẻ	Đã làm
F6	Theo dõi mã và nhận email khi có BCTC mới	Đã làm
F7	Yêu cầu đọc mã ngoài danh sách, tải BCTC lên (có hạn mức)	Đã làm
F8	Quản trị: duyệt tay, sửa ô, mời và phân quyền người dùng, xem chi phí gọi mô hình	Đã làm
F9	Chỉ số tài chính (biên lợi nhuận, ROE…)	Dự kiến
F10	Agent báo cáo so sánh theo câu hỏi của người dùng	Dự kiến

4.1.5 Yêu cầu phi chức năng

- **Đúng số:** chỉ công bố số đã qua ràng buộc bắt buộc hoặc đã được duyệt tay.
- **Truy vết:** mỗi số mở được trang BCTC gốc; mỗi lần sửa được ghi lại người sửa và lý do.
- **Chi phí:** trung bình khoảng 0,12 USD để đọc một BCTC; có trần chi phí theo ngày và theo tháng (mục 4.7).
- **Độ trễ:** có thể trong vài phút sau khi BCTC xuất hiện trên nguồn (sẽ đo trong mùa quý 3/2026).

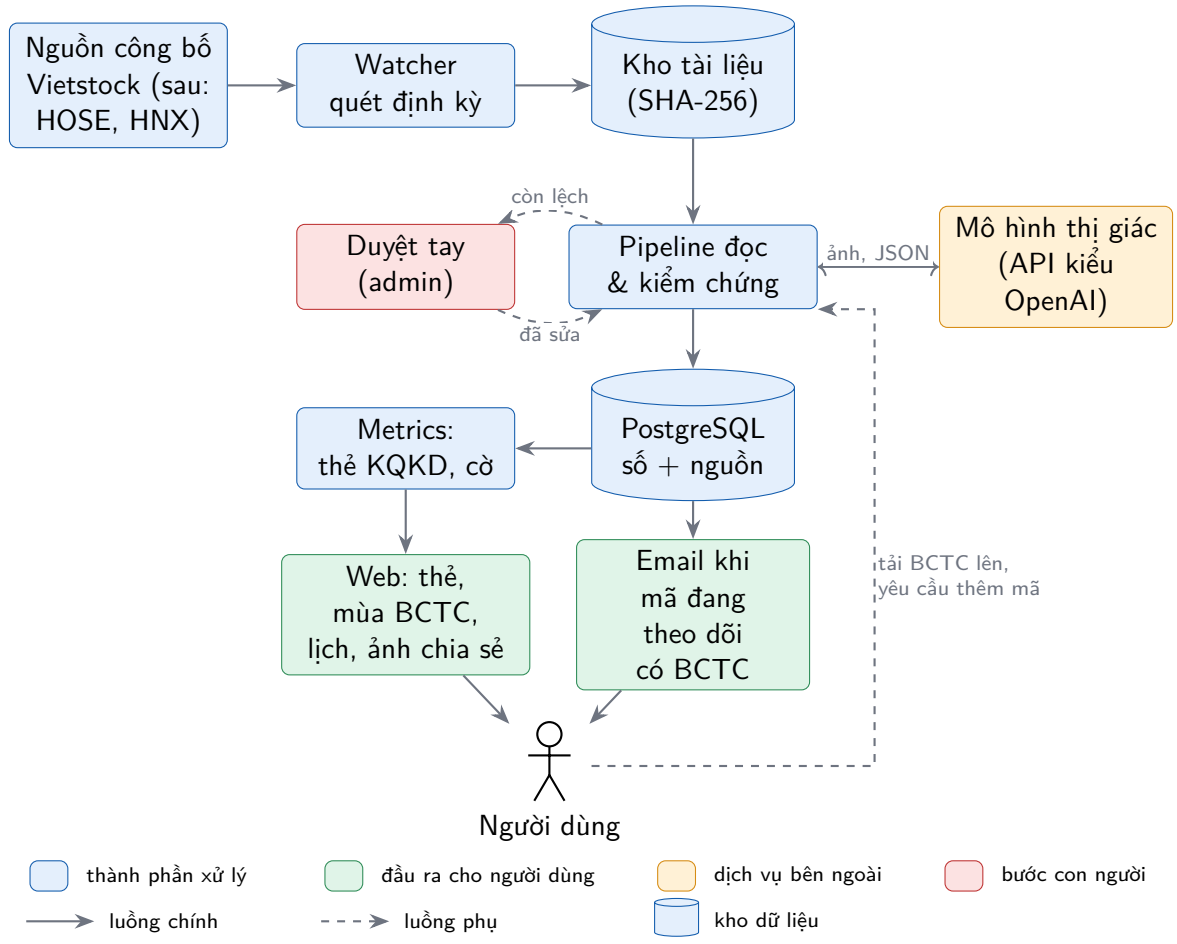
- **Riêng tư:** tài liệu người dùng tải lên chỉ người đó thấy.
- **Pháp lý:** không đưa khuyến nghị đầu tư; nội dung do AI tạo được gắn nhãn.

4.2 Kiến trúc tổng thể

4.2.1 Nguyên tắc thiết kế

1. **Xử lý trước (precompute-first):** tài liệu được xử lý một lần khi công bố, không đợi người dùng hỏi.
2. **Số do code tính, chữ do mô hình viết:** mô hình chỉ định vị trang và chép nguyên văn từng ô. Mọi việc phân tích số, quy đổi đơn vị và kiểm tra đều do code làm.
3. **Không có nguồn thì không nói:** mỗi số mang theo tài liệu, trang và dòng gốc.
4. **Kiểm chứng xong mới công bố:** ràng buộc kế toán là cổng chất lượng.
5. **Quy tắc khai báo theo mẫu và phiên bản**, không viết cứng trong code.
6. **Có phiên bản, không ghi đè:** BCTC công bố lại tạo phiên bản mới; mỗi lần trích xuất ghi phiên bản pipeline.
7. **Không khóa vào một nhà cung cấp mô hình:** gọi mô hình qua giao diện kiểu OpenAI.

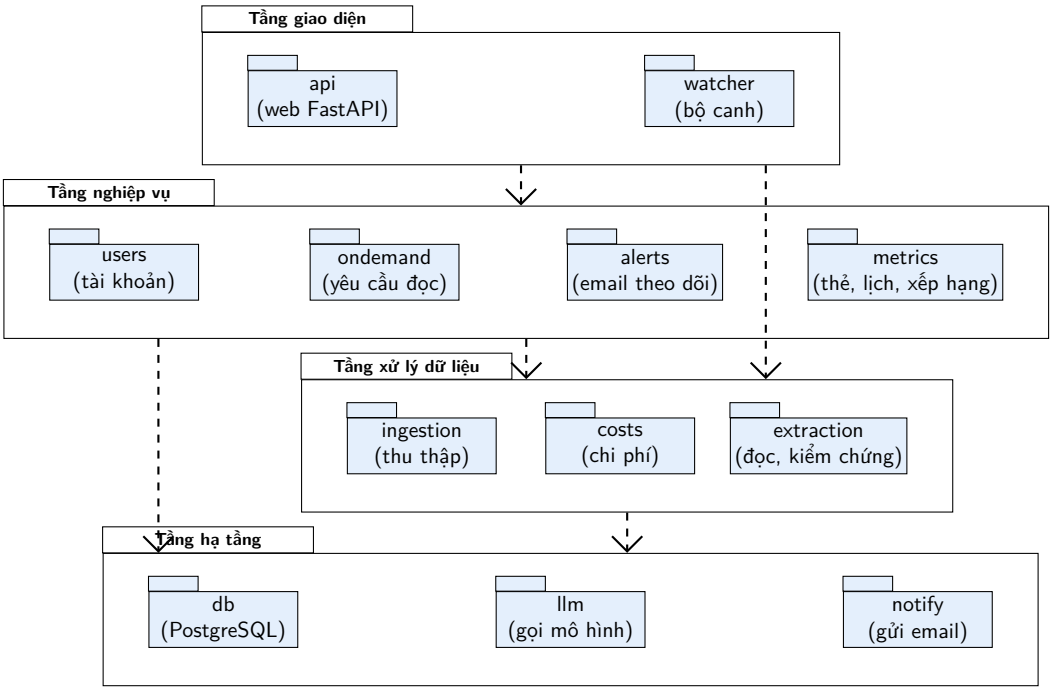
4.2.2 Các thành phần



Hình 4.2: Sơ đồ kiến trúc tổng quan (sơ đồ khối) của Soi.

4.2.3 Phân rã module

Mã nguồn chia thành các gói Python theo bốn tầng (Hình 4.3). Gói ở tầng trên chỉ dùng gói ở tầng dưới, không có chiều ngược lại. Phụ thuộc chi tiết (Bảng 4.5) lấy từ các câu lệnh `import` thực tế.



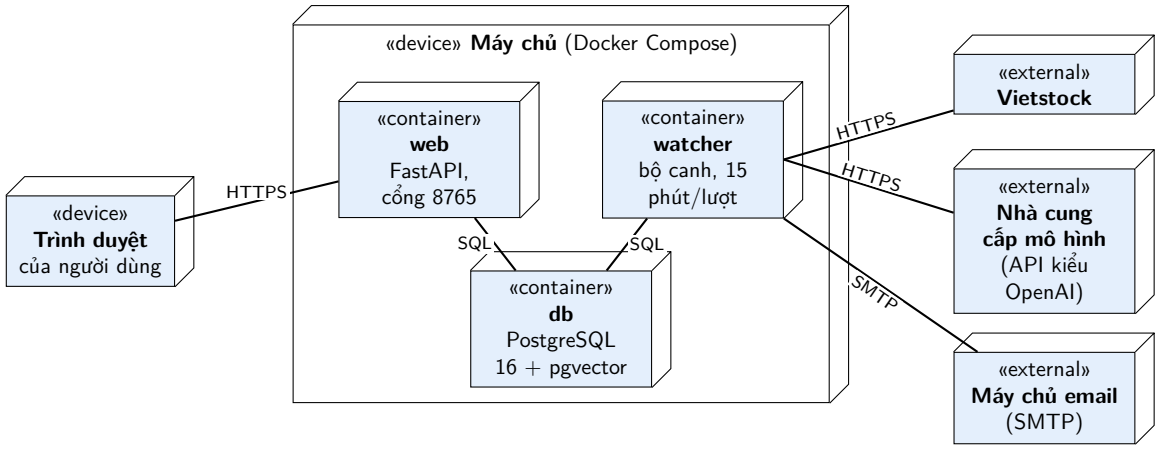
Hình 4.3: Biểu đồ gói theo tầng. Mũi tên đứt nét đầu hở là quan hệ phụ thuộc giữa các tầng; phụ thuộc giữa từng gói ở Bảng 4.5.

Bảng 4.5: Phụ thuộc giữa các gói (lấy từ câu lệnh `import`; mọi gói nghiệp vụ và xử lý dữ liệu đều dùng `db`)

Gói	**Dùng các gói**
api	users, ondemand, metrics, costs, alerts, extraction, ingestion
watcher	ondemand, alerts, extraction, ingestion, llm, notify
ondemand	extraction, ingestion, metrics, alerts, users, costs, llm, notify
alerts	metrics, users, notify
users	notify
metrics	extraction
costs	ingestion, llm
extraction	ingestion, llm, costs
ingestion	(chỉ db)
db, llm, notify	(không dùng gói nội bộ nào)

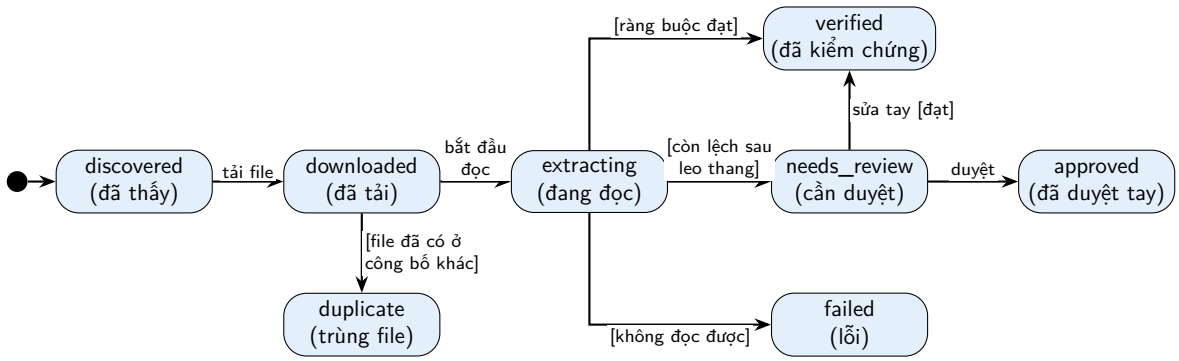
4.2.4 Triển khai

Hiện hệ thống chạy trên máy phát triển bằng Docker Compose; khi triển khai thật sẽ chuyển nguyên cụm container lên một máy chủ ảo (VPS) (Hình 4.4).



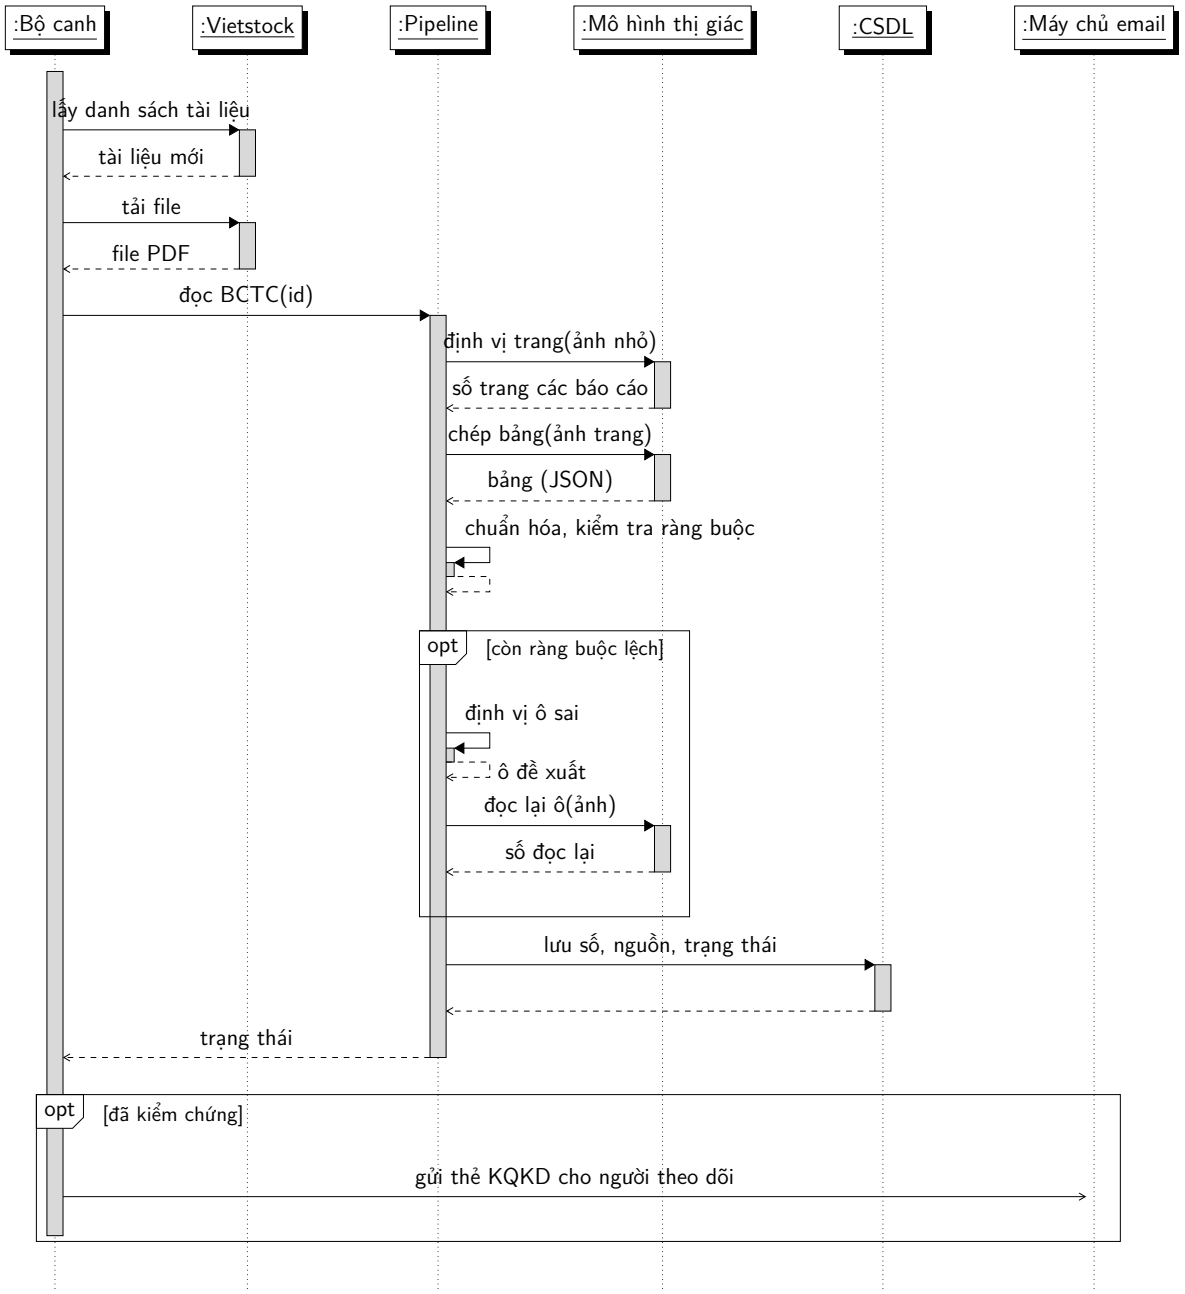
Hình 4.4: Biểu đồ triển khai. Hộp ba chiều là nút (thiết bị hoặc môi trường chạy); đường nối là kênh giao tiếp, ghi giao thức.

4.2.5 Vòng đời một tài liệu



Hình 4.5: Biểu đồ trạng thái của một tài liệu. Chấm đen là trạng thái đầu; nhãn trên mũi tên là sự kiện, phần trong ngoặc vuông là điều kiện. Chỉ `verified` và `approved` được hiển thị trên thẻ và bảng xếp hạng.

4.2.6 Luồng xử lý một BCTC mới



Hình 4.6: Biểu đồ tuần tự khi một BCTC mới xuất hiện. Mũi tên liền đầu đặc là lời gọi, mũi tên đứt là giá trị trả về, mũi tên đầu hở là thông điệp không chờ trả lời; khung `opt` là đoạn chỉ chạy khi điều kiện trong ngoặc vuông đúng.

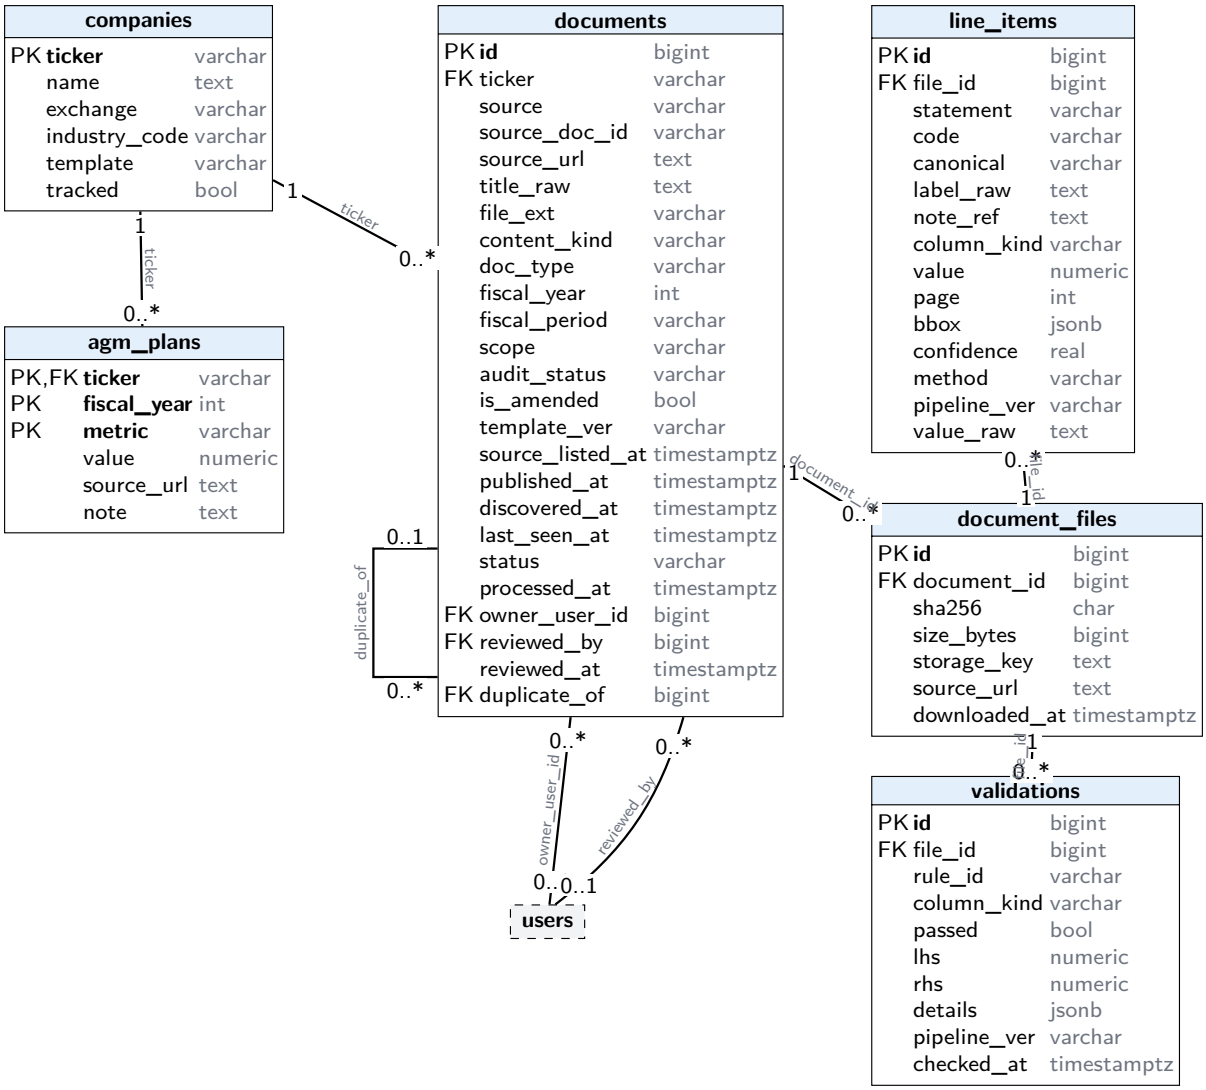
4.3 Thiết kế cơ sở dữ liệu

CSDL PostgreSQL gồm 12 bảng, chia hai nhóm: dữ liệu BCTC (Hình 4.7) và người dùng (Hình 4.8). Hai sơ đồ được **sinh tự động từ cấu trúc bảng trong CSDL thật**, nên luôn khớp với code. Mỗi hộp là một bảng gồm tên cột, khóa (PK: khóa chính, FK: khóa

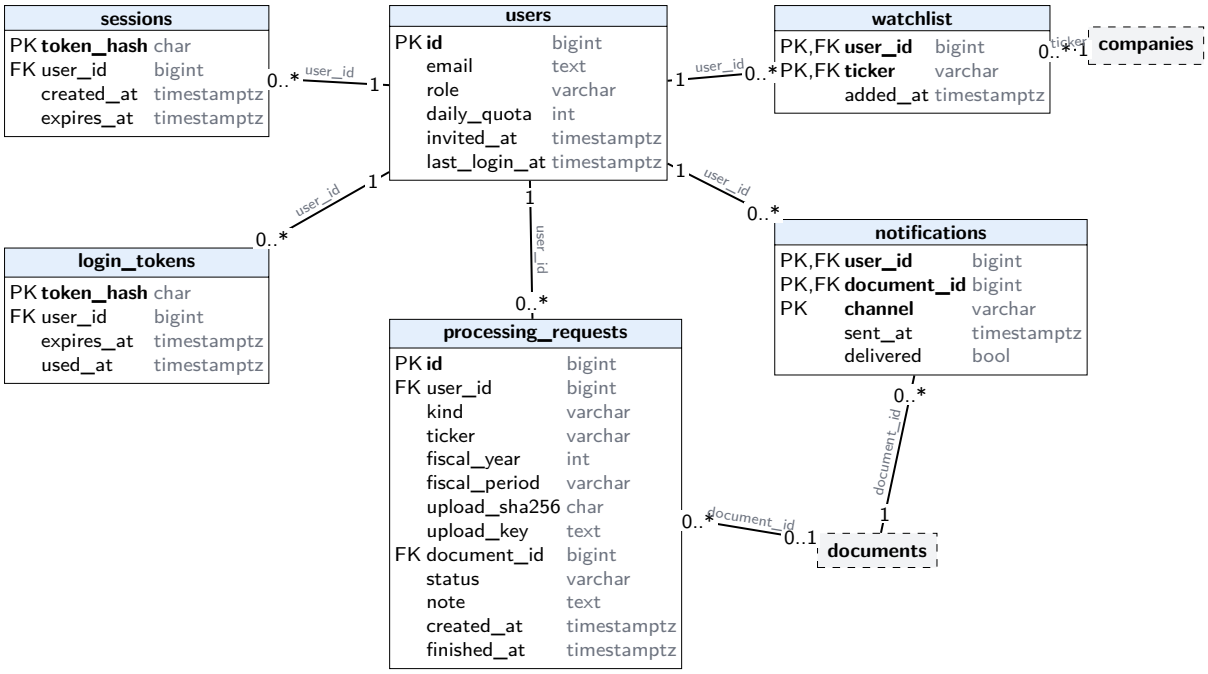
ngoại) và kiểu dữ liệu; mỗi đường nối là một khóa ngoại, hai đầu ghi bội số theo UML (`1`: đúng một, `0..1`: không hoặc một, `0..*`: không hoặc nhiều).

Một số điểm thiết kế:

- `documents` là một công bố (mã, loại, kỳ, phạm vi, trạng thái); `document_files` là từng phiên bản file (băm SHA-256), nên BCTC công bố lại tạo dòng mới chứ không ghi đè.
- `line_items` lưu từng ô số theo cột (`column_kind`), kèm chuỗi gốc, trang và phiên bản pipeline; `validations` lưu kết quả từng ràng buộc. Toàn bộ đầu ra của mô hình và lịch sử đọc lại, sửa tay được lưu thêm thành bản ghi JSON theo từng file để kiểm tra lại mà không phải gọi mô hình.
- `documents.owner_user_id` khác rỗng là BCTC do người dùng tải lên, không xuất hiện trong dữ liệu công khai.



Hình 4.7: Sơ đồ CSDL phần dữ liệu BCTC. Bảng nét đứt thuộc sơ đồ còn lại.



Hình 4.8: Sơ đồ CSDL phần người dùng. Bảng nét đứt thuộc sơ đồ còn lại.

4.4 Thu thập tài liệu

4.4.1 Lấy danh sách và nhận dạng tiêu đề

Watcher gọi API danh sách tài liệu của Vietstock (logic kế thừa từ khóa trước) cho các mã đang theo dõi. Từ tiêu đề tiếng Việt, bộ luật nhận dạng xác định bộ khóa: mã, loại báo cáo (quý, bán niên, năm), kỳ, phạm vi (hợp nhất, riêng, duy nhất), trạng thái soát xét hay kiểm toán, và có phải bản điều chỉnh hay không. Bộ luật được kiểm thử trên toàn bộ tiêu đề thật của VN30 năm 2025–2026. Lần chạy đầu nhận dạng đúng 174/174 tài liệu.

4.4.2 Lưu trữ và phiên bản

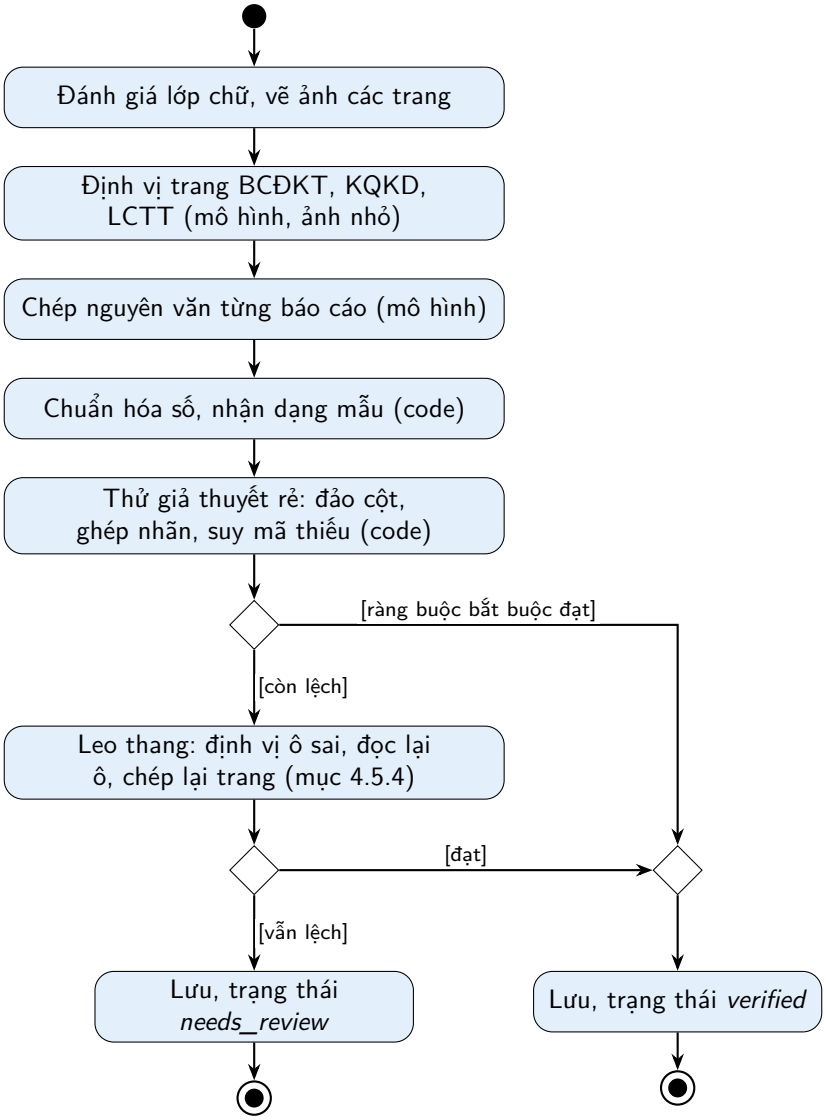
- Mỗi file được băm SHA-256. Cùng khóa nhưng khác hash là phiên bản mới, không ghi đè bản cũ.
- Cùng một file có thể được đăng dưới hai công bố khác nhau (ví dụ BCTC bán niên 2026 của GVR được đăng hai lần với cùng một file). Công bố sau được đánh dấu trùng và trỏ về công bố trước, không đọc lại, không tính hai lần vào thẻ hay phép đối chiếu giữa các kỳ.

- File nén (`.zip`, `.rar`) được giải nén và tách thành từng báo cáo.
- Lưu thời điểm Vietstock đăng (`source_listed_at`) và thời điểm hệ thống thấy (`discovered_at`). Giờ công bố chính thức (`published_at`) sẽ lấy từ HOSE, HNX ở giai đoạn sau.

Kho hiện có 532 tài liệu của 31 mã (VN30 và một mã người dùng yêu cầu thêm), trong đó 120 BCTC đã được đọc. Người dùng được mời cũng có thể tải lên BCTC riêng; tài liệu tải lên chỉ người đó thấy, không xuất hiện trong dữ liệu công khai.

4.5 Đọc và kiểm chứng BCTC

4.5.1 Quy trình



Hình 4.9: Biểu đồ hoạt động của quy trình đọc và kiểm chứng một BCTC. Hình thoi là nút rẽ nhánh (điều kiện ghi trong ngoặc vuông trên mỗi nhánh) hoặc nút gộp; chấm đen là điểm bắt đầu, vòng tròn có chấm là điểm kết thúc.

4.5.2 Mô hình chỉ chép, code mới hiểu số

Mô hình được yêu cầu chép đúng chuỗi in trên trang, ví dụ `(2.868.766)`, không tự đổi đơn vị hay tính toán. Đầu ra là JSON theo schema cố định (Listing 4.1). Code mới là phần phân tích chuỗi thành số:

- suy dấu phân cách hàng nghìn của cả tài liệu từ các nhóm 3 chữ số và phép cộng

kiểm tra;

- đọc đơn vị từ dòng "Đơn vị tính" và tiêu đề cột;
- hiểu số trong ngoặc là số âm;
- chuẩn hóa mã số và gán mã chuẩn cho ngân hàng (`b.nii`, `b.toi`…) theo tên dòng đã bỏ dấu.

Đoạn mã 4.1: Một dòng KQKD sau khi mô hình chép (VCB quý 2/2026)

```
{"stt": "XIV", "code": null,
 "label": "Lợi nhuận thuần trong kỳ phân bổ cho cổ đông của Ngân hàng",
 "page": 11,
 "values": {"q_cur": "14.542.276", "q_prev_year": "8.831.885",
            "ytd_cur": "23.998.842", "ytd_prev_year": "17.528.114"}}
```

4.5.3 Giả thuyết rẻ trước khi gọi lại mô hình

Nhiều lỗi có dạng lặp lại và sửa được bằng code. Mỗi giả thuyết được "phân xử" bằng chính các ràng buộc: giữ phương án làm số ràng buộc đạt nhiều nhất mà không làm mất ràng buộc nào đang đạt.

- **Đảo cột STT và mã số** theo từng trang của từng báo cáo.
- **Nhãn ngân hàng bị xuống dòng:** ghép lại tên dòng rồi so khớp với danh sách nhãn.
- **Mã thiếu:** một dòng không in mã nhưng bằng đúng phần còn thiếu của một ràng buộc thì được gán mã đó. Riêng dòng "LNST của cổ đông công ty mẹ / không kiểm soát" được gán mã 61/62 theo tên dòng (bài học từ lỗi VIC, mục 5.7).
- **Mã theo vị trí:** dòng không in mã nằm giữa hai dòng tổng được gán mã con của dòng tổng phía dưới (ví dụ `20.1`, `20.2`) để kiểm phép "dòng tổng = tổng các dòng thành phần". Ở LCTT doanh nghiệp, dòng tổng (08, 20, 30, 40, 50, 60, 70) được nhận theo tên dòng khi không có mã. Dòng tổng tạm không tên (ví dụ tiền từ hoạt động kinh doanh trước lãi vay và thuế đã nộp ở BCTC MSN) được nhận ra vì số của nó bằng tổng các dòng trước nó ở mọi cột. Ngân hàng dùng cùng cách này cho BCĐKT và LCTT. Trên web, mã đặt theo vị trí được hiện mờ để không bị nhầm với mã in trên BCTC.

- **Ngoại lệ thật của BCTC:** mã 269 (lợi thế thương mại) thuộc tài sản dài hạn khác; nhiều dòng LCTT cùng một mã thì cộng lại; hai dòng chi tiết BCĐKT khác tên nhưng in cùng mã (VJC in mã 321 cho cả vay ngắn hạn và nợ thuê tài chính ngắn hạn) cũng được cộng lại.

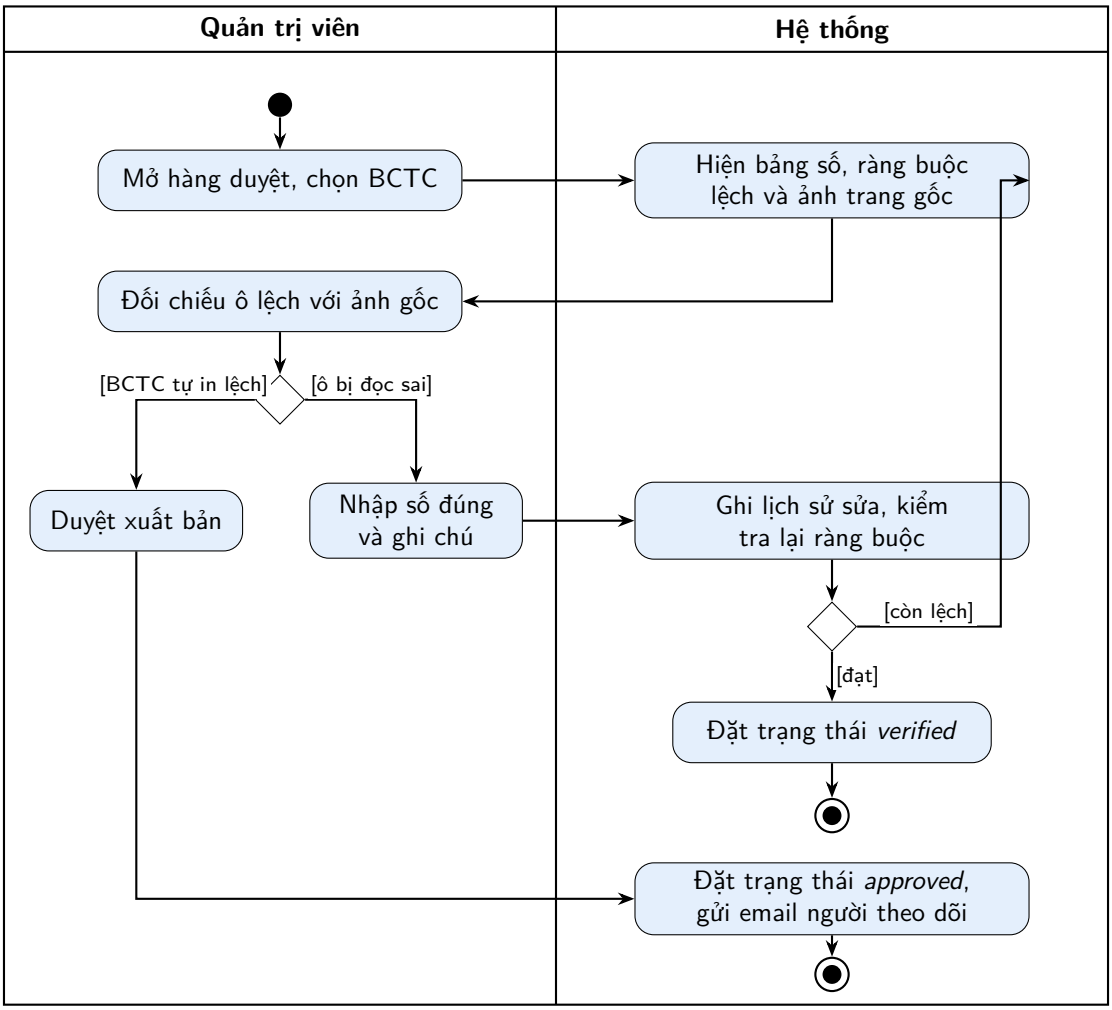
4.5.4 Thang leo thang khi còn lệch

1. BCĐKT chưa có đủ tổng tài sản và tổng nguồn vốn thì chép thêm trang kế tiếp, vì có thể bước định vị bỏ sót trang.
2. **Tự định vị ô sai bằng ràng buộc, rồi đọc lại riêng các ô đó** (mục 4.6).
3. Đọc lại các ô thuộc ràng buộc còn lệch ở độ phân giải cao hơn. Chỉ giữ lần đọc lại nếu số ràng buộc lệch giảm và số ràng buộc đạt không giảm.
4. **Chép lại cả báo cáo** (BCĐKT, KQKD hoặc LCTT) khi báo cáo đó vẫn còn ràng buộc bắt buộc lệch, hoặc BCĐKT, KQKD chưa có ràng buộc nào đạt. Bậc này nhắm vào các lỗi mà đọc lại từng ô không sửa được: bỏ sót dòng, lệch hàng, chép nhầm cả cột, trang lộn ngược. Nó khác lần chép đầu ở ba điểm:
   - Lần đầu gửi mọi trang của báo cáo trong một lần gọi; bậc này gửi **mỗi trang một lần gọi** rồi ghép các dòng theo thứ tự trang. Mỗi lượt trả lời ngắn hơn nên mô hình ít bỏ sót dòng ở chỗ chuyển trang.
   - Luôn dùng ảnh nét ở mức `original` (mục 4.6.4).
   - Nếu chép lại vẫn lệch, lần lượt xoay **từng trang một** thêm 180 độ rồi chép lại, vì một số file scan có trang lộn ngược (VHM quý 1/2026).

   Bản mới chỉ được giữ khi hiệu số "ràng buộc đạt trừ ràng buộc lệch" tốt hơn bản cũ (hoặc bằng nhưng có nhiều ràng buộc đạt hơn) và số ràng buộc đạt không giảm. Chỉ so số ràng buộc lệch là chưa đủ: bản chép lại làm mất mã số thì chạy được ít ràng buộc hơn nên trông như ít lệch hơn (KQKD quý 2/2026 của TCX: lệch từ 2 xuống 0, nhưng số ràng buộc kiểm được giảm từ 28 xuống 12). Kết quả đo ở mục 5.5.
5. Vẫn lệch thì chuyển duyệt tay. Người duyệt xem ảnh trang cạnh bảng số, sửa từng ô. Mỗi lần sửa được ghi lại và trở thành **dữ liệu vàng** để đánh giá.

4.5.5 Duyệt tay

BCTC còn lệch sau mọi bậc leo thang được đưa vào hàng duyệt. Hình 4.10 chia việc theo hai làn: quản trị viên và hệ thống.

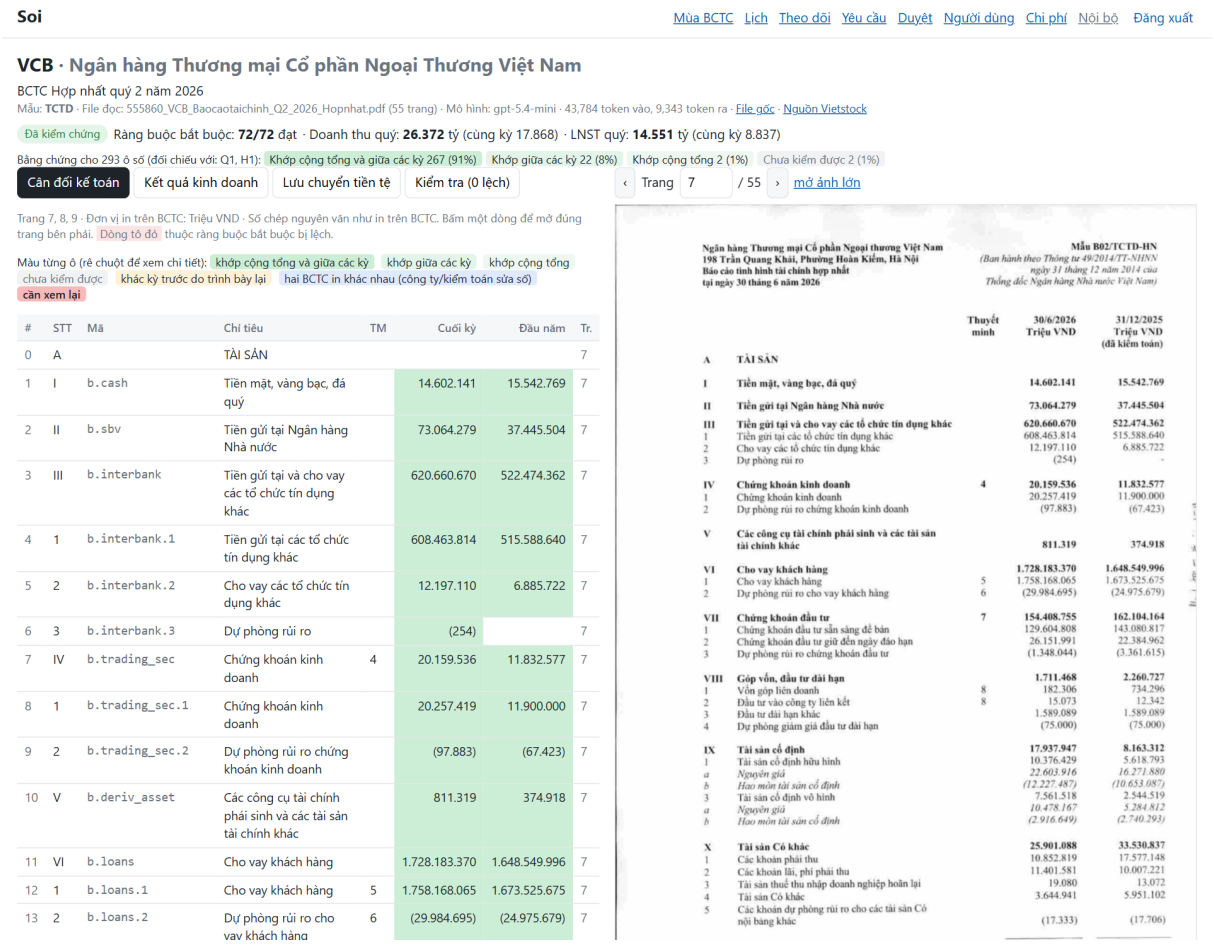


Hình 4.10: Biểu đồ hoạt động của việc duyệt tay, chia làn theo người thực hiện.

Người duyệt có thể sửa một ô số, hoặc sửa mã số của một dòng khi mô hình đọc nhầm mã (BCTC bán niên 2026 của GVR: mã 420a/420b bị đọc thành 421/421a). Hai loại sửa được ghi riêng: chỉ các ô số sửa tay mới được dùng làm dữ liệu vàng để đánh giá bước định vị ô sai (mục 5.4). Ví dụ BCTC bán niên của GVR chỉ có bản 72 dpi; sau khi đối chiếu ảnh phóng to, người duyệt sửa 33 ô số và 2 mã, và BCTC đạt mọi ràng buộc bắt buộc.

4.5.6 Bằng chứng cho từng ô

Sau khi kiểm chứng, mỗi ô số được xếp vào một loại bằng chứng: khớp cả phép cộng lẫn giữa các kỳ; chỉ khớp giữa các kỳ; chỉ khớp phép cộng; hai BCTC in khác nhau (doanh nghiệp hoặc kiểm toán sửa số); khác kỳ trước do trình bày lại; cần xem lại; hoặc chưa kiểm được. Giao diện tô màu từng ô theo loại này (Hình 4.11).



#	STT	Mã	Chỉ tiêu	TM	Cuối kỳ	Đầu năm	Tr.
0	A		TÀI SẢN				7
1	I	b.cash	Tiền mặt, vàng bạc, đá quý		14.602.141	15.542.769	7
2	II	b.sbv	Tiền gửi tại Ngân hàng Nhà nước		73.064.279	37.445.504	7
3	III	b.interbank	Tiền gửi tại và cho vay các tổ chức tín dụng khác		620.660.670	522.474.362	7
4	1	b.interbank.1	Tiền gửi tại các tổ chức tín dụng khác		608.463.814	515.588.640	7
5	2	b.interbank.2	Cho vay các tổ chức tín dụng khác		12.197.110	6.885.722	7
6	3	b.interbank.3	Dự phòng rủi ro		(254)		7
7	IV	b.trading_sec	Chứng khoán kinh doanh	4	20.159.536	11.832.577	7
8	1	b.trading_sec.1	Chứng khoán kinh doanh		20.257.419	11.900.000	7
9	2	b.trading_sec.2	Dự phòng rủi ro chứng khoán kinh doanh		(97.883)	(67.423)	7
10	V	b.deriv_asset	Các công cụ tài chính phái sinh và các tài sản tài chính khác		811.319	374.918	7
11	VI	b.loans	Cho vay khách hàng		1.728.183.370	1.648.549.996	7
12	1	b.loans.1	Cho vay khách hàng	5	1.758.168.065	1.673.525.675	7
13	2	b.loans.2	Dự phòng rủi ro cho vay khách hàng	6	(29.984.695)	(24.975.679)	7

Hình 4.11: Trang tài liệu: bên trái là bảng số đã đọc, tô màu theo bằng chứng; bên phải là ảnh trang BCTC gốc. Bấm một dòng để mở đúng trang.

4.6 Công nghệ lõi: tự định vị và tự sửa ô đọc sai

4.6.1 Ý tưởng

Khi một phép cộng lệch, cách đơn giản là đọc lại *tất cả* các ô trong phép cộng đó. Cách này tốn tiền, và lần đọc lại cũng có thể sai. Ý tưởng của Soi là **dùng chính lưới ràng buộc để khoanh vùng ô sai trước**, rồi mới đọc lại, theo nguyên lý định vị lỗi của Fellegi–Holt [7]. Soi thêm hai điều chỉnh riêng cho lỗi đọc ảnh:

- Số đề xuất phải **giống số cũ về mặt chữ số**: khác nhiều nhất 2 chữ số theo khoảng cách Levenshtein, vì đọc nhầm thường chỉ sai 1–2 chữ số. Số đề xuất cũng phải nguyên theo đơn vị in trên BCTC.
- Đề xuất **phải được ảnh xác nhận**: đọc lại riêng ô đó mà không cho mô hình biết con số mong đợi, và chỉ nhận khi lần đọc ra đúng số đề xuất. Hai nguồn độc lập là phép cộng và ảnh phải cùng chỉ một con số.

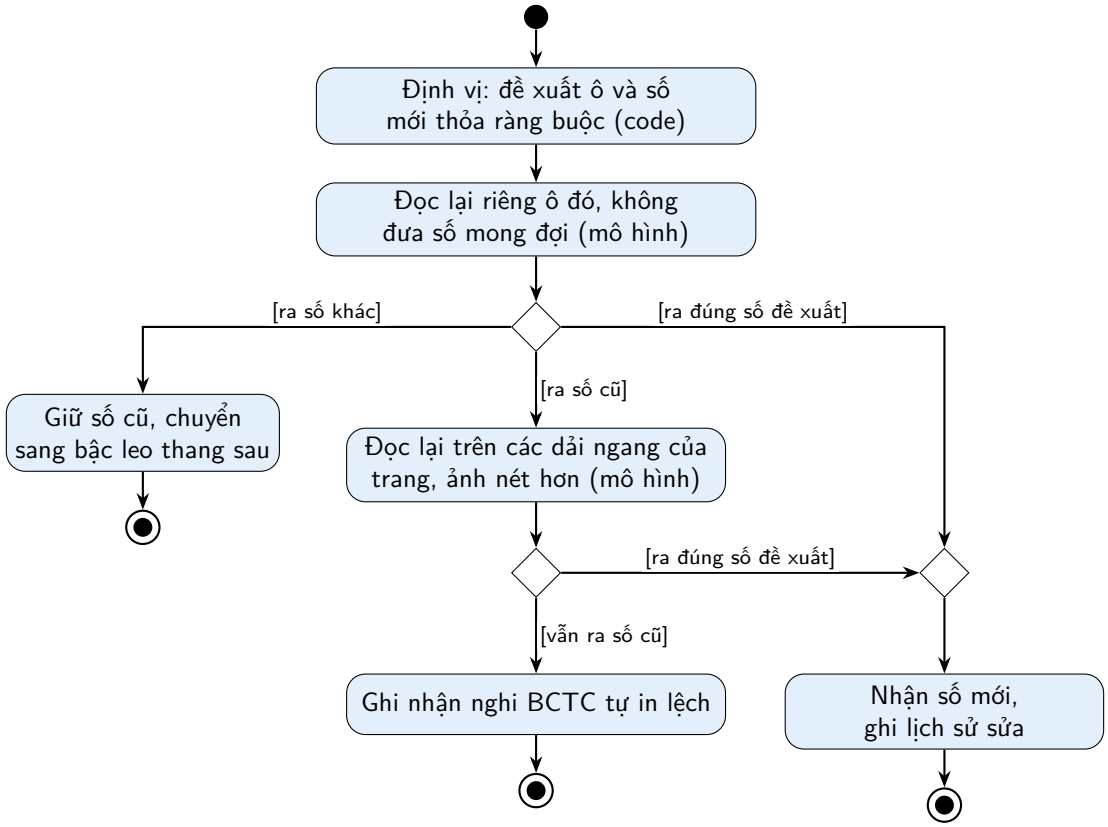
4.6.2 Thuật toán định vị

Thuật toán 1 Định vị ô đọc sai bằng ràng buộc (rút gọn)

Input: bảng số S; tập ràng buộc R; tập ràng buộc đang lệch $F \subseteq R$; δ_r là độ lệch của r
Output: danh sách đề xuất (ô, số mới, độ tin)

$P \leftarrow \emptyset$
for ràng buộc $r \in F$, ô c thuộc r **do**
    $v \leftarrow$ giá trị làm r khớp nếu thay c ▷ $v = S[c] \pm \delta_r$
    if v nguyên theo đơn vị in **and** số chữ số khác với $S[c] \leq 2$ **then**
        $S' \leftarrow S$ với $S'[c] = v$
        if S' ít ràng buộc lệch hơn S **and** không làm lệch ràng buộc đang đạt **then**
            thêm $(c, v,$ số ràng buộc được sửa$)$ vào P
xét thêm **cặp ô** cùng lệch một lượng (lỗi lan qua phép cộng giữa chúng)
chọn đề xuất sửa được nhiều ràng buộc nhất; nếu nhiều đề xuất ngang nhau và sửa *cùng một tập* ràng buộc thì gom thành **nhóm ngang nhau**
áp đề xuất, lặp lại với các ràng buộc còn lệch (tối đa 40 vòng)
return P kèm độ tin: *cao* (sửa từ 2 ràng buộc trở lên), *vừa*, *thấp*

4.6.3 Xác nhận bằng đọc lại



Hình 4.12: Biểu đồ hoạt động của bước đọc lại để xác nhận một đề xuất. Với một nhóm đề xuất ngang nhau, hệ thống đọc lại cả nhóm và chỉ nhận khi đúng *một* ô ra số đề xuất.

Vì sao không đưa con số mong đợi cho mô hình?

Nếu nói với mô hình "ô này phải là 4.831", mô hình có xu hướng đồng ý. Kết quả khi đó không còn là bằng chứng độc lập. Soi chỉ hỏi "ô ở dòng X, cột Y ghi số gì", rồi so câu trả lời với đề xuất bằng code. Phép so bỏ qua khác biệt về dấu phân cách và dấu ngoặc.

4.6.4 Chuẩn bị ảnh cho bước đọc lại

Đọc lại chỉ có ích khi mô hình nhìn rõ hơn lần đầu. Hai điều quyết định độ rõ của ảnh mà mô hình thực sự nhìn thấy:

- **API có thu nhỏ ảnh hay không.** Ở mức mặc định, API của mô hình thu ảnh về cạnh dài tối đa 2048 điểm ảnh và khoảng 2,5 triệu điểm ảnh [10]. Vẽ trang to hơn mức này rồi gửi đi không giúp gì, vì API thu về đúng cỡ ảnh lần chép đầu. Soi gửi các ảnh đọc lại ở mức `original`, giữ nguyên tới khoảng 10 triệu điểm ảnh.

- **Phóng ảnh scan như thế nào.** Ảnh scan 72 dpi (như BCTC bán niên của GVR) chỉ có chữ số cao khoảng 7 điểm ảnh. Khi vẽ trang ở độ phân giải cao, thư viện vẽ PDF phóng ảnh scan bằng cách nhân bản điểm ảnh, nên chữ số bị răng cưa và dễ nhầm 3 với 8. Soi vẽ trang đúng độ phân giải của ảnh scan gốc (một điểm ảnh trang ứng với một điểm ảnh scan), rồi phóng một lần bằng nội suy Lanczos tới khoảng 288 dpi, để chữ số cao khoảng 28 điểm ảnh. Mức phóng không vượt quá 3 lần ảnh gốc, vì phóng thêm không tạo ra thông tin mới.

Soi không chuyển ảnh sang trắng đen và không dùng mô hình tăng độ phân giải: trên bản scan chất lượng thấp, các bước xử lý ảnh truyền thống (ảnh xám, chuyển trắng đen) không cải thiện mà có khi còn làm OCR kém đi [8], còn mô hình tăng độ phân giải có thể tạo ra chi tiết không có thật trong vùng chữ [13]. Với chữ số tài chính, một nét giả là đủ biến chữ số này thành chữ số khác. Với file scan từ 100 dpi trở xuống, cách vẽ này được dùng ngay từ lần chép đầu, vì ô đọc đúng từ đầu thì không cần đọc lại. Kết quả đo ở mục 5.6.

4.6.5 Mở rộng sang ràng buộc giữa các BCTC

Một số lỗi không làm lệch phép cộng nào trong chính BCTC. Ví dụ đọc nhầm một dòng chi tiết không nằm trong ràng buộc bắt buộc. Khi đó hệ thống dùng thêm các ràng buộc giữa các kỳ (Hình 2.3): số đầu năm bằng số cuối năm trước, BCTC quý 2 khớp bán niên, quý 4 khớp năm. Nếu hai bản khác nhau, hệ thống đọc lại ô đó trên *cả hai* bản. Số mới chỉ được nhận khi nó làm hai bản khớp nhau mà không làm lệch ràng buộc bắt buộc nào.

4.7 Quản lý token và chi phí

Chi phí gọi mô hình được tính theo số token gửi vào và nhận về:

$$\text{Chi phí} = p_{\text{vào}} \times N_{\text{vào}} + p_{\text{ra}} \times N_{\text{ra}}, \tag{4.1}$$

trong đó p là giá mỗi token theo bảng giá của nhà cung cấp, N là số token. Với mô hình có bước suy luận, token suy luận được tính vào N_{ra}. Soi giảm cả hai đại lượng bằng các cách sau.

4.7.1 Giảm token vào

- **Chỉ gửi trang cần thiết:** bước định vị dùng ảnh nhỏ (cạnh dài 900 px) của tối đa 30 trang đầu; bước chép bảng chỉ gửi đúng các trang BCĐKT, KQKD, LCTT (cạnh dài 2000 px), không gửi cả tài liệu.
- **Đọc lại theo ô:** khi lệch, chỉ hỏi lại vài ô được bước định vị đề xuất, không chép lại cả báo cáo. Chép lại cả trang chỉ là bậc sau cùng trước khi chuyển duyệt tay.
- **Giả thuyết rẻ trước:** đảo cột, ghép nhãn, suy mã thiếu đều làm bằng code, không gọi mô hình.
- **Đọc một lần, dùng nhiều lần:** BCTC được đọc một lần khi công bố; file trùng nhận ra bằng SHA-256; ai hỏi sau cũng dùng lại kết quả trong kho. Thay đổi quy tắc thì kiểm tra lại trên kết quả đã lưu, không đọc lại ảnh.

4.7.2 Giới hạn token ra

Mỗi bước gọi mô hình có trần token ra riêng (Bảng 4.6), đặt khoảng 3–4 lần mức lớn nhất đo được, để chặn trường hợp mô hình trả lời dài bất thường. Đầu ra luôn theo khuôn JSON cố định nên mô hình không viết thêm lời thừa.

Bảng 4.6: Trần token ra theo bước và mức đo được (trung bình mỗi lần gọi, lớn nhất trên các BCTC)

Bước	**Đo được (lớn nhất)**	**Trần**
Định vị trang	1.267	6.000
Chép một báo cáo (BCĐKT, KQKD, LCTT)	5.697	24.000
Chép lại một trang	4.143	16.000
Đọc lại ô (kiểm chứng, sửa lỗi, đọc phóng to)	1.156	6.000
Nhận diện file người dùng tải lên	–	3.000

4.7.3 Đo và giới hạn chi phí

- Mỗi lần gọi được ghi số token vào, ra và thời gian **theo từng bước**; trang "Chi phí" dành cho quản trị viên hiện chi phí tháng này so với trần, theo ngày, theo bước, theo người yêu cầu và các BCTC tốn nhiều nhất (Bảng 5.2 lấy từ cùng nguồn số liệu). Trang tài liệu hiện số token đã dùng cho BCTC đó.
- Mỗi người dùng có **hạn mức yêu cầu mới mỗi ngày**; yêu cầu trả ngay từ kho không tính vào hạn mức.

- Tổng chi phí gọi mô hình mỗi tháng không vượt **trần tháng** (mặc định 5 USD); vượt thì yêu cầu mới nằm chờ sang tháng sau, giao diện báo cho người dùng biết.

Bảng 4.7: Token mỗi báo cáo so với hệ thống của khóa trước

	Khóa trước	**Soi**
Token vào mỗi báo cáo	272.054	59.112
Token ra mỗi báo cáo	41.106	16.218
Chi phí mỗi báo cáo	0,04 USD	0,117 USD (trung vị 0,084)
Ghi chú	Một báo cáo, gửi toàn bộ văn bản OCR cho nhiều bước	Trung bình 29 BCTC quý 4/2025, quy trình hiện tại, đã gồm mọi lần đọc lại

Soi dùng ít token vào hơn khoảng 4,7 lần, nhưng chi phí mỗi báo cáo cao hơn vì mô hình đọc ảnh đắt hơn mô hình khóa trước dùng cho văn bản OCR, và vì Soi đọc lại để kiểm chứng. Đổi lại, Soi không cần GPU để chạy OCR và mỗi số đều đã được kiểm chứng.

4.8 Thẻ KQKD và giao diện

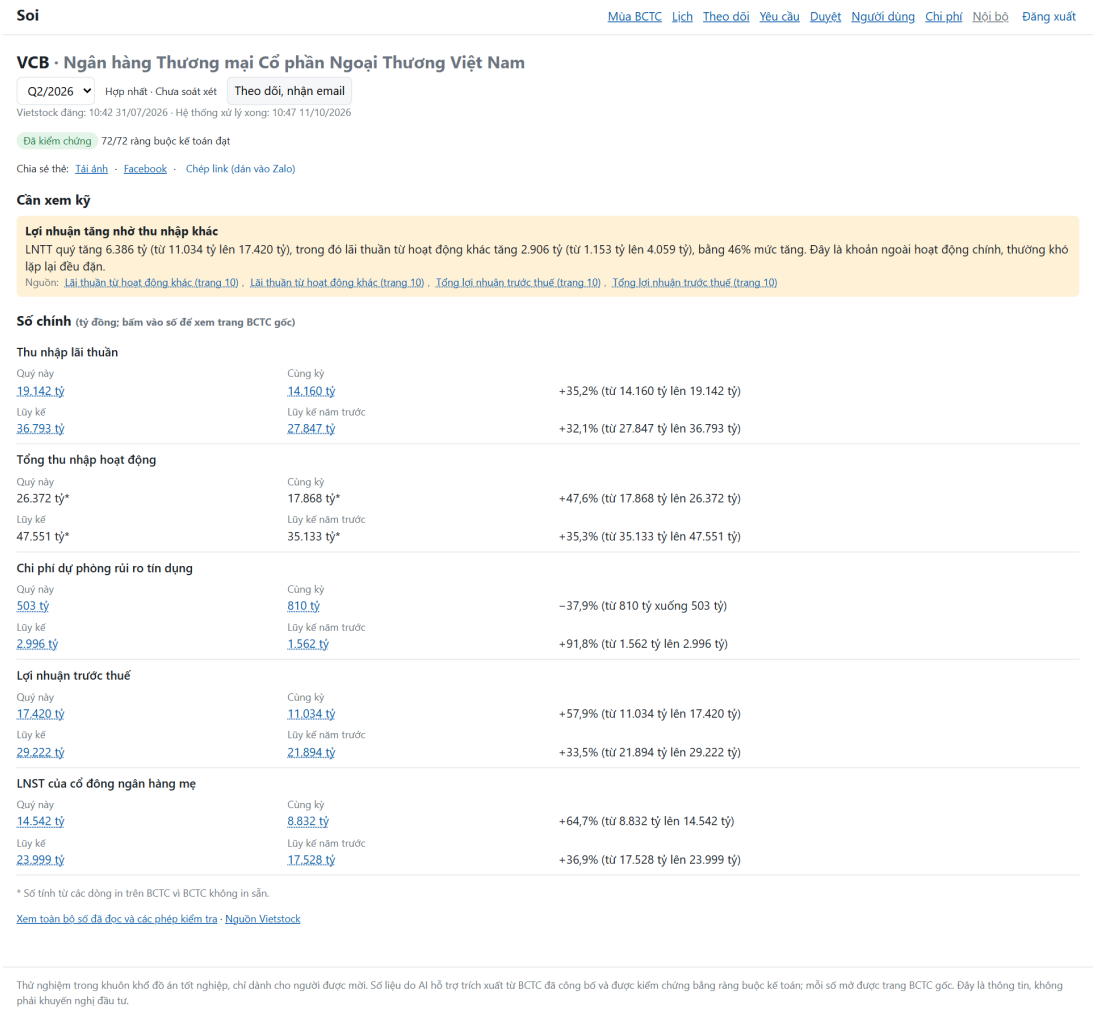
4.8.1 Thẻ KQKD

Thẻ được tính hoàn toàn bằng code từ số đã kiểm chứng. Mỗi giá trị trên thẻ mang theo nguồn: tài liệu, trang, dòng và chuỗi gốc. Doanh nghiệp thường có các chỉ tiêu doanh thu thuần, lợi nhuận gộp và LNST của cổ đông công ty mẹ. Ngân hàng có thu nhập lãi thuần, tổng thu nhập hoạt động, chi phí dự phòng, LNTT và LNST của cổ đông ngân hàng mẹ.

Quy tắc hiển thị tăng trưởng: chỉ in % khi cả hai kỳ đều lãi. Khi có kỳ lỗ, thẻ mô tả bằng lời, ví dụ "lỗ thu hẹp từ 6,8 tỷ còn 3,2 tỷ", thay vì in "+53,6%" gây hiểu nhầm.

Bảng 4.8: Các cờ "cần xem kỹ" trên thẻ. Cờ chỉ nêu số liệu kèm nguồn, không đưa nhận định đầu tư.

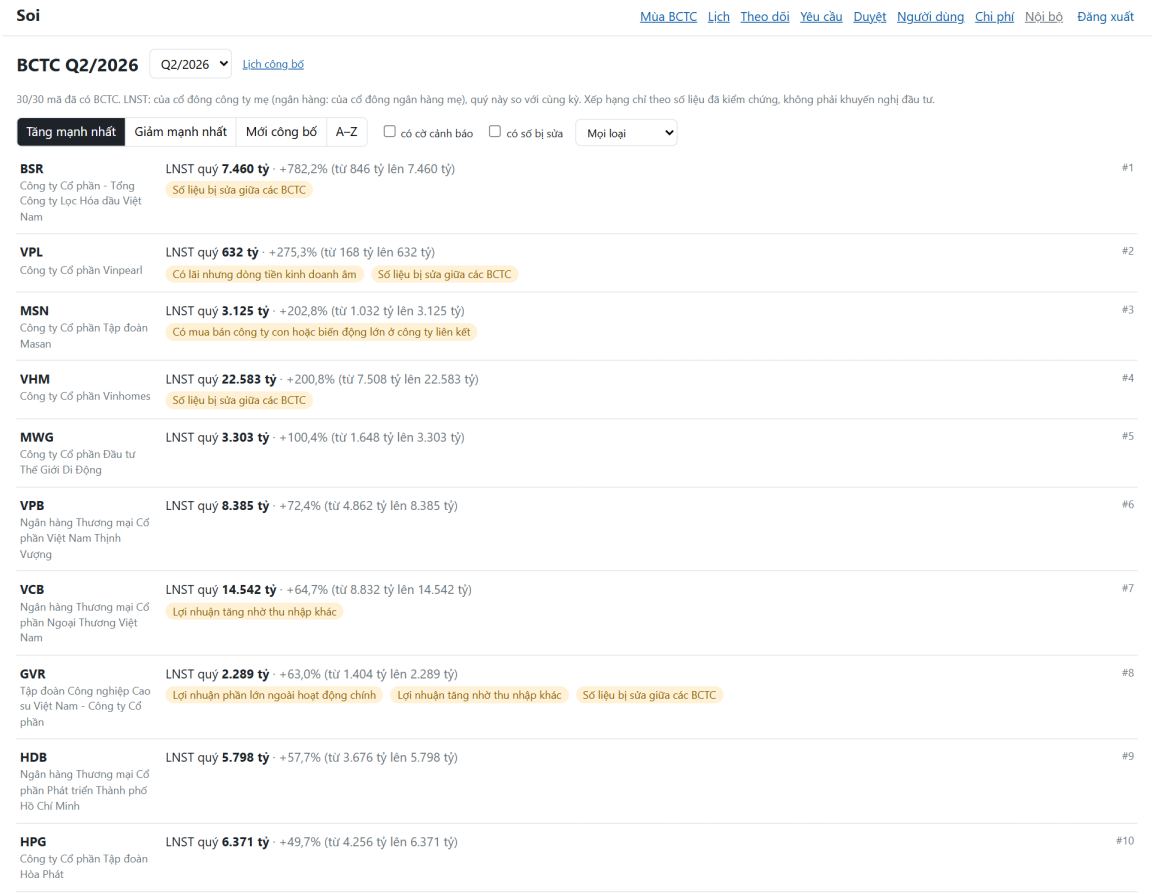
Cờ	**Điều kiện (tóm tắt)**
Lỗ hoặc đổi dấu lợi nhuận	Một trong hai kỳ lỗ: % không có ý nghĩa
Tăng trưởng do nền thấp	Tăng trên 100% và LNST cùng kỳ dưới 1/3 trung bình 4 quý trước đó
Lợi nhuận phần lớn ngoài hoạt động chính	Hơn nửa LNTT không đến từ LN gộp − chi phí bán hàng, quản lý
Lợi nhuận tăng nhờ thu nhập khác	Lợi nhuận khác (ngân hàng: lãi thuần hoạt động khác) tăng từ 1/3 mức tăng LNTT và từ 10% LNTT quý
Hoàn nhập / chi phí dự phòng giảm mạnh	Ngân hàng: dự phòng âm, hoặc giảm quá nửa trong khi LNTT tăng
Mua bán công ty con, biến động công ty liên kết	Dòng LCTT về mua, bán công ty con; lãi liên doanh, liên kết tăng trên 3 lần
Có lãi nhưng dòng tiền kinh doanh âm	LNST lũy kế dương, lưu chuyển tiền thuần từ hoạt động kinh doanh âm
Số liệu bị sửa giữa các BCTC	Hai BCTC cùng ngày (quý 2 và bán niên…) in khác nhau ở các dòng chính



Hình 4.13: Thẻ KQKD của VCB quý 2/2026. LNST tăng 64,7%, và cờ cho thấy gần một nửa mức tăng LNTT đến từ thu nhập hoạt động khác. Bấm vào mỗi số để mở trang BCTC gốc.

4.8.2 Bảng xếp hạng mùa BCTC

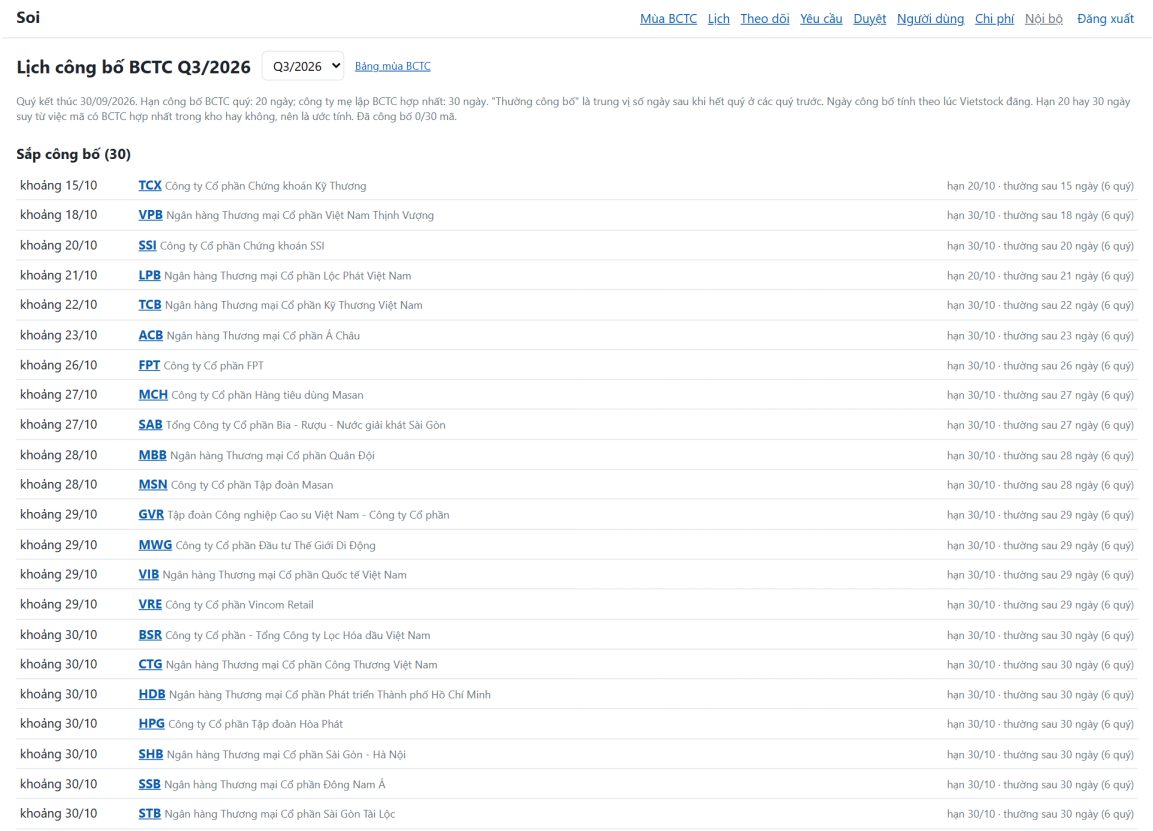
Bảng xếp hạng các mã theo tăng trưởng LNST quý so với cùng kỳ, chỉ gồm thẻ đã kiểm chứng. Người dùng lọc được theo loại (ngân hàng, doanh nghiệp), theo "có cờ" và theo "số bị sửa" (Hình 4.14).



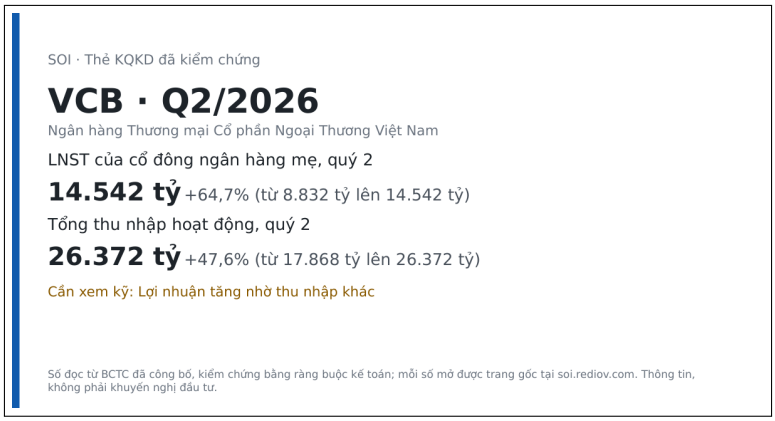
Hình 4.14: Bảng xếp hạng mùa BCTC quý 2/2026 (phần đầu trang).

4.8.3 Lịch công bố và ảnh chia sẻ

Lịch công bố cho biết hạn chót của từng mã (20 hoặc 30 ngày sau khi hết quý) và "ngày dự kiến". Ngày dự kiến là trung vị số ngày công bố sau khi hết quý của 8 quý gần nhất. Ảnh thẻ kích thước 1200×630 dùng để chia sẻ lên Facebook, Zalo; chỉ thẻ đã kiểm chứng mới có trang chia sẻ công khai.



(a) Lịch công bố quý 3/2026 (phần đầu trang)



(b) Ảnh thẻ để chia sẻ

Hình 4.15: Lịch công bố và ảnh thẻ chia sẻ.

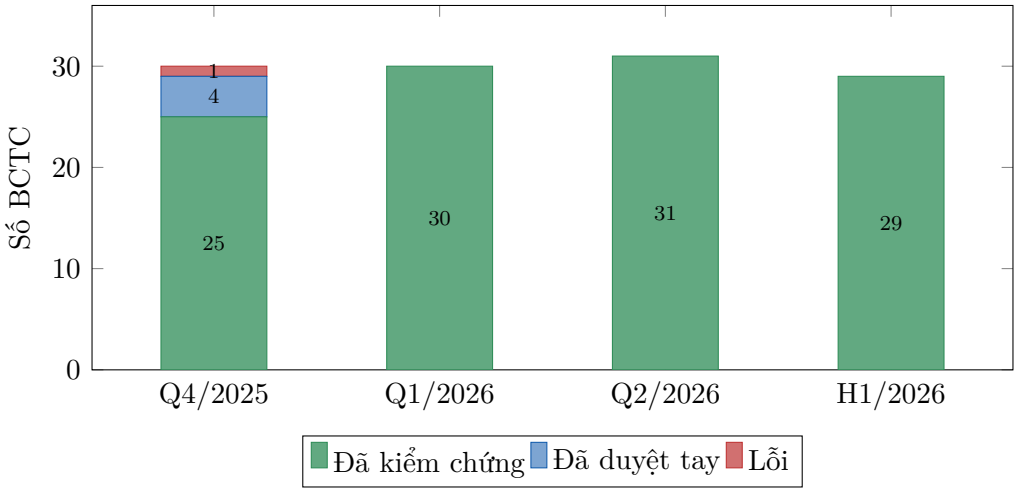
4.8.4 Người dùng và quyền riêng tư

Giai đoạn thử nghiệm chỉ dành cho người được mời, đăng nhập bằng link gửi qua email. Người dùng theo dõi mã để nhận email khi có BCTC mới, gửi yêu cầu đọc mã ngoài danh sách (có hạn mức mỗi ngày), hoặc tải lên BCTC riêng. Tài liệu tải lên chỉ chủ sở hữu thấy.

Chương 5

Kết quả thực nghiệm và đánh giá

5.1 Tỷ lệ BCTC đạt kiểm chứng



Hình 5.1: Trạng thái 120 BCTC đã đọc (VN30, cộng một mã ngoài VN30 do người dùng yêu cầu ở quý 2/2026): 119/120 đạt kiểm chứng hoặc được duyệt tay, không còn BCTC nào chờ duyệt. Không tính một BCTC bán niên trùng file với công bố khác.

Bốn BCTC quý 4/2025 "đã duyệt tay" (BSR, SSB, VPL, VHM) là trường hợp chính BCTC tự cộng lệch. Lần đọc lại phóng to vẫn ra đúng số cũ, nên người duyệt ghi rõ lý do rồi duyệt. Ví dụ ở cột quý 4/2024 của BCTC VHM, mã 30 in 17.067.869, trong khi các dòng 20 đến 26 cộng ra 16.067.869 (cùng công thức này khớp ở ba cột còn lại của bảng) và mã 50 cũng khớp với 16.067.869; nhiều khả năng doanh nghiệp in nhầm một chữ số ở mã 30. Bản lỗi duy nhất (TCX quý 4/2025) là một công ty chứng khoán có cấu trúc trang khác thường.

5.2 Độ đúng theo từng ô

Tỷ lệ BCTC đạt kiểm chứng chưa cho biết bao nhiêu ô số được xác nhận, vì một ô chỉ được kiểm khi nó nằm trong ít nhất một ràng buộc. Bảng 5.1 chia toàn bộ 35.075 ô số của 120 BCTC theo cách ô đó được xác nhận.

Bảng 5.1: Phân loại 35.075 ô số theo cách được xác nhận (VN30, quý 4/2025 đến bán niên 2026)

Loại	**Số ô**	**Tỷ lệ**
Đúng ngay lần đọc đầu, ràng buộc xác nhận	31.066	88,6%
Thuộc báo cáo phải chép lại trang, sau đó ràng buộc xác nhận	1.456	4,2%
Đọc lại riêng ô (định vị ô sai, đối chiếu kỳ) mới đúng	32	0,1%
Người duyệt sửa sau khi đối chiếu ảnh gốc	80	0,2%
Chưa nằm trong ràng buộc nào	2.441	7,0%

Như vậy 93,0% số ô đã được ràng buộc xác nhận, và không còn ô nào lệch mà chưa xử lý. Nhóm chưa kiểm được không có nghĩa là sai: đó là các ô không nằm trong phép cộng nào. Khoảng 900 ô trong nhóm này là dòng chi tiết của công ty chứng khoán, sẽ được kiểm khi bổ sung ràng buộc chi tiết cho mẫu CTCK; phần còn lại chủ yếu là các dòng đứng riêng như "trong đó: chi phí lãi vay" hay lãi cơ bản trên cổ phiếu. Ràng buộc chi tiết của mẫu TT99 và phép kiểm theo vị trí cho dòng không in mã đã giảm nhóm này từ 17,5% xuống 7,0%.

5.3 Chi phí

5.3.1 Cách tính

Mỗi BCTC có một bản ghi trích xuất, cộng dồn token của mọi lần gọi mô hình cho chính BCTC đó: định vị trang, chép bảng, chép lại trang, đọc lại ô. Vì vậy chi phí trong mục này là **chi phí đọc một BCTC** đúng như khi hệ thống chạy thật. Chi phí **phát triển** (các lần chạy thử rồi bị ghi đè khi sửa code, các thử nghiệm riêng) **không** nằm trong các con số dưới đây; tổng tiền thực trả cho nhà cung cấp mô hình trong giai đoạn phát triển cao hơn.

Số liệu đáng tin nhất cho chi phí vận hành là **29 BCTC quý 4/2025** (bản lỗi của TCX không có bản ghi chi phí): đây là đợt đọc đầu tiên chạy trọn bằng quy trình hiện tại (có định vị ô sai, đọc phóng to) và có ghi chi phí theo từng bước. 90 BCTC các kỳ

còn lại được đọc bằng quy trình cũ, sau đó được đọc lại một phần bằng quy trình hiện tại; chi phí của chúng (trung bình 0,108 USD) dùng để đối chiếu.

Bảng 5.2: Chi phí trung bình mỗi BCTC theo bước, quy trình hiện tại (29 BCTC quý 4/2025, mô hình gpt-5.4-mini)

Bước	**Lần gọi**	**Token vào**	**Token ra**	**USD**
Định vị trang	1,2	23.917	770	0,021
Chép BCĐKT, KQKD, LCTT	3,0	22.702	9.498	0,060
Chép lại trang còn lệch	2,7	10.110	5.658	0,033
Đọc lại ô (định vị ô sai, đối chiếu kỳ)	0,7	2.383	292	0,003
Tổng mỗi BCTC	**7,6**	**59.112**	**16.218**	**0,117**

Bảng 5.3: Phân bố chi phí mỗi BCTC (USD)

	Số BCTC	**Trung bình**	**Trung vị**	**90% dưới**
Quy trình hiện tại (quý 4/2025)	29	0,117	0,084	0,173
Ngân hàng	13	0,096		
Doanh nghiệp thường	15	0,136		
Công ty chứng khoán	1	0,121		
Các kỳ còn lại (Q1, Q2, bán niên 2026)	90	0,108	0,083	0,136

Trung vị (0,084 USD) thấp hơn trung bình vì một số BCTC khó tốn gấp 2–3 lần: BCTC phải chép lại nhiều trang, hoặc BCTC tự in lệch nên hệ thống đọc lại nhiều lần trước khi chuyển duyệt tay. Bước "chép lại trang" chiếm khoảng 1/4 chi phí và sẽ giảm khi bộ quy tắc bắt được thêm các dạng BCTC đặc biệt (mỗi lỗi quy tắc đã sửa ở quý 4/2025 đều từng gây chép lại).

5.3.2 Ước tính chi phí vận hành

Với mỗi mã, mỗi kỳ Soi chỉ đọc một BCTC dùng cho thẻ (ưu tiên hợp nhất), không đọc mọi bản riêng lẻ. Một năm có 4 BCTC quý, 1 bán niên và 1 năm, tức khoảng 6 BCTC mỗi mã. Lấy 0,10–0,12 USD mỗi BCTC:

Bảng 5.4: Ước tính chi phí gọi mô hình khi vận hành (chưa gồm đọc theo yêu cầu người dùng, đã có trần riêng)

Phạm vi	**BCTC mỗi mùa quý**	**USD mỗi mùa quý**	**USD mỗi năm**
VN30	khoảng 30	3–3,5	18–22
VN100	khoảng 100	10–12	60–72

5.4 Định vị ô đọc sai

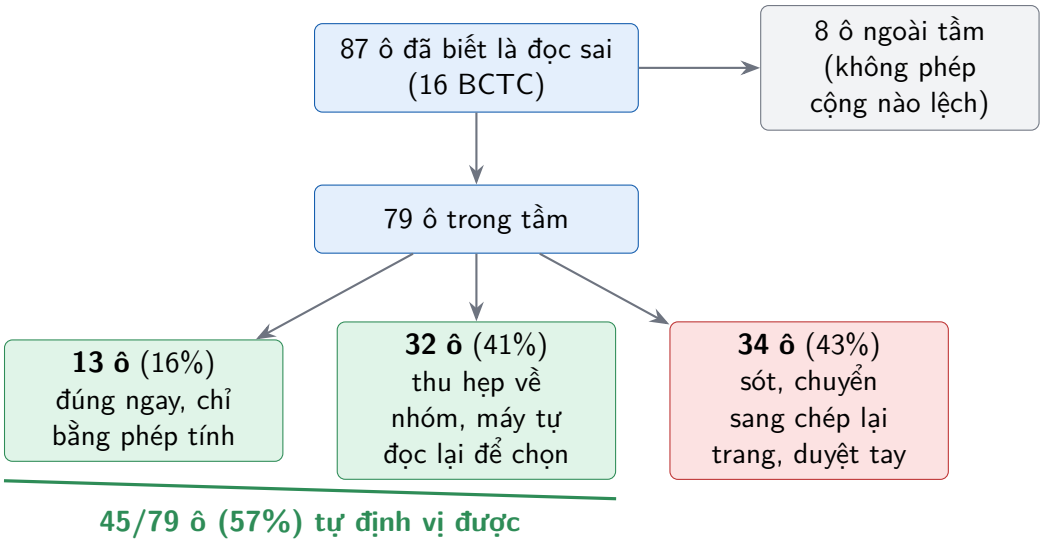
5.4.1 Bộ đề và cách thử

Trong các lần chạy, hệ thống đã gặp **87 ô số bị đọc sai** ở 16 BCTC mà ta biết cả số sai lẫn số đúng: hoặc người duyệt đã sửa tay sau khi xem ảnh gốc, hoặc lần đọc lại đã ra số đúng và BCTC sau đó đạt kiểm chứng. Thí nghiệm như sau: lấy từng BCTC, **đặt lại số sai vào đúng ô cũ**, chạy bước định vị (chỉ dùng phép tính trên các ràng buộc, không gọi mô hình), rồi so đề xuất với số đúng.

Bộ đề này **nghiêng về các ca khó**: một ô chỉ vào bộ đề khi quy trình lúc đó chưa tự xử lý được, phải sửa tay hoặc phải đọc lại. Các ô đọc sai mà quy trình đã tự sửa ngay thì không có trong đề.

5.4.2 Bốn loại kết quả

- **Ngoài tầm:** ô sai không nằm trong phép cộng bắt buộc nào bị lệch, và đối chiếu với BCTC kỳ khác cũng không tự chỉ ra được. Đọc sai ô này thì mọi phép cộng vẫn khớp, nên không phương pháp nào dựa trên phép cộng nhận ra được. Các ô này được loại khỏi phép đo.
- **Đúng ngay:** chỉ bằng phép tính, bước định vị chỉ ra đúng một ô và đúng số, chưa cần nhìn lại ảnh. Thường là ô nằm trong hai phép cộng cùng lệch.
- **Cần đọc lại cả nhóm:** phép tính thu hẹp được về một nhóm vài ô, trong đó có phương án đúng, nhưng chưa biết ô nào. Ví dụ: tài sản ngắn hạn (mã 100) bằng tổng các mã 110 đến 150 nhưng đang lệch đúng 1 tỷ đồng. Nếu tiền (mã 110) đọc nhầm 6,231 tỷ thành 5,231 tỷ thì lệch 1 tỷ; nếu tồn kho (mã 140) đọc nhầm 13,4 tỷ thành 12,4 tỷ thì cũng lệch đúng 1 tỷ. Cả hai đều chỉ khác một chữ số. Khi đó hệ thống **tự gửi ảnh trang cho mô hình đọc lại riêng các ô trong nhóm** (không cho biết số mong đợi) và nhận ô duy nhất đọc ra đúng số đề xuất (mục 4.6). Bước này hoàn toàn tự động, không có người chấm.
- **Sót:** bước định vị không đưa ra đề xuất nào cho ô này. Ô đi tiếp sang các bậc sau: chép lại trang, rồi duyệt tay.



Hình 5.2: Kết quả định vị ô đọc sai trên bộ đề 87 ô. Trong 42 nhóm cần đọc lại có tổng cộng 172 ô, khoảng 4 ô mỗi nhóm; đọc lại vài ô tốn khoảng 0,003 USD mỗi BCTC. Nếu bỏ BCTC bán niên của GVR (file 72 dpi, xem mục dưới), tỷ lệ tự định vị được là 29/46 ô (63%).

5.4.3 Phân tích các ca ngoài tầm, ca sót và đề xuất sai

- **8 ô ngoài tầm** là các dòng chi tiết không thuộc phép cộng bắt buộc nào, hoặc chỉ lệch so với BCTC kỳ khác. Người duyệt tìm ra chúng nhờ màu bằng chứng trên trang tài liệu ("cần xem lại", "chưa kiểm được"). Các chỉ tiêu dùng trên thẻ KQKD đều nằm trong phép cộng bắt buộc, nên đọc sai thì phép cộng sẽ lệch và hệ thống không công bố.
- **34 ô sót** phần lớn rơi vào trường hợp **nhiều ô sai cùng lúc trong cùng một phép cộng**, trái với giả thiết của bước định vị là mỗi phép cộng chỉ có một ô sai (hoặc hai ô lệch cùng một lượng):
  - 17 ô của BCTC bán niên 2026 của GVR. File chỉ có độ phân giải 72 dpi, nên mô hình đọc sai nhiều chữ số trên cùng một trang. Ví dụ ba dòng nợ ngắn hạn (mã 312, 316, 319) cùng sai trong phép cộng của mã 310; nguyên giá và hao mòn tài sản cố định cùng sai trong phép cộng của mã 221. Khi đó không có cách thay một ô nào làm phép cộng khớp lại. Người duyệt sửa các ô này sau khi đối chiếu ảnh phóng to.
  - 9 ô nằm trong **cùng một cột** (số liệu cùng kỳ năm trước) của BCTC quý 4/2025 của VHM: cả cột bị đọc sai nhiều chỗ một lúc. Nguyên nhân sau này

tìm ra là các trang KQKD của BCTC đó bị vẽ lộn ngược (mục 5.6).

  - 8 ô của BCTC quý 1 và quý 2/2026 của VHM, trong đó 2 ô mô hình chép số của một dòng khác (số khác hẳn, không phải nhầm 1–2 chữ số).

- **5 đề xuất sai** đều ở các BCTC của VHM có nhiều ô sai cùng lúc nói trên. Không đề xuất sai nào được nhận trong các lần chạy thật, vì số đề xuất chỉ được nhận khi lần đọc lại ảnh ra đúng số đó. Trong các lần chạy thật, mọi số được nhận qua bước "định vị → đọc lại xác nhận" đều đúng khi đối chiếu với ảnh gốc. Ví dụ BCTC bán niên của HDB có một ô BCĐKT đọc sai được sửa đúng nhờ đề xuất của bước định vị; bước đọc phóng to theo dải sửa được một ô của VHM mà lần đọc lại thường vẫn nhầm.

5.5 Chép lại cả báo cáo

Thống kê từ nhật ký lưu trong từng BCTC: mỗi lần chép lại ghi số ràng buộc đạt và lệch trước, sau, và bản mới có được giữ hay không.

Bảng 5.5: Bậc chép lại cả báo cáo trên 120 BCTC (khoảng 360 báo cáo BCĐKT, KQKD, LCTT)

Chỉ tiêu	**Số báo cáo**
Phải chép lại (vẫn lệch sau khi đã đọc lại từng ô)	46
Bản chép lại tốt hơn nên được giữ	16 (35%)
trong đó hiện đạt mọi ràng buộc bắt buộc	16/16
trong đó nhờ xoay trang 180 độ	4
Bản chép lại không tốt hơn, giữ bản cũ	30

Khi được giữ, bản chép lại sửa triệt để: cả 16 báo cáo đều hết lệch, gồm 1.456 ô số (4,2% toàn bộ ô, Bảng 5.1). Bậc này sửa được những lỗi mà đọc lại từng ô không sửa được: BCĐKT quý 1/2026 của MBB có thêm 9 dòng bị bỏ sót, LCTT bán niên của GVR thêm 7 dòng; KQKD bán niên của GVR, HDB, MCH trước đó không kiểm được ràng buộc nào; cả ba báo cáo của VHM quý 1/2026 và KQKD quý 4/2025 của HPG có trang lộn ngược. Mặt hạn chế là 30/46 lần chép lại không giúp gì; phần lớn các báo cáo đó về sau hết lệch nhờ đọc lại ô, sửa quy tắc hoặc sửa tay, còn 4 báo cáo là do chính BCTC in lệch. Bậc này chiếm khoảng 0,033 USD mỗi BCTC (Bảng 5.2). Số ràng buộc "trước" được tính theo bộ quy tắc lúc chạy, còn trạng thái hiện tại đã gồm cả các lần sửa quy tắc về sau, nên không tách được 30 báo cáo kia hết lệch nhờ cách nào.

5.6 Chuẩn bị ảnh cho bước đọc lại

Thí nghiệm dùng lại các ô đã biết là đọc sai của mục 5.4, cộng thêm số ô đối chứng bằng nhau: các ô đúng lấy ngẫu nhiên trên cùng trang, để đo xem cách vẽ mới có làm hỏng ô đang đúng hay không. Mỗi trang được hỏi một lần cho mỗi cách vẽ. Ô sai và ô đối chứng được trộn lẫn, và mô hình không được biết số mong đợi. Ba trang bị loại vì bản ghi lưu sai góc xoay nên cả hai cách đều vẽ trang lộn ngược (mục dưới); còn lại 27 trang của 16 BCTC.

Bảng 5.6: Đọc lại 71 ô sai và 71 ô đối chứng (27 trang của 16 BCTC, gpt-5.4-mini)

Cách vẽ ảnh	**Ô sai đọc ra đúng**	**Ô đối chứng vẫn đúng**
Cũ: vẽ trang cạnh dài 3000 điểm ảnh, API tự thu nhỏ	38/71 (54%)	64/71 (90%)
Mới: vẽ theo độ phân giải scan gốc, phóng Lanczos, mức `original` (mục 4.6.4)	**57/71 (80%)**	**67/71 (94%)**

So từng ô: cách mới đọc đúng 23 ô sai mà cách cũ đọc sai, chỉ 4 ô theo chiều ngược lại (kiểm định dấu, $p < 0{,}001$). Ở ô đối chứng, cách mới đúng thêm 6 ô và sai thêm 3 ô; khác biệt này không có ý nghĩa thống kê, tức là cách mới không làm hỏng ô đang đúng. Lợi ích dồn vào file scan từ 100 dpi trở xuống: ô sai đọc ra đúng tăng từ 24/53 lên 43/53; với file scan nét hơn, kết quả không đổi (14/18). Mỗi lần gọi tốn khoảng gấp đôi token, nhưng bước đọc lại chỉ chiếm khoảng 3% chi phí đọc một BCTC (Bảng 5.2). Mỗi cách chỉ chạy một lần, nên kết quả từng trang còn dao động; khác biệt tổng thể giữa hai cách thì đủ lớn để kết luận.

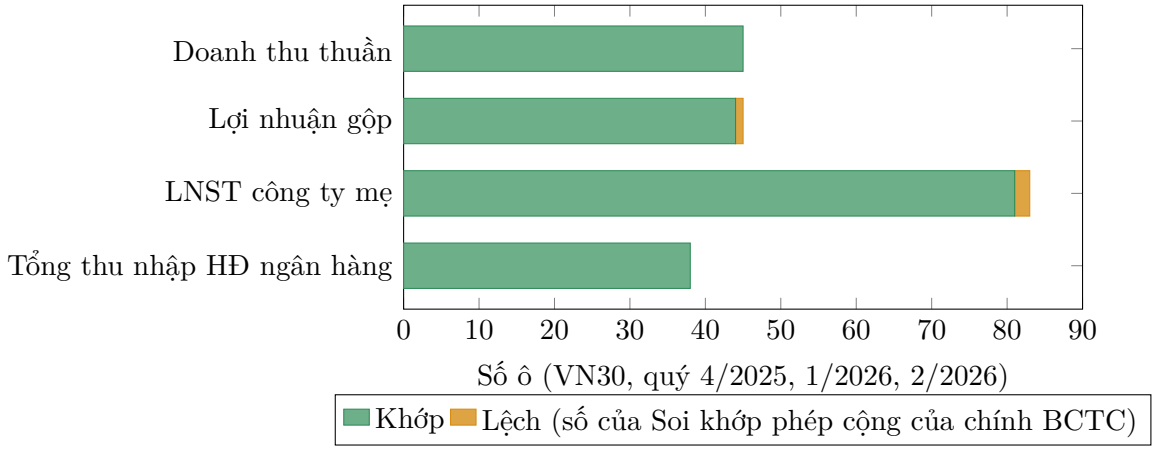
Kiểm lại trong quy trình thật: trả các ô đã biết về số sai cũ trên 4 BCTC mờ (GVR bán niên, VHM quý 1/2026, HDB, LPB; 51 ô), rồi chạy bước "định vị → đọc lại → chỉ nhận khi khớp". Cách cũ tự sửa đúng 11 ô, cách mới 20 ô; cả hai cách đều không nhận nhầm ô nào, chi phí gần như nhau (0,11 và 0,12 USD cho cả 4 BCTC).

Phát hiện phụ: trang lộn ngược

Khi xem ảnh của thí nghiệm, ba trang KQKD của BCTC quý 4/2025 của VHM hiện ra lộn ngược: bước định vị trang ghi góc xoay 90 độ trong khi đúng phải là 270 độ. Cả KQKD của BCTC này vì vậy đã được chép trên ảnh lộn ngược, và đây là nguyên nhân của lỗi "cả cột hỏng" ở mục 5.4. Góc xoay của các trang này đã được sửa. Với BCTC đọc từ nay, trang lộn ngược làm ràng buộc lệch, nên ở bậc chép lại hệ thống sẽ thử xoay từng trang 180 độ (mục 4.5.4).

5.7 Đối chiếu với nguồn dữ liệu công khai

Sau mỗi mùa BCTC, một chương trình đối chiếu so các chỉ tiêu trên thẻ với bảng KQKD theo quý của một trang dữ liệu tài chính công khai. Số của nguồn ngoài **chỉ dùng nội bộ**, không hiển thị trên Soi.



Hình 5.3: Đối chiếu với nguồn ngoài: 208/211 ô khớp. 3 ô lệch (VJC quý 1/2026 chênh 2 nghìn đồng; VHM quý 4/2025 chênh 200 triệu đồng) đều là trường hợp số của Soi thỏa ràng buộc của chính BCTC.

Bài học: lỗi "đọc đúng số nhưng lấy nhầm dòng"

Lần đối chiếu đầu tìm ra một lỗi thật của Soi. BCTC quý 1/2026 của VIC không in mã cho hai dòng "LNST của cổ đông công ty mẹ" và "của cổ đông không kiểm soát". Thẻ không tìm thấy dòng công ty mẹ nên lấy dòng LNST tổng. Kết quả thẻ hiện LNST công ty mẹ 5.611 tỷ, **tăng khoảng 150%**, trong khi số đúng là 7.276 tỷ, **tăng 4,3%**. Mọi ô đều được đọc đúng, nên bộ kiểm chứng không bắt được lỗi này.

Cách sửa: gán mã 61/62 theo tên dòng khi BCTC không in mã. Nhờ đó ràng buộc $61 + 62 = 60$ kiểm được hai dòng này. Rút ra: ràng buộc kế toán bắt được lỗi *đọc sai số*, nhưng cần thêm đối chiếu nguồn ngoài để bắt lỗi *lấy nhầm dòng*. Vì vậy đối chiếu nguồn ngoài đã trở thành bước cố định sau mỗi mùa BCTC.

5.8 Tốc độ và các thước đo khác

(Dự kiến, chưa thực hiện.)

- Time-to-Insight: từ lúc BCTC xuất hiện tới lúc thẻ được công bố, p50/p95, đo trong mùa quý 3/2026.
- Độ chính xác theo ô trên bộ dữ liệu vàng (50–100 BCTC duyệt tay).
- So sánh Number F1 với baseline của khóa trước trên bộ vnpdf.

Chương 6

Kết luận và hướng phát triển

6.1 Kết luận

Đến giữa tháng 10/2026, Soi đã có đủ chuỗi xử lý: thu thập BCTC, đọc bằng mô hình thị giác, kiểm chứng bằng ràng buộc kế toán, tự định vị và sửa ô đọc sai, tính thẻ KQKD có cờ cảnh báo, và giao diện web. Trên VN30, 119/120 BCTC (quý và bán niên) đạt kiểm chứng hoặc được duyệt tay, 93% số ô được ràng buộc kế toán xác nhận, với chi phí đọc trung bình khoảng 0,12 USD mỗi BCTC (khoảng 3–3,5 USD cho cả nhóm VN30 mỗi mùa BCTC quý). Đối chiếu với nguồn ngoài cho thấy số liệu khớp ở 208/211 ô, và cả 3 ô lệch đều có lời giải thích từ chính BCTC.

Điểm khác biệt của hệ thống không nằm ở mô hình ngôn ngữ, vì ai cũng dùng được mô hình như nhau. Điểm khác biệt là **lớp kiểm chứng**: mỗi con số đều có nguồn, đều đã qua kiểm tra, và có lịch sử sửa lỗi tích lũy qua từng mùa. Các giai đoạn tiếp theo sẽ đặt agent phân tích lên trên lớp số liệu này.

6.2 Hướng phát triển

Các mục dưới đây đã có trong kế hoạch nhưng chưa thực hiện. Mỗi mục sẽ được viết đầy đủ khi hoàn thành.

6.2.1 Chạy thật mùa BCTC quý 3/2026 cho VN30

(Dự kiến, chưa thực hiện.)

6.2.2 Chỉ số tài chính: biên lợi nhuận gộp, ROE, tăng trưởng lũy kế

(Dự kiến, chưa thực hiện.)

6.2.3 Agent báo cáo so sánh (lập kế hoạch, gọi công cụ, kiểm tra số khi viết)

(Dự kiến, chưa thực hiện.)

6.2.4 Bộ kiểm tra số và từ chỉ hướng trong văn bản sinh ra

(Dự kiến, chưa thực hiện.)

6.2.5 Bộ dữ liệu vàng và benchmark vnpdf

(Dự kiến, chưa thực hiện.)

6.2.6 Phép thử so với trợ lý AI đa năng

(Dự kiến, chưa thực hiện.)

6.2.7 Mở rộng lên VN100

(Dự kiến, chưa thực hiện.)

6.2.8 Tìm nguyên nhân biến động trong thuyết minh và công văn giải trình

(Dự kiến, chưa thực hiện.)

6.2.9 Sàng lọc doanh nghiệp tăng trưởng và kiểm định lịch sử (backtest)

(Dự kiến, chưa thực hiện.)

6.2.10 Radar sự kiện công bố thông tin và bản tin sáng theo danh mục

(Dự kiến, chưa thực hiện.)

6.2.11 Kênh phân phối: Facebook, Zalo, MCP

(Dự kiến, chưa thực hiện.)

6.2.12 Triển khai lên máy chủ và số liệu người dùng thật

(Dự kiến, chưa thực hiện.)

Tài liệu tham khảo

[1] Bui Nguyen Khai. Stock Report Agent with Confidence-Gated Hybrid OCR, báo cáo IT3940E Project III. Mã nguồn: `https://github.com/buinguyenkhai/stock-report-agent-20251` (giấy phép MIT), 2026.

[2] Bộ Tài chính. Thông tư 200/2014/TT-BTC hướng dẫn chế độ kế toán doanh nghiệp, 2014.

[3] Bộ Tài chính. Thông tư 334/2016/TT-BTC về chế độ kế toán áp dụng đối với công ty chứng khoán, 2016.

[4] Bộ Tài chính. Thông tư 96/2020/TT-BTC hướng dẫn công bố thông tin trên thị trường chứng khoán, 2020.

[5] Bộ Tài chính. Thông tư 99/2025/TT-BTC hướng dẫn chế độ kế toán doanh nghiệp, hiệu lực từ 1/1/2026, 2025.

[6] Ton de Waal, Jeroen Pannekoek, and Sander Scholtus. *Handbook of Statistical Data Editing and Imputation*. Wiley, 2011.

[7] Ivan P. Fellegi and David Holt. A Systematic Approach to Automatic Edit and Imputation. *Journal of the American Statistical Association*, 71(353):17–35, 1976.

[8] Octavian M. Machidon and Alina L. Machidon. Comparing OCR Pipelines for Folkloristic Text Digitization. arXiv:2507.19092, 2025.

[9] Ngân hàng Nhà nước Việt Nam. Thông tư 49/2014/TT-NHNN về chế độ báo cáo tài chính đối với các tổ chức tín dụng, 2014.

[10] OpenAI. Images and vision: image input detail levels and sizing. `https://developers.openai.com/api/docs/guides/images-vision`, truy cập 14/10/2026, 2026.

[11] Quốc hội. Luật Trí tuệ nhân tạo số 134/2025/QH15, hiệu lực từ 1/3/2026, 2025.

[12] Vietstock. Thư viện tài liệu báo cáo tài chính doanh nghiệp. `https://finance.vietstock.vn`, 2026.

[13] Keren Ye, Ignacio Garcia Dorado, Michalis Raptis, Mauricio Delbracio, Irene Zhu, Peyman Milanfar, and Hossein Talebi. TextSR: Diffusion Super-Resolution with Multilingual OCR Guidance. arXiv:2505.23119, 2025.