**ĐẠI HỌC BÁCH KHOA HÀ NỘI**

TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG




**IT3940E - Project III**

---

# Soi: Đọc, kiểm chứng và tự sửa số liệu báo cáo tài chính Việt Nam

Đề tài: Ứng dụng Agentic AI trong Chứng khoán: Stock Report Agent

(Báo cáo kỹ thuật sơ bộ)

---

**Giảng viên hướng dẫn:**

PGS. TS. Cao Tuấn Dũng

**Sinh viên thực hiện:**

Hoàng Văn Nhân - 20235542

**Hà Nội - Việt Nam**

2026

# Mục lục

**Danh mục thuật ngữ và viết tắt** **i**

**1 Giới thiệu** **1**

1.1 Đặt vấn đề . . . . . 1

1.2 Mục tiêu nghiên cứu . . . . . 2

1.3 Phạm vi và đóng góp . . . . . 2

1.3.1 Phạm vi . . . . . 2

1.3.2 Đóng góp . . . . . 2

1.4 Cấu trúc báo cáo . . . . . 3

**2 Cơ sở lý thuyết và công nghệ** **4**

2.1 Cấu trúc báo cáo tài chính Việt Nam . . . . . 4

2.2 Nhiều mẫu biểu cùng tồn tại . . . . . 5

2.3 Ràng buộc kế toán . . . . . 6

2.4 Làm sạch số liệu bằng ràng buộc: phương pháp Fellegi–Holt . . . . . 7

2.5 Mô hình ngôn ngữ đọc ảnh . . . . . 8

2.6 Công nghệ sử dụng . . . . . 8

**3 Các sản phẩm và nghiên cứu liên quan** **9**

3.1 Các phương pháp trích xuất số từ BCTC . . . . . 9

3.1.1 Dùng lớp chữ có sẵn trong file . . . . . 9

3.1.2 Nhận dạng ký tự (OCR) rồi dựng bảng bằng luật . . . . . 10

3.1.3 OCR kết hợp mô hình ngôn ngữ đọc văn bản . . . . . 10

3.1.4 Mô hình nhận dạng cấu trúc bảng và bộ chuyển đổi tài liệu . . . . 10

3.1.5 Mô hình ngôn ngữ đọc ảnh chép thẳng . . . . . 11

3.1.6 Phép kiểm kế toán dùng được cho mọi phương pháp . . . . . 11

3.2 Nền tảng dữ liệu tài chính trong nước . . . 12
3.3 Sản phẩm "AI chứng khoán" . . . 12
3.4 Sản phẩm quốc tế . . . 12
3.5 Đánh giá khoảng trống . . . 12

**4 Phân tích, thiết kế và cài đặt 14**
4.1 Phân tích yêu cầu . . . 14
4.1.1 Tác nhân . . . 14
4.1.2 Biểu đồ use case . . . 15
4.1.3 Đặc tả các use case chính . . . 16
4.1.4 Yêu cầu chức năng . . . 17
4.1.5 Yêu cầu phi chức năng . . . 17
4.2 Kiến trúc tổng thể . . . 18
4.2.1 Nguyên tắc thiết kế . . . 18
4.2.2 Các thành phần . . . 19
4.2.3 Phân rã module . . . 19
4.2.4 Triển khai . . . 20
4.2.5 Vòng đời một tài liệu . . . 21
4.2.6 Luồng xử lý một BCTC mới . . . 22
4.3 Thiết kế cơ sở dữ liệu . . . 23
4.4 Thu thập tài liệu . . . 25
4.4.1 Lấy danh sách và nhận dạng tiêu đề . . . 25
4.4.2 Nguồn thứ hai: trang công bố thông tin của HOSE . . . 26
4.4.3 Lưu trữ và phiên bản . . . 26
4.5 Đọc và kiểm chứng BCTC . . . 27
4.5.1 Quy trình . . . 27
4.5.2 Mô hình chỉ chép, code mới hiểu số . . . 27
4.5.3 Giả thuyết rẻ trước khi gọi lại mô hình . . . 28
4.5.4 Thang leo thang khi còn lệch . . . 28
4.5.5 Duyệt tay . . . 29
4.5.6 Bằng chứng cho từng ô . . . 30
4.5.7 Kiểm đủ dòng, không chỉ kiểm phép cộng . . . 32
4.6 Công nghệ lõi: tự định vị và tự sửa ô đọc sai . . . 32

4.6.1 Ý tưởng . . . 32
4.6.2 Thuật toán định vị . . . 33
4.6.3 Xác nhận bằng đọc lại . . . 34
4.6.4 Chuẩn bị ảnh cho bước đọc lại . . . 34
4.6.5 Mở rộng sang ràng buộc giữa các BCTC . . . 35
4.7 Quản lý token và chi phí . . . 35
4.7.1 Giảm token vào . . . 35
4.7.2 Giới hạn token ra . . . 36
4.7.3 Đo và giới hạn chi phí . . . 36
4.8 Thẻ KQKD và giao diện . . . 36
4.8.1 Thẻ KQKD . . . 36
4.8.2 Vì sao lợi nhuận thay đổi: agent tìm nguyên nhân . . . 38
4.8.3 Nguyên nhân từ công văn giải trình . . . 39
4.8.4 Bảng xếp hạng mùa BCTC . . . 40
4.8.5 Lịch công bố và ảnh chia sẻ . . . 41
4.8.6 Xuất file Excel . . . 42
4.8.7 Người dùng và quyền riêng tư . . . 43
4.9 Agent tạo báo cáo theo yêu cầu . . . 43
4.9.1 Luồng xử lý . . . 43
4.9.2 Bảng số và bộ kiểm tra số . . . 45
4.9.3 Câu hỏi "mã nào tốt nhất" . . . 46
4.9.4 Xu hướng nhiều quý và các tỷ lệ ROE, NIM . . . 47
4.9.5 Trang báo cáo . . . 47

**5 Kết quả thực nghiệm và đánh giá 49**
5.1 Kết quả chính: bao nhiêu số đúng mà không cần người sửa . . . 49
5.2 Đo bằng đáp án có sẵn . . . 51
5.2.1 Ý tưởng và bộ dữ liệu . . . 51
5.2.2 Kết quả theo chất lượng ảnh . . . 52
5.3 So sánh các phương pháp trích xuất trên cùng bộ đáp án . . . 53
5.4 Độ đúng theo BCTC và theo từng ô . . . 55
5.5 Kiểm đủ dòng . . . 56
5.6 Phép kiểm bắt được bao nhiêu lỗi . . . 57

5.7 Người đọc thứ hai . . . 57
5.7.1 Đọc lần hai trong quy trình xử lý BCTC mới . . . 58
5.8 Chi phí . . . 59
5.9 Định vị ô đọc sai . . . 60
5.9.1 Bộ đề và cách thử . . . 60
5.9.2 Bốn loại kết quả . . . 60
5.9.3 Phân tích các ca ngoài tầm, ca sót và đề xuất sai . . . 61
5.10 Chép lại cả báo cáo . . . 62
5.11 Chuẩn bị ảnh cho bước đọc lại . . . 62
5.12 Đối chiếu với nguồn dữ liệu công khai . . . 63
5.13 Agent tạo báo cáo: hiểu yêu cầu . . . 64
5.14 Agent tạo báo cáo: viết lời và kiểm số . . . 65
5.15 So với trợ lý AI đa năng . . . 66

**6 Kết luận và hướng phát triển 68**

6.1 Kết luận . . . 68
6.2 Hướng phát triển . . . 69
6.2.1 Đo độ đúng trên cả mùa BCTC quý 3/2026 . . . 69
6.2.2 Đo thời gian từ lúc công bố tới lúc có thẻ trong mùa quý 3/2026 . 69
6.2.3 Đo agent tìm nguyên nhân trên cả mùa quý 3/2026, lấy công văn giải trình làm đáp án . . . 69
6.2.4 Chỉ số tài chính trên thẻ KQKD: biên lợi nhuận gộp, ROE, NIM . 69
6.2.5 Mở rộng lên VN100 . . . 69
6.2.6 Thuyết minh làm nguồn ràng buộc thứ hai cho dòng không có phép cộng (lãi trên cổ phiếu, chi phí lãi vay, mục ngoài bảng) . . . 70
6.2.7 Xác suất đúng cho từng ô và bước kiểm chứng tự chọn công cụ theo lợi ích trên chi phí . . . 70
6.2.8 Mở rộng bộ đáp án (thêm công ty chứng khoán, bản scan thật có con dấu) . . . 70
6.2.9 Sàng lọc doanh nghiệp tăng trưởng và kiểm định lịch sử (backtest) 70
6.2.10 Radar sự kiện công bố thông tin và bản tin sáng theo danh mục . . 70
6.2.11 Kênh phân phối: Facebook, Zalo, MCP . . . 70
6.2.12 Số liệu người dùng thật và chạy suốt ngày đêm trên máy chủ ảo . . 70

**Tài liệu tham khảo** **71**

## Tóm tắt nội dung

Báo cáo tài chính (BCTC) là nguồn số liệu gốc của mọi phân tích cổ phiếu. Ở Việt Nam, phần lớn BCTC được công bố dưới dạng ảnh scan. Số trong đó phải được "đọc" bằng OCR hoặc mô hình thị giác, và mọi công cụ đọc đều có lúc nhầm chữ số. Một chữ số sai trên dòng lợi nhuận đủ làm sai hẳn một nhận định đầu tư.

Báo cáo này trình bày **Soi**, hệ thống đọc BCTC ngay khi doanh nghiệp công bố và tự kiểm chứng từng con số bằng các ràng buộc kế toán có sẵn trong chính BCTC, ví dụ tổng tài sản bằng tổng nguồn vốn, hay lợi nhuận sau thuế bằng lợi nhuận trước thuế trừ thuế. Khi một ràng buộc bị lệch, hệ thống tự tìm ô nào bị đọc sai theo tinh thần phương pháp Fellegi–Holt trong thống kê chính thức, rồi đọc lại riêng ô đó. Số mới chỉ được nhận khi lần đọc lại ra đúng con số mà ràng buộc đòi hỏi. Chỉ số liệu đã qua kiểm chứng mới được dùng để tính thẻ kết quả kinh doanh (thẻ KQKD), gắn cờ cảnh báo và xếp hạng. Mỗi con số trên giao diện đều mở được đúng trang BCTC gốc.

Trên 11 BCTC có sẵn đáp án (file xuất thẳng từ Excel, Word, có lớp chữ gốc), hệ thống đọc từ ảnh và **đúng 3.105/3.107 ô (99,94%)**; khi làm mờ ảnh giống bản scan 72 dpi vẫn đúng 98,8%. Trên 119 BCTC, chủ yếu của nhóm VN30 (quý 4/2025 đến bán niên 2026, khoảng 35.000 ô số, phần lớn là bản scan không có đáp án), **97 BCTC (81,5%) được hệ thống xử lý trọn mà không cần người**, và ước tính **khoảng 99,5% ô số đúng mà không cần người sửa**; trong đó 95,1% có phép kiểm kế toán tự động xác nhận, 3,5% có hai lần đọc độc lập của hai mô hình khác hãng trùng nhau. Người chỉ phải sửa 152 ô (0,4%), trung bình 8 ô ở mỗi BCTC cần sửa. Chi phí gọi mô hình để đọc một BCTC trung bình khoảng 0,12 USD, chưa tính chi phí phát triển. Khi đối chiếu với một nguồn dữ liệu công khai, 208/211 ô khớp; ở cả 3 ô lệch, số của Soi khớp với phép cộng trong chính BCTC.

Trên lớp số liệu đã kiểm chứng này, một **agent** nhận câu hỏi người dùng gõ bằng lời thường, thuộc năm loại: so nhiều mã cùng kỳ, một mã so với cùng kỳ, vị trí của một mã trong nhóm, mã nào tốt nhất trong các mã đang theo dõi (ví dụ "công ty nào có KQKD tốt nhất hiện nay, tại sao?") và xu hướng qua nhiều quý. Agent tự lập kế hoạch, lấy số, viết báo cáo kèm bảng và biểu đồ; mọi con số và từ tăng/giảm, cao hơn/thấp hơn trong lời văn được code kiểm lại với bảng số trước khi người đọc thấy. Trên 66 câu hỏi mẫu (có

6 câu do người dùng thử viết), agent **hiểu đúng yêu cầu ở 65 câu** với Claude Haiku 5.5 và 64 câu với gpt-5.4-mini, và viết xong đủ 58/58 báo cáo ở cả hai nhà. Trên 8 câu hỏi chung, trợ lý AI đa năng có tìm web đưa ra 4 con số sai và 30 con số của kỳ khác với kỳ được hỏi, trong khi agent không có số nào như vậy.

# Danh mục thuật ngữ và viết tắt

| Viết tắt | Nghĩa |
|---|---|
| BCTC | Báo cáo tài chính |
| BCĐKT (BS) | Bảng cân đối kế toán (Balance Sheet) |
| KQKD (IS) | Báo cáo kết quả hoạt động kinh doanh (Income Statement) |
| LCTT (CF) | Báo cáo lưu chuyển tiền tệ (Cash Flow) |
| LNTT, LNST | Lợi nhuận trước thuế, lợi nhuận sau thuế |
| TT200, TT99 | Thông tư 200/2014/TT-BTC và Thông tư 99/2025/TT-BTC: mẫu BCTC doanh nghiệp thường |
| TCTD | Tổ chức tín dụng (ngân hàng), mẫu BCTC theo TT49/2014/TT-NHNN |
| CTCK | Công ty chứng khoán, mẫu BCTC theo TT334/2016/TT-BTC |
| CBTT | Công bố thông tin |
| OCR | Nhận dạng ký tự quang học |
| VLM | Mô hình ngôn ngữ có khả năng đọc ảnh (vision-language model) |
| Ràng buộc bắt buộc (gate) | Phép kiểm tra kế toán mà BCTC phải thỏa mới được coi là đã kiểm chứng |
| Thẻ KQKD | Trang tóm tắt kết quả kinh doanh một quý của một mã, kèm cờ cảnh báo |

# Chương 1

# Giới thiệu

## 1.1 Đặt vấn đề

Mỗi mùa BCTC quý, hơn 1.600 doanh nghiệp niêm yết và đăng ký giao dịch công bố BCTC trong vài tuần. Theo quy định công bố thông tin [4], BCTC quý phải công bố trong 20 ngày sau khi hết quý; công ty mẹ lập BCTC hợp nhất được 30 ngày. Vì vậy mỗi mùa có hai đỉnh công bố, khoảng ngày 20 và ngày 30 của tháng đầu quý sau.

Nhà đầu tư cá nhân cần biết nhanh và đúng: doanh nghiệp lãi bao nhiêu, tăng hay giảm so với cùng kỳ, và mức tăng đó có "thật" không. Có thể đó chỉ là nhờ nền so sánh thấp, nhờ thu nhập bất thường, hay nhờ hoàn nhập dự phòng.

Hiện đã có nhiều sản phẩm "AI chứng khoán" như trợ lý hỏi–đáp của các công ty chứng khoán, tóm tắt tin tức, hay các trợ lý AI đa năng. Nhưng gần như không sản phẩm nào cho người dùng kiểm chứng từng con số: số lấy từ đâu, đã được kiểm tra chưa. Trong tài chính, một mô hình ngôn ngữ "đoán" sai một con số là rủi ro thật.

Bài toán cụ thể gồm ba phần:

1. **Đọc đúng số từ BCTC dạng scan.** Khoảng 52/58 file BCTC quý 2/2026 của VN30 là ảnh scan, hoặc có lớp chữ (text layer) hỏng, không dùng được.
2. **Biết khi nào số đọc ra là sai**, và sửa được mà không cần người kiểm tra từng ô.
3. **Biến số liệu thành thông tin có ích:** tăng trưởng tính đúng cách, cờ cảnh báo, xếp hạng mùa BCTC. Mọi con số phải có nguồn.

## 1.2 Mục tiêu nghiên cứu

Mục tiêu là một hệ thống đọc BCTC ngay khi công bố, tự kiểm chứng và tự sửa số đọc sai bằng ràng buộc kế toán để người ít phải duyệt tay, rồi đưa số đã kiểm chứng tới người dùng qua thẻ KQKD và agent tạo báo cáo, mỗi số đều có nguồn. Mỗi mục tiêu cụ thể ứng với một đóng góp ở mục 1.3.2.

## 1.3 Phạm vi và đóng góp

### 1.3.1 Phạm vi

- **Dữ liệu:** nhóm VN30 gồm doanh nghiệp thường, 13 ngân hàng và 2 công ty chứng khoán; các kỳ quý 4/2025, quý 1/2026, quý 2/2026 và bán niên 2026. Từ mùa quý 3/2026 hệ thống chạy thật, sau đó mở rộng lên VN100.
- **Nguyên tắc:** số do code tính, mô hình ngôn ngữ chỉ đọc ảnh và viết lời. Không có nguồn thì không nói. Kiểm chứng xong mới công bố.
- **Ranh giới pháp lý:** Soi là dịch vụ thông tin, không đưa khuyến nghị mua, bán, giá mục tiêu hay tín hiệu giao dịch; nội dung do AI tạo được gắn nhãn [11].

### 1.3.2 Đóng góp

1. **Trích xuất đủ các cột** của từng báo cáo (quý này, cùng kỳ, lũy kế, đầu năm), thay vì một giá trị cho mỗi chỉ tiêu như hệ thống mã nguồn mở Stock Report Agent [1].
2. **Bộ ràng buộc kế toán khai báo theo từng mẫu** TT200, TT99, TCTD và CTCK. Mẫu được nhận dạng từ chính nội dung BCTC, không suy ra từ năm.
3. **Bộ máy tự định vị và tự sửa ô đọc sai** dựa trên ràng buộc (mục 4.6). Hệ thống chỉ đọc lại đúng những ô bị nghi, và chỉ nhận số mới khi hai nguồn độc lập cùng chỉ một con số.
4. **Bằng chứng cho từng ô số:** khớp phép cộng trong BCTC, khớp giữa các kỳ, hay bị doanh nghiệp hoặc kiểm toán sửa giữa hai bản BCTC.
5. **Sản phẩm web chạy được:** thẻ KQKD có cờ cảnh báo, bảng xếp hạng mùa BCTC, lịch công bố, ảnh thẻ để chia sẻ.

6. **Agent tạo báo cáo có bộ kiểm tra số** (mục 4.9): lời văn do mô hình viết, nhưng từng con số, từ tăng/giảm, so sánh và thứ hạng được code đối chiếu với bảng số trước khi đến người đọc.

## 1.4 Cấu trúc báo cáo

Chương 2 trình bày kiến thức nền về BCTC, ràng buộc kế toán và công nghệ sử dụng. Chương 3 điểm lại các phương pháp trích xuất số từ BCTC và các sản phẩm liên quan. Chương 4 mô tả thiết kế và cài đặt, trong đó có công nghệ lõi tự định vị và tự sửa ô đọc sai. Chương 5 trình bày kết quả đo. Chương 6 kết luận và liệt kê việc dự kiến làm tiếp.

# Chương 2

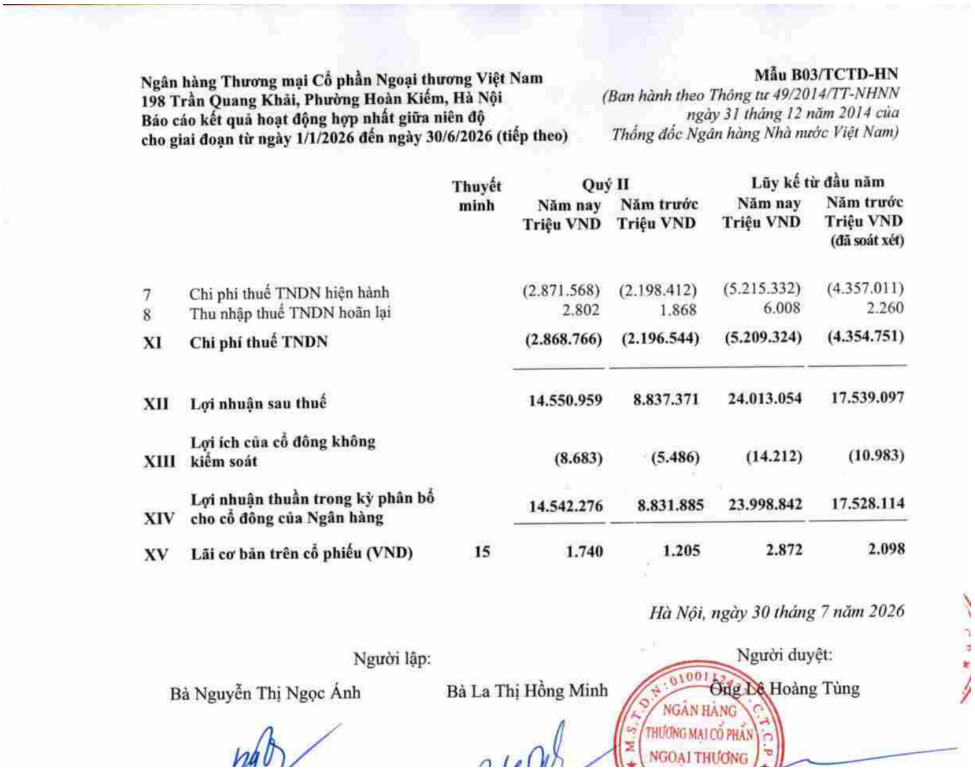
# Cơ sở lý thuyết và công nghệ

## 2.1 Cấu trúc báo cáo tài chính Việt Nam

Một bộ BCTC quý gồm ba báo cáo chính và phần thuyết minh. Mỗi dòng của các báo cáo này có một **mã số** do thông tư quy định [2, 5]. Nhờ mã số mà ta viết được ràng buộc kế toán dưới dạng phép cộng giữa các mã.

Bảng 2.1: Các báo cáo chính và các cột số liệu cần lấy

| **Báo cáo** | **Các cột** | **Ghi chú** |
|---|---|---|
| BCĐKT | cuối kỳ, đầu năm | Số dư tại một thời điểm |
| KQKD | quý này, cùng kỳ năm trước, lũy kế năm nay, lũy kế năm trước | Cột cùng kỳ giúp so sánh ngay |
| LCTT | lũy kế năm nay, lũy kế năm trước | Quý đơn lẻ = lũy kế kỳ này − lũy kế kỳ trước |



Ngân hàng Thương mại Cổ phần Ngoại thương Việt Nam
198 Trần Quang Khải, Phường Hoàn Kiếm, Hà Nội
Báo cáo kết quả hoạt động hợp nhất giữa niên độ
cho giai đoạn từ ngày 1/1/2026 đến ngày 30/6/2026 (tiếp theo)

Mẫu B03/TCTD-HN
*(Ban hành theo Thông tư 49/2014/TT-NHNN ngày 31 tháng 12 năm 2014 của Thống đốc Ngân hàng Nhà nước Việt Nam)*

| | | Thuyết minh | Quý II | | Lũy kế từ đầu năm | |
|---|---|---|---|---|---|---|
| | | | Năm nay Triệu VND | Năm trước Triệu VND | Năm nay Triệu VND | Năm trước Triệu VND (đã soát xét) |
| 7 | Chi phí thuế TNDN hiện hành | | (2.871.568) | (2.198.412) | (5.215.332) | (4.357.011) |
| 8 | Thu nhập thuế TNDN hoãn lại | | 2.802 | 1.868 | 6.008 | 2.260 |
| **XI** | **Chi phí thuế TNDN** | | **(2.868.766)** | **(2.196.544)** | **(5.209.324)** | **(4.354.751)** |
| **XII** | **Lợi nhuận sau thuế** | | **14.550.959** | **8.837.371** | **24.013.054** | **17.539.097** |
| **XIII** | **Lợi ích của cổ đông không kiểm soát** | | **(8.683)** | **(5.486)** | **(14.212)** | **(10.983)** |
| **XIV** | **Lợi nhuận thuần trong kỳ phân bổ cho cổ đông của Ngân hàng** | | **14.542.276** | **8.831.885** | **23.998.842** | **17.528.114** |
| **XV** | **Lãi cơ bản trên cổ phiếu (VND)** | **15** | **1.740** | **1.205** | **2.872** | **2.098** |

*Hà Nội, ngày 30 tháng 7 năm 2026*

Người lập: Bà Nguyễn Thị Ngọc Ánh

Bà La Thị Hồng Minh

Người duyệt: Ông Lê Hoàng Tùng

Hình 2.1: Một phần trang KQKD hợp nhất quý 2/2026 của VCB (bản scan, đơn vị triệu đồng). Bốn cột số, mỗi dòng có ký hiệu La Mã thay vì mã số. Đây là đầu vào điển hình của hệ thống.

## 2.2 Nhiều mẫu biểu cùng tồn tại

Từ năm 2026, Thông tư 99/2025 [5] thay Thông tư 200/2014 [2] cho doanh nghiệp thường và đánh lại một số mã. Ngân hàng [9] và công ty chứng khoán [3] có mẫu riêng (Bảng 2.2).

Bảng 2.2: Các mẫu BCTC hệ thống đang hỗ trợ

| Mẫu | Áp dụng | Điểm cần lưu ý |
|---|---|---|
| TT200 | DN thường, năm tài chính $\leq 2025$ | Tổng tài sản mã 270 |
| TT99 | DN thường, từ quý 1/2026 | Tổng tài sản đổi sang mã 280; doanh thu, chi phí tài chính dịch từ 21–23 sang 22–24. Khoảng 11% BCTC quý 2/2026 vẫn in mã 270 |
| TCTD | Ngân hàng | Cấu trúc khác hẳn; nhiều ngân hàng không in mã số mà chỉ có số thứ tự La Mã |
| CTCK | Công ty chứng khoán | Tài sản tài chính FVTPL, cho vay ký quỹ… |

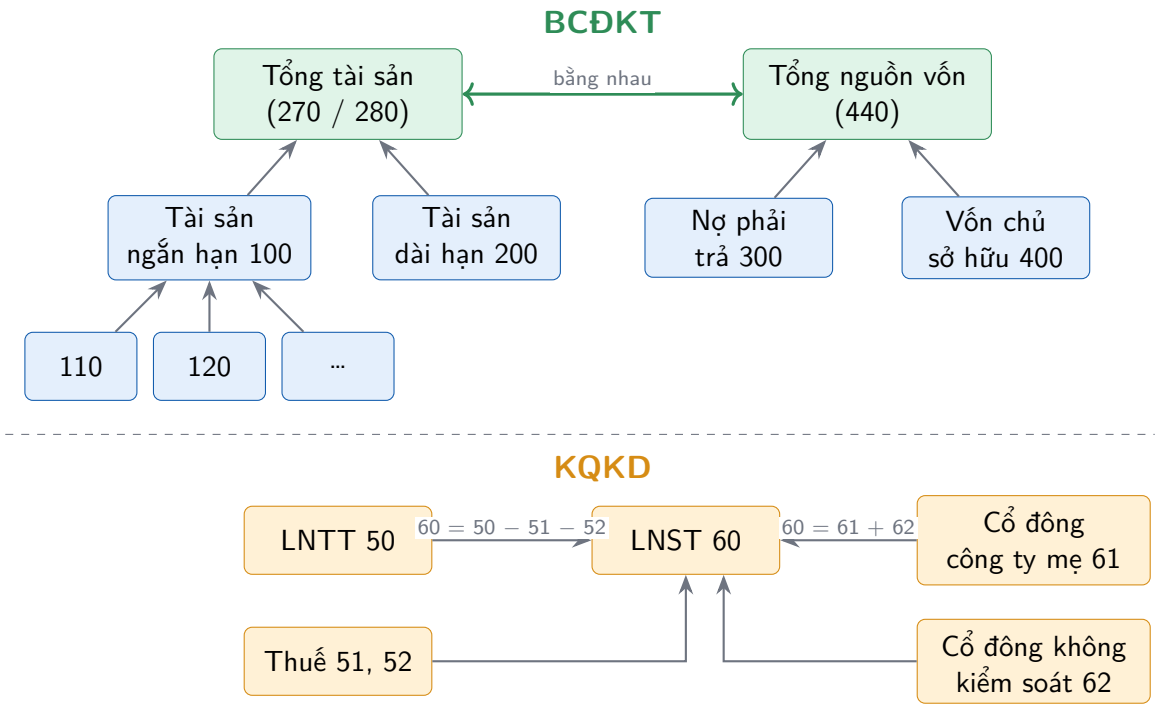
Những khó khăn thực tế khi đọc, rút ra từ việc rà khoảng 940 BCTC quý 2/2026:

- Khoảng 1/4 BCTC viết `1,234,567` thay vì `1.234.567`, nên phải suy ra dấu phân cách theo từng tài liệu.

- Đơn vị có thể là đồng, nghìn đồng hoặc triệu đồng.
- Cột thuyết minh cũng là số nhỏ, dễ nhầm với cột mã số. Cột số thứ tự và cột mã số đôi khi bị đọc đảo cho nhau.
- BCTC thật không luôn theo đúng mẫu: có file in mã 270 cho dòng tổng theo mẫu mới, có dòng không in mã, có nhiều dòng LCTT trùng mã, cùng dòng lợi nhuận chưa phân phối nhưng công ty này in mã 421a/421b, công ty khác in 420a/420b.
- Một số file scan có trang bị lộn ngược, hoặc có độ phân giải rất thấp (72 dpi). File đăng trên trang của chính công ty cũng là đúng file đó, nên không có bản nét hơn để thay.

## 2.3 Ràng buộc kế toán

Mỗi BCTC tự chứa nhiều phép cộng, đủ để kiểm tra chéo các con số trong chính nó (Hình 2.2). Sai số cho phép là $\pm 1$ đơn vị làm tròn cho mỗi số hạng.



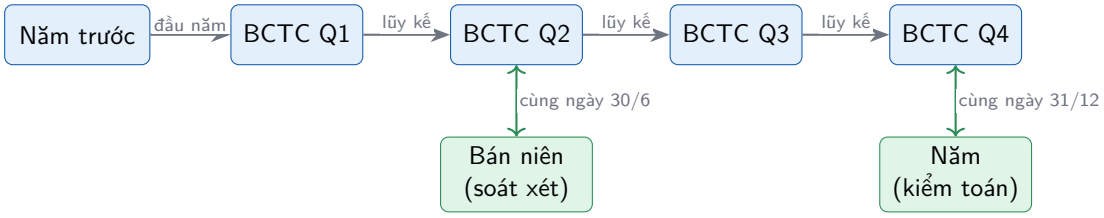

Hình 2.2: Hình minh họa một phần lưới ràng buộc của BCTC doanh nghiệp thường. Mũi tên chỉ từ số hạng tới tổng của phép cộng. Một ô số thường nằm trong nhiều phép cộng cùng lúc, nên khi đọc nhầm một ô, các phép cộng chứa nó cùng lệch một lượng như nhau.

Bảng 2.3: Số mẫu ràng buộc đã khai báo (mỗi mẫu được áp cho từng cột số liệu)

| Mẫu | Theo mã | Bắt buộc | Theo vị trí | Ví dụ |
|---|---|---|---|---|
| TT200 | 43 | 43 | LCTT | $270 = 100 + 200$, $60 = 50 - 51 - 52$ |
| TT99 | 48 | 44 | LCTT | $280 = 440$, $130 = 131 + \ldots + 139$ |
| TCTD | 17 | 16 | BCĐKT, LCTT | thu nhập lãi thuần = thu nhập lãi − chi phí lãi |
| CTCK | 23 | 20 | | theo TT334 |

Cột "theo vị trí" là phép kiểm dành cho các dòng không in mã số: dòng tổng phải bằng tổng các dòng nằm ngay trên nó, tính tới dòng tổng trước đó. Ngân hàng hiếm khi in mã cho dòng chi tiết; một số doanh nghiệp bỏ mã ở phần đầu LCTT. Một ràng buộc chỉ được đưa vào nhóm "bắt buộc" sau khi đã đo trên toàn bộ BCTC đã đọc và thấy nó khớp ở mọi BCTC, trừ những chỗ đã xác nhận là đọc sai. Các ràng buộc chi tiết của mẫu TT99 được đưa vào nhóm bắt buộc theo cách này.

Ngoài ràng buộc trong một BCTC, còn có **ràng buộc giữa các BCTC** của cùng công ty (Hình 2.3).




Hình 2.3: Hình minh họa ràng buộc giữa các kỳ: số đầu năm phải bằng số cuối năm trước; quý = lũy kế kỳ này − lũy kế kỳ trước; BCTC quý 2 và bán niên (hay quý 4 và năm) cùng ngày nên phải khớp. Khi hai bản khác nhau, đó hoặc là đọc nhầm, hoặc là doanh nghiệp, kiểm toán đã sửa số.

## 2.4 Làm sạch số liệu bằng ràng buộc: phương pháp Fellegi–Holt

Trong thống kê chính thức, số liệu điều tra thường được kiểm tra bằng các quy tắc (edit rules), ví dụ tổng các khoản chi phải bằng tổng chi. Fellegi và Holt [7] đề xuất nguyên lý: khi một bản ghi vi phạm quy tắc, hãy tìm **tập trường nhỏ nhất** cần thay đổi để mọi quy tắc cùng thỏa, thay vì sửa tùy ý từng trường. Bước này gọi là định vị lỗi (error localization) và là nền của các hệ thống làm sạch số liệu ở cơ quan thống kê [6].

BCTC có cấu trúc rất giống: các ô số liên kết với nhau bằng phép cộng. Điểm khác

là lỗi ở đây chủ yếu do *đọc ảnh* nhầm 1–2 chữ số, và ta có thể quay lại ảnh gốc để xác nhận. Mục 4.6 trình bày cách Soi tận dụng hai đặc điểm này.

## 2.5 Mô hình ngôn ngữ đọc ảnh

Các mô hình ngôn ngữ đa phương thức (VLM) nhận ảnh trang tài liệu và trả về văn bản có cấu trúc, ví dụ JSON theo schema. So với OCR truyền thống, VLM đọc được bảng nhiều cột, dòng tên bị xuống dòng và chữ tiếng Việt có dấu mà không cần bước nhận diện vùng bảng riêng. Nhược điểm là đôi khi "bịa" hoặc đọc nhầm số, và không cho điểm tin cậy cho từng ô. Vì vậy Soi chỉ dùng VLM để *định vị trang* và *chép nguyên văn*; độ tin cậy đến từ ràng buộc kế toán chứ không từ mô hình.

## 2.6 Công nghệ sử dụng

Bảng 2.4: Công nghệ sử dụng

| **Thành phần** | **Lựa chọn** |
|---|---|
| Ngôn ngữ, web | Python 3.12, FastAPI, Jinja2 (giao diện tạm; trang công khai dự kiến Next.js) |
| CSDL | PostgreSQL 16 + pgvector, migration đánh số |
| Đọc PDF, vẽ ảnh | PyMuPDF |
| Mô hình đọc ảnh | Hai nhà cung cấp (Claude và OpenAI), mô hình cỡ nhỏ, giá rẻ; một nhà lỗi thì tự chuyển sang nhà còn lại; đầu ra JSON theo schema |
| Agent tạo báo cáo | LangGraph (đồ thị trạng thái, lưu trạng thái vào PostgreSQL) |
| Xuất PDF | WeasyPrint |
| Chạy | Docker Compose: CSDL, web, bộ canh và một container chạy lệnh một lần |
| Kiểm thử | pytest, 339 bài kiểm thử; dữ liệu mẫu là tiêu đề và BCTC thật |

# Chương 3

# Các sản phẩm và nghiên cứu liên quan

## 3.1 Các phương pháp trích xuất số từ BCTC

Bài toán là lấy ra đúng từng ô số (dòng nào, cột nào, giá trị bao nhiêu) của ba báo cáo chính từ file PDF. Khó khăn nằm ở dữ liệu: phần lớn BCTC là bản scan, có file độ phân giải thấp hoặc trang bị xoay; số viết theo hai kiểu dấu phân cách hàng nghìn, số âm để trong ngoặc, dấu gạch nghĩa là không có số; tên chỉ tiêu dài và xuống dòng; bảng có bốn đến sáu cột số xen với cột mã số và cột thuyết minh. Sai một chữ ở tên chỉ tiêu ít hại; sai một chữ số, mất dấu âm hay đặt đúng số vào sai dòng mới làm hỏng số liệu. Có năm họ phương pháp chính, mỗi họ có điểm mạnh, điểm yếu riêng. Các điểm yếu nêu dưới đây là điều được dự đoán từ cách mỗi họ làm việc; mức độ thật được đo trên cùng một bộ đáp án ở mục 5.3.

### 3.1.1 Dùng lớp chữ có sẵn trong file

Khi công ty xuất BCTC thẳng từ Excel, Word hoặc phần mềm kế toán, file PDF chứa sẵn chữ và vị trí của chữ. Gom chữ thành hàng theo vị trí dọc và xếp số vào cột theo mép phải là có bảng đúng tuyệt đối, miễn phí và rất nhanh. Nhưng cách này gần như không dùng được với BCTC Việt Nam: trong 119 BCTC của đề tài chỉ 5 file có chữ gốc; nhiều file có lớp chữ do máy nhận dạng từ ảnh tạo ra, sai chính tả và tách vỡ số, nên phải đánh giá chất lượng lớp chữ chứ không chỉ xem có hay không. Soi dùng chính loại file hiếm này làm đáp án để đo độ đúng (mục 5.2).

### 3.1.2 Nhận dạng ký tự (OCR) rồi dựng bảng bằng luật

Phần mềm OCR như Tesseract, PaddleOCR hay VietOCR tìm các dòng chữ trên ảnh và nhận dạng từng dòng, kèm vị trí và điểm tin cậy; luật gom hàng, gom cột rồi dựng lại bảng. Ưu điểm: miễn phí, chạy trên máy cá nhân, kết quả lặp lại được, có điểm tin cậy cho từng từ. Nhược điểm dự đoán trên BCTC scan: dấu tiếng Việt nhỏ dễ mất khi ảnh mờ; với số thì dễ nhầm dấu chấm và dấu phẩy, mất dấu ngoặc, nhầm các chữ số có nét gần nhau ở ảnh độ phân giải thấp; luật dựng bảng dễ vỡ khi tên chỉ tiêu xuống dòng, bảng không kẻ ô hoặc trang bị xoay.

### 3.1.3 OCR kết hợp mô hình ngôn ngữ đọc văn bản

Văn bản OCR được đưa cho một mô hình ngôn ngữ để sắp thành bảng có cấu trúc. Mô hình xử lý tốt phần bố cục: ghép tên chỉ tiêu bị xuống dòng, nhận ra cột nào là quý này, cột nào là lũy kế; đọc văn bản cũng rẻ hơn đọc ảnh. Nhưng mô hình không nhìn thấy ảnh nên không sửa được chữ số mà OCR đã đọc sai, và có thể tự ý "sửa" số cho hợp lý. Hệ thống mã nguồn mở Stock Report Agent [1] là một cách hiện thực của họ này: chuyển PDF thành văn bản bằng Tesseract tiếng Việt qua một bộ chuyển đổi tài liệu, đọc lại các ô số có độ tin cậy thấp bằng một mô hình OCR thứ hai (Surya), rồi dùng mô hình ngôn ngữ tách ba báo cáo. Theo báo cáo của tác giả, trên 401 trang BCTC cách OCR lai này đạt Number F1 85,3% và đọc một BCTC mất khoảng 5 phút trên máy có GPU. Thước đo Number F1 đếm các số trùng nhau trên cả trang, không xét số nằm ở dòng nào, cột nào, nên chưa cho biết tỷ lệ ô đúng.

### 3.1.4 Mô hình nhận dạng cấu trúc bảng và bộ chuyển đổi tài liệu

Các công cụ như Docling, Marker, MinerU dùng một mô hình tìm vùng bảng và một mô hình đoán lưới hàng, cột, rồi điền chữ do OCR đọc vào từng ô. Ưu điểm là giữ được cấu trúc bảng tổng quát và chạy trên máy cá nhân. Nhược điểm dự đoán: dữ liệu huấn luyện bảng công bố chủ yếu không phải BCTC Việt Nam (ví dụ bộ PubTables-1M của Table Transformer lấy từ bài báo khoa học); với bảng không kẻ ô của ngân hàng, cột số có thể bị gộp hoặc tách sai, cột mã số và thuyết minh lẫn vào cột số; chất lượng chữ Việt phụ thuộc phần OCR bên dưới; cần GPU để chạy nhanh.

### 3.1.5 Mô hình ngôn ngữ đọc ảnh chép thẳng

Mô hình đa phương thức nhận ảnh trang và chép từng ô thành dữ liệu có cấu trúc trong một bước. Cách này xử lý được bảng nhiều cột, tên xuống dòng và chữ có dấu bằng một cách chung cho mọi mẫu biểu, không cần GPU tại chỗ. Nhược điểm: không có điểm tin cậy cho từng ô, đôi khi chép lệch dòng hoặc đọc nhầm số, kết quả giữa các lần chạy không giống hệt nhau, và tốn tiền theo số ảnh gửi đi. Soi theo cách này nhưng giới hạn vai trò của mô hình: mô hình chỉ chép nguyên văn; code hiểu số, đơn vị, dấu; độ tin cậy đến từ ràng buộc kế toán và từ việc đọc lại đúng các ô bị nghi.

### 3.1.6 Phép kiểm kế toán dùng được cho mọi phương pháp

Các họ trên khác nhau ở cách đọc, nhưng đầu ra cuối cùng đều là một bảng số, nên phép kiểm kế toán (tổng các khoản bằng dòng tổng, tài sản bằng nguồn vốn, số đầu năm khớp BCTC kỳ trước) áp được cho tất cả. Vì vậy so sánh gồm hai câu hỏi: mỗi cách đọc đúng bao nhiêu ô, và phép kiểm phát hiện được bao nhiêu phần lỗi của từng cách. Bảng 3.1 tóm tắt các họ phương pháp.

Bảng 3.1: Các họ phương pháp trích xuất số từ BCTC (điểm yếu là dự đoán; số đo ở Bảng 5.3)

| **Phương pháp** | **Điểm mạnh** | **Điểm yếu với BCTC scan** | **Chi phí, phần cứng** |
|---|---|---|---|
| Lớp chữ có sẵn | Đúng tuyệt đối khi là chữ gốc; rất nhanh | Chỉ 5/119 BCTC có chữ gốc; lớp chữ do máy nhận dạng có thể sai | Miễn phí, CPU |
| OCR + luật dựng bảng | Miễn phí, lặp lại được, có điểm tin cậy | Mất dấu, nhầm chấm/phẩy, mất ngoặc âm; vỡ bảng khi tên xuống dòng, bảng không kẻ, trang xoay | Miễn phí, CPU |
| OCR + mô hình đọc văn bản | Sửa được bố cục; rẻ hơn đọc ảnh | Không sửa được chữ số OCR đọc sai; có thể tự ý sửa số | Rẻ; OCR nhanh hơn nếu có GPU |
| Mô hình cấu trúc bảng, bộ chuyển đổi tài liệu | Giữ cấu trúc bảng tổng quát; chạy cục bộ | Gộp/tách cột sai ở bảng không kẻ; chữ Việt phụ thuộc OCR | Miễn phí; nên có GPU |
| Mô hình đọc ảnh chép thẳng (Soi) | Một cách cho mọi mẫu biểu; bảng nhiều cột, chữ có dấu | Không có điểm tin cậy; đôi khi chép lệch dòng; tốn tiền theo ảnh | Trả theo lượt gọi |

Ngoài cách đọc số, Soi khác hệ thống Stock Report Agent nêu ở trên (đọc khi người

dùng hỏi) ở chỗ đọc sẵn khi BCTC được công bố, lấy đủ các cột (quý này, cùng kỳ, lũy kế, đầu năm) thay vì một giá trị mỗi chỉ tiêu, hỗ trợ bốn mẫu biểu (TT200, TT99, ngân hàng, công ty chứng khoán) và kiểm từng ô bằng ràng buộc kế toán.

## 3.2 Nền tảng dữ liệu tài chính trong nước

Các cổng thông tin như Vietstock, CafeF cung cấp BCTC dạng PDF, số liệu tổng hợp, biểu đồ và tin tức. Số liệu tổng hợp thường chỉ có số riêng từng quý, không kèm cột cùng kỳ, lũy kế hay nguồn đến từng trang. Ngày trong kho tài liệu là ngày đăng lại, không phải giờ công bố chính thức.

## 3.3 Sản phẩm "AI chứng khoán"

Nhiều nền tảng đầu tư và công ty chứng khoán đã có trợ lý AI hỏi–đáp, tóm tắt tin tức hay tóm tắt BCTC. Theo thông tin công khai, các sản phẩm này chủ yếu *bị động* (chờ người dùng hỏi), hiếm khi trích nguồn đến từng ô số, và nhiều trợ lý gắn với tài khoản của một công ty chứng khoán. Trợ lý AI đa năng tìm được web và đọc được PDF, nhưng không có kho số liệu đã kiểm chứng để đối chiếu.

## 3.4 Sản phẩm quốc tế

Ở thị trường quốc tế, Daloopa trích số liệu từ BCTC, mỗi số có link về nguồn; Fiscal.ai và AlphaSense trích dẫn đến từng câu. Đây là hình mẫu gần nhất của "lớp số liệu kiểm chứng được" mà Soi hướng tới cho thị trường Việt Nam.

## 3.5 Đánh giá khoảng trống

- Chưa có hệ thống nào cho BCTC Việt Nam dạng scan *tự kiểm chứng* số đọc được bằng ràng buộc kế toán và tự sửa lỗi đọc.
- Chưa có nguồn miễn phí cung cấp số liệu kèm nguồn đến từng trang, đủ cột so sánh, ghi đúng thời điểm công bố.

- Các sản phẩm hiện có ít cảnh báo về chất lượng lợi nhuận: nền thấp, thu nhập bất thường, lãi nhưng dòng tiền âm.

# Chương 4

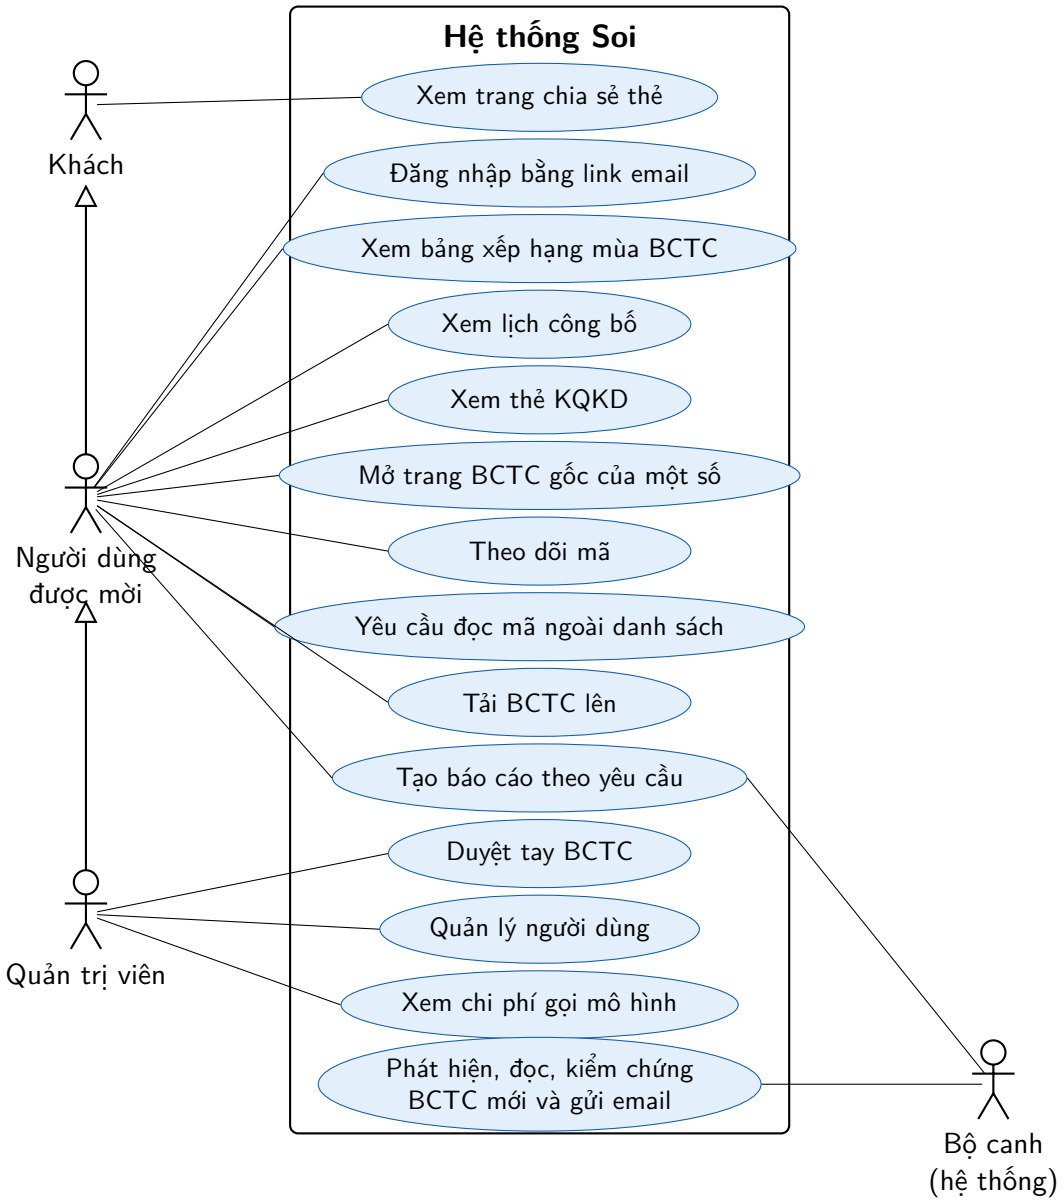
# Phân tích, thiết kế và cài đặt

## 4.1 Phân tích yêu cầu

### 4.1.1 Tác nhân

- **Khách:** người chưa đăng nhập, chỉ xem được trang chia sẻ thẻ KQKD đã kiểm chứng (ví dụ khi bấm link trên Facebook, Zalo).
- **Người dùng được mời:** nhà đầu tư cá nhân đã được mời trong giai đoạn thử nghiệm, đăng nhập bằng link gửi qua email.
- **Quản trị viên:** có mọi quyền của người dùng, thêm quyền duyệt tay BCTC và quản lý người dùng.
- **Bộ canh (hệ thống):** tác nhân chạy theo lịch, tự phát hiện BCTC mới, gọi quy trình đọc và gửi email.

### 4.1.2 Biểu đồ use case




Hình 4.1: Biểu đồ use case tổng quát. Đường nối là quan hệ giữa tác nhân và use case; mũi tên tam giác rỗng là quan hệ khái quát hóa: người dùng được mời làm được mọi việc của khách, quản trị viên làm được mọi việc của người dùng.

### 4.1.3 Đặc tả các use case chính

Bảng 4.1: Đặc tả use case "Xem thẻ KQKD"

| | |
|---|---|
| **Tác nhân** | Người dùng được mời |
| **Tiền điều kiện** | Đã đăng nhập |
| **Luồng chính** | 1. Người dùng chọn mã (từ bảng xếp hạng, lịch công bố hoặc đường dẫn riêng của mã) và kỳ.<br>2. Hệ thống chọn BCTC quý dùng cho thẻ: ưu tiên hợp nhất, bản đăng sau cùng.<br>3. Hệ thống tính thẻ từ số đã kiểm chứng: các chỉ tiêu, tăng trưởng, cờ cảnh báo, nguồn của từng số.<br>4. Người dùng bấm vào một số để mở đúng trang BCTC gốc. |
| **Luồng thay thế** | 2a. Chưa có BCTC của kỳ đó: báo chưa có.<br>3a. BCTC chưa đạt kiểm chứng: hiện trạng thái, không hiện số.<br>3b. Mẫu BCTC chưa hỗ trợ (bảo hiểm): báo thẻ chưa hỗ trợ. |
| **Hậu điều kiện** | Không thay đổi dữ liệu |

Bảng 4.2: Đặc tả use case "Yêu cầu đọc mã ngoài danh sách"

| | |
|---|---|
| **Tác nhân** | Người dùng được mời; bộ canh (xử lý hàng chờ) |
| **Tiền điều kiện** | Đã đăng nhập |
| **Luồng chính** | 1. Người dùng nhập mã và kỳ.<br>2. Hệ thống kiểm tra kho; chưa có thì kiểm tra hạn mức trong ngày của người dùng.<br>3. Hệ thống ghi yêu cầu vào hàng chờ.<br>4. Ở lượt kế tiếp (tối đa 15 phút), bộ canh tìm BCTC trên Vietstock, tải về, đọc và kiểm chứng.<br>5. Hệ thống gửi email báo kết quả; BCTC mới vào kho dùng chung. |
| **Luồng thay thế** | 2a. Kho đã có BCTC đã đọc: trả kết quả ngay, không tính vào hạn mức.<br>2b. Hết hạn mức trong ngày: từ chối và báo cho người dùng.<br>4a. Chi phí đọc theo yêu cầu đã chạm trần tháng: yêu cầu nằm chờ sang tháng sau.<br>4b. Không tìm thấy mã hoặc BCTC: từ chối kèm lý do. |
| **Hậu điều kiện** | Yêu cầu ở trạng thái đã xong hoặc bị từ chối |

Bảng 4.3: Đặc tả use case “Tạo báo cáo theo yêu cầu”

| | |
|---|---|
| **Tác nhân** | Người dùng được mời; bộ canh (chạy tiếp báo cáo đang chờ) |
| **Tiền điều kiện** | Đã đăng nhập, còn hạn mức báo cáo trong ngày, chưa chạm trần chi phí tháng |
| **Luồng chính** | 1. Người dùng gõ câu hỏi bằng lời thường, thuộc một trong năm loại (mục 4.9).<br>2. Agent hiểu câu hỏi thành kế hoạch (loại câu hỏi, mã, kỳ); code kiểm kế hoạch.<br>3. Code lấy số đã kiểm chứng, dựng bảng số và biểu đồ.<br>4. Mô hình viết lời; code kiểm từng câu, câu sai được viết lại.<br>5. Hệ thống hiện trang báo cáo; người dùng tải PDF nếu cần. |
| **Luồng thay thế** | 2a. Không có mã (trừ câu hỏi mã nào tốt nhất) hoặc mã không tồn tại: hỏi lại người dùng, kèm ví dụ của năm loại câu hỏi.<br>3a. Kho thiếu BCTC: hỏi người dùng có cho đọc thêm không (báo chi phí, hạn mức); đồng ý thì chờ bộ canh đọc xong rồi chạy tiếp và gửi email.<br>4a. Câu vẫn sai sau 2 lần viết lại: bỏ câu đó; không còn câu nào thì báo lỗi.<br>5a. Cùng câu hỏi, số liệu chưa đổi: dùng lại báo cáo cũ, không tốn tiền. |
| **Hậu điều kiện** | Báo cáo có trạng thái xong hoặc lỗi kèm lý do; chi phí ghi vào trần tháng |

Use case “Duyệt tay BCTC” được tả bằng biểu đồ hoạt động ở mục 4.5.5.

### 4.1.4 Yêu cầu chức năng

Bảng 4.4: Các yêu cầu chức năng chính và trạng thái

| Mã | Yêu cầu | Trạng thái |
|---|---|---|
| F1 | Tự phát hiện BCTC mới của các mã theo dõi, tải về, nhận dạng loại và kỳ | Đã làm |
| F2 | Đọc BCTC (kể cả bản scan), lấy đủ các cột, kiểm chứng bằng ràng buộc kế toán | Đã làm |
| F3 | Tự định vị và sửa ô đọc sai; chuyển duyệt tay khi không tự sửa được | Đã làm |
| F4 | Thẻ KQKD có cờ cảnh báo, mỗi số có nguồn tới trang BCTC | Đã làm |
| F5 | Bảng xếp hạng mùa BCTC, lịch công bố, ảnh thẻ để chia sẻ | Đã làm |
| F6 | Theo dõi mã và nhận email khi có BCTC mới | Đã làm |
| F7 | Yêu cầu đọc mã ngoài danh sách, tải BCTC lên (có hạn mức) | Đã làm |
| F8 | Quản trị: duyệt tay, sửa ô, mời và phân quyền người dùng, xem chi phí gọi mô hình, đọc góp ý | Đã làm |
| F9 | Chỉ số tài chính (biên lợi nhuận, ROE…) | Một phần |
| F10 | Agent tạo báo cáo theo câu hỏi của người dùng, kiểm từng con số trong lời văn | Đã làm |

### 4.1.5 Yêu cầu phi chức năng

- **Đúng số:** chỉ công bố số đã qua ràng buộc bắt buộc hoặc đã được duyệt tay.

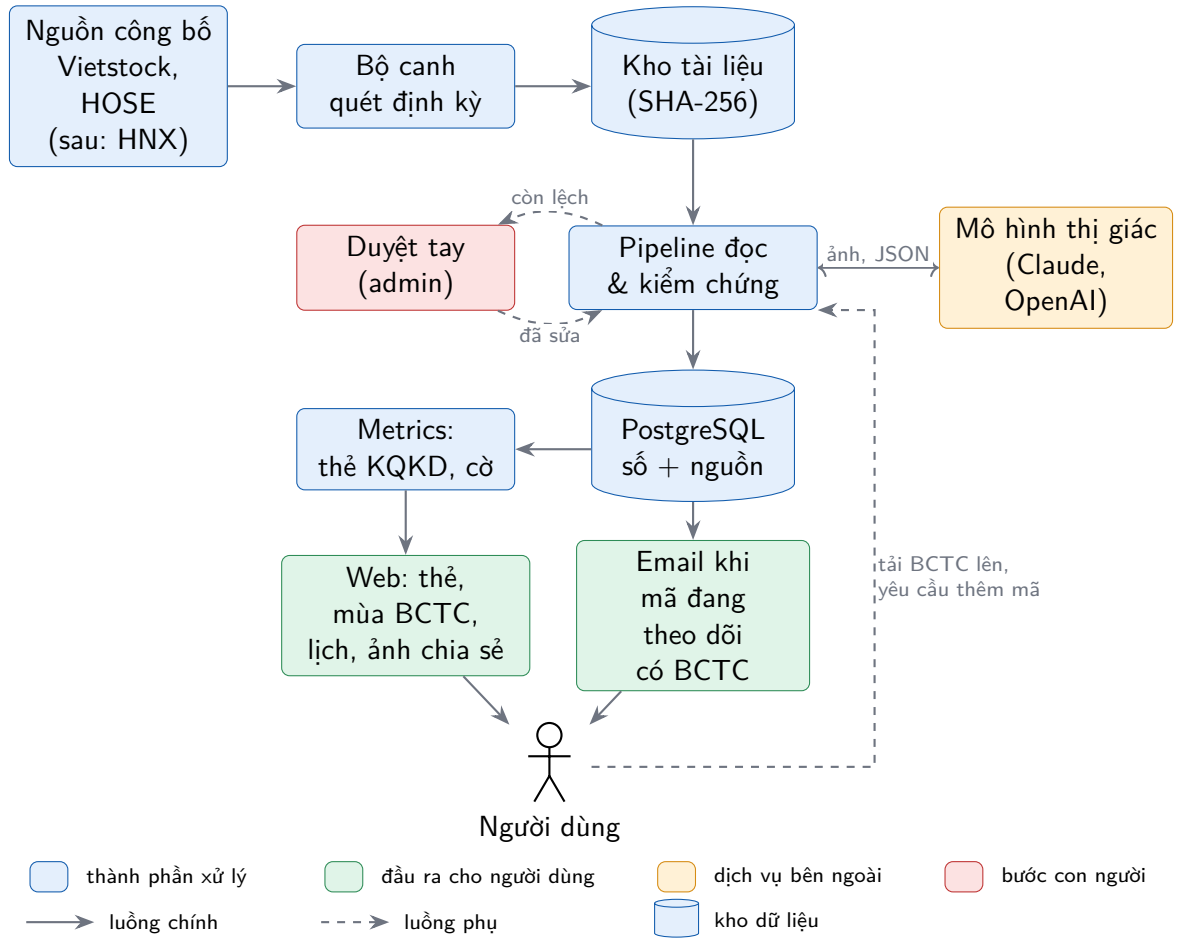
- **Truy vết:** mỗi số mở được trang BCTC gốc; mỗi lần sửa được ghi lại người sửa và lý do.
- **Chi phí:** trung bình khoảng 0,12 USD để đọc một BCTC; có trần chi phí theo ngày và theo tháng (mục 4.7).
- **Độ trễ:** có thể trong vài phút sau khi BCTC xuất hiện trên nguồn.
- **Riêng tư:** tài liệu người dùng tải lên chỉ người đó thấy.
- **Pháp lý:** không đưa khuyến nghị đầu tư; nội dung do AI tạo được gắn nhãn.

## 4.2 Kiến trúc tổng thể

### 4.2.1 Nguyên tắc thiết kế

1. **Xử lý trước (precompute-first):** tài liệu được xử lý một lần khi công bố, không đợi người dùng hỏi.
2. **Số do code tính, chữ do mô hình viết:** mô hình chỉ định vị trang và chép nguyên văn từng ô. Mọi việc phân tích số, quy đổi đơn vị và kiểm tra đều do code làm.
3. **Không có nguồn thì không nói:** mỗi số mang theo tài liệu, trang và dòng gốc.
4. **Kiểm chứng xong mới công bố:** ràng buộc kế toán là cổng chất lượng.
5. **Quy tắc khai báo theo mẫu và phiên bản**, không viết cứng trong code.
6. **Có phiên bản, không ghi đè:** BCTC công bố lại tạo phiên bản mới; mỗi lần trích xuất ghi phiên bản pipeline.
7. **Không khóa vào một nhà cung cấp mô hình:** mọi lần gọi mô hình đi qua một lớp chung. Hiện dùng hai nhà cung cấp (Claude và OpenAI); một nhà lỗi hoặc hết tiền thì hệ thống tự chuyển sang nhà còn lại.

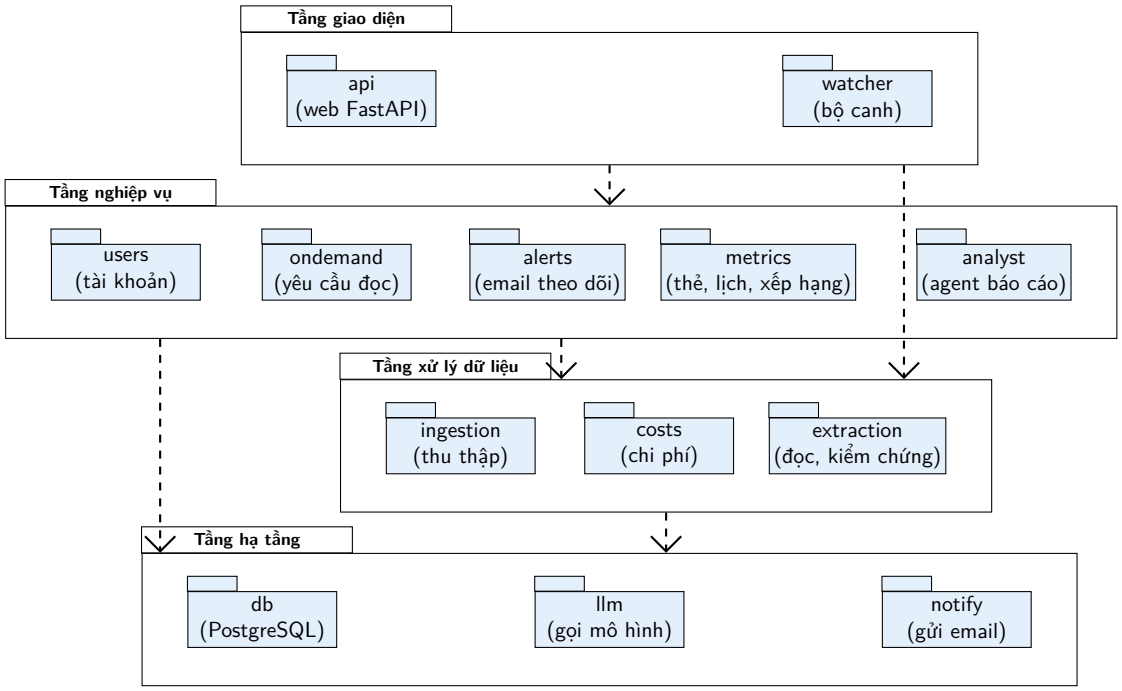
### 4.2.2 Các thành phần




Hình 4.2: Sơ đồ kiến trúc tổng quan (sơ đồ khối) của Soi.

### 4.2.3 Phân rã module

Mã nguồn chia thành các gói Python theo bốn tầng (Hình 4.3). Gói ở tầng trên chỉ dùng gói ở tầng dưới, không có chiều ngược lại; điều này đã được kiểm trên mã nguồn.

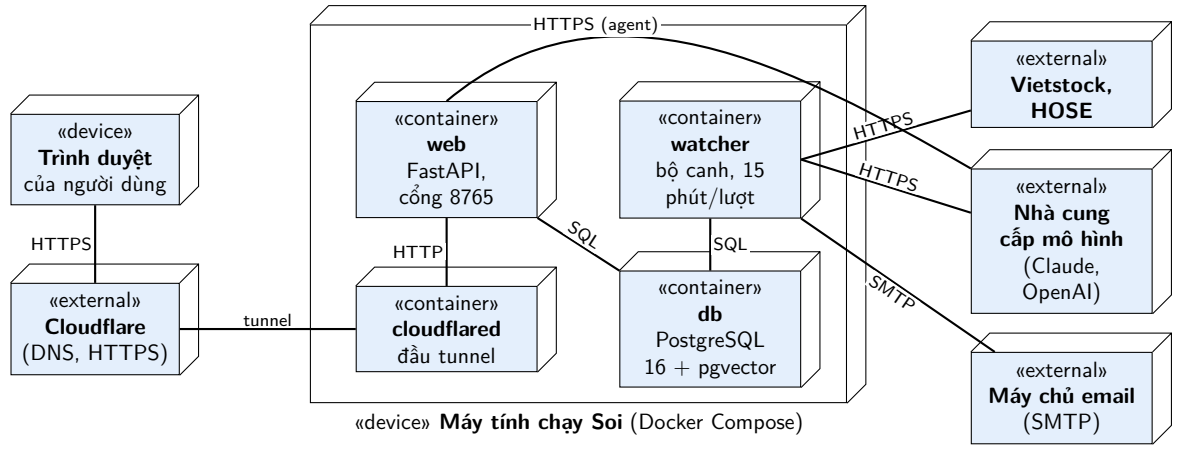



Hình 4.3: Biểu đồ gói theo tầng. Mũi tên đứt nét đầu hở là quan hệ phụ thuộc giữa các tầng.

### 4.2.4 Triển khai

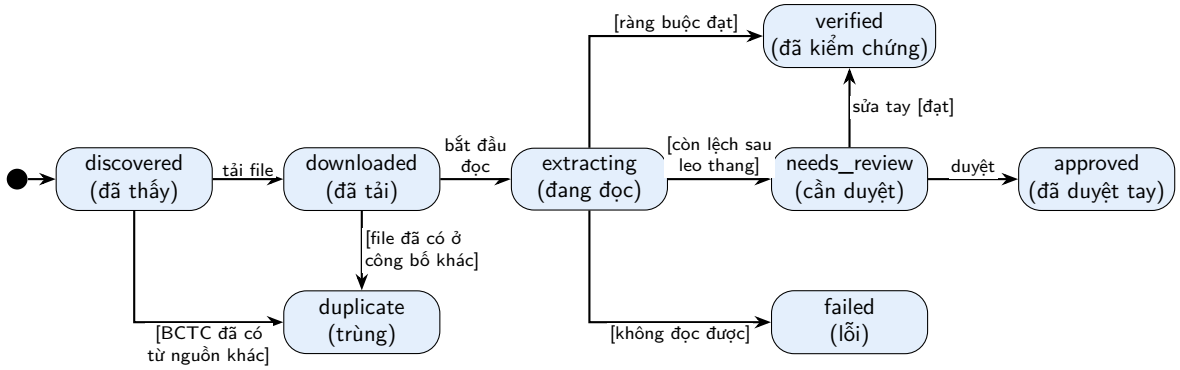
Từ 27/10/2026 hệ thống chạy công khai tại `https://soi.rediov.com`, trên một máy tính cá nhân bằng Docker Compose (Hình 4.4). Web ra Internet qua Cloudflare Tunnel: một container trên máy chủ động kết nối ra mạng của Cloudflare, nên không phải mở cổng nào trên bộ định tuyến và không lộ địa chỉ IP của máy; Cloudflare lo HTTPS. Chỉ trang web được đưa ra ngoài, cơ sở dữ liệu chỉ mở cho chính máy đó. Máy tắt ban đêm (khoảng 23h đến 7h); BCTC hầu như được công bố trong giờ làm việc, và khi máy bật lại bộ canh tự quét bù nên BCTC đăng ban đêm chỉ được đọc muộn hơn chứ không bị bỏ sót. Khi cần chạy suốt ngày đêm, cả cụm container chuyển nguyên lên một máy chủ ảo (VPS).

Bộ canh ghi nhịp tim ở đầu và cuối mỗi lượt; khi khởi động lại sau một thời gian dừng, nó email cho quản trị viên biết đã dừng bao lâu. Khi cả máy dừng thì hệ thống không tự báo được, nên web có một trang sức khỏe trả lỗi khi bộ canh im quá hai giờ hoặc cơ sở dữ liệu hỏng; một dịch vụ theo dõi bên ngoài gọi trang này 5 phút một lần và email cho quản trị viên khi có lỗi.



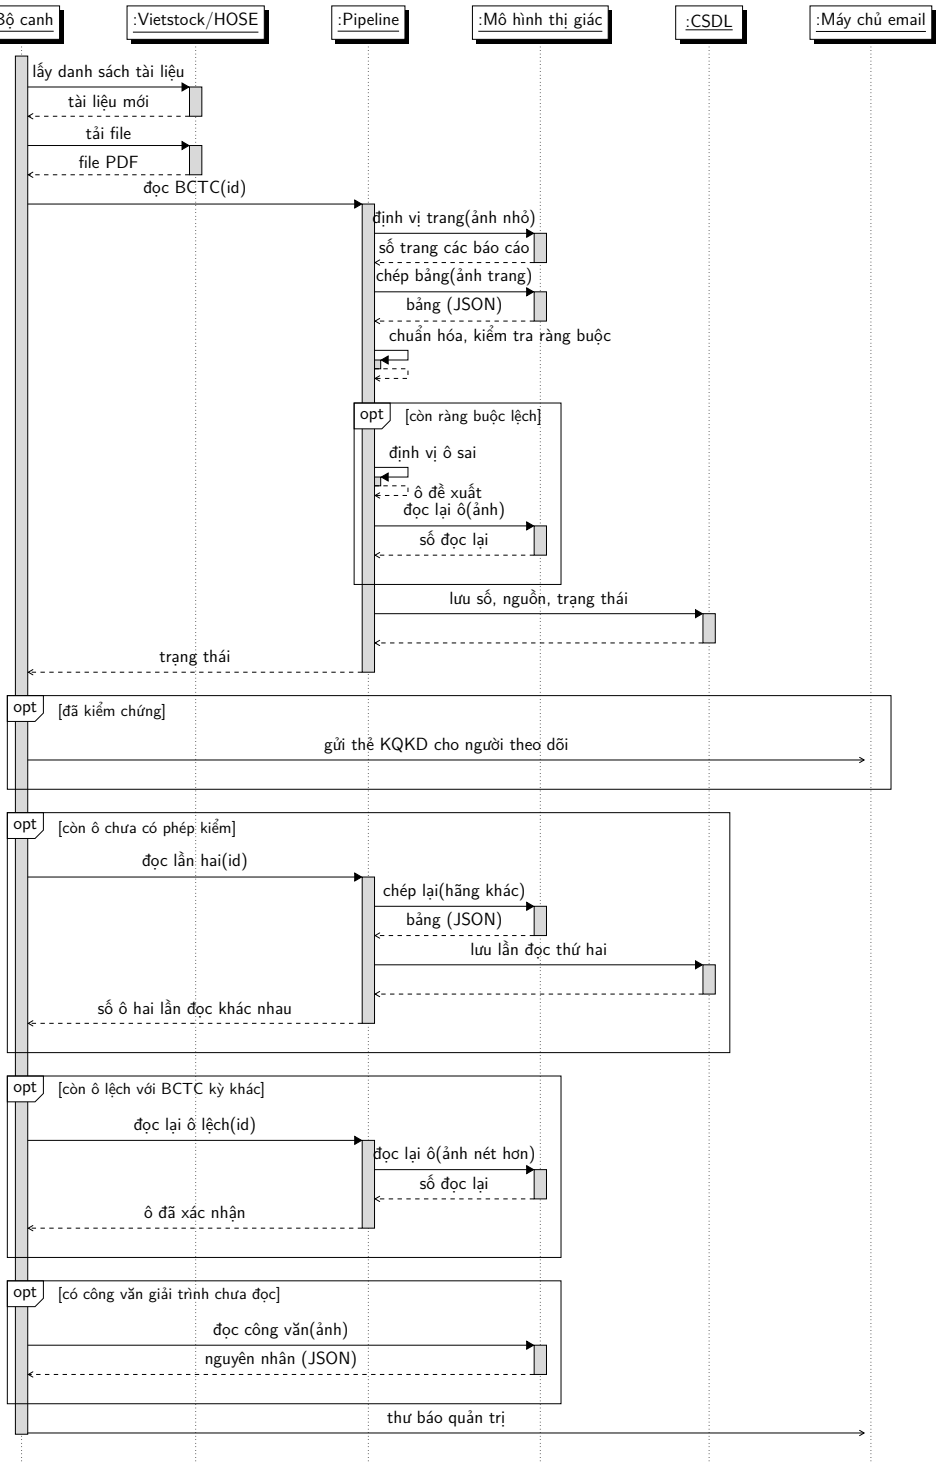

Hình 4.4: Biểu đồ triển khai. Hộp ba chiều là nút (thiết bị hoặc môi trường chạy); đường nối là kênh giao tiếp, ghi giao thức. Kết nối tunnel do máy chạy Soi mở ra phía Cloudflare, không có kết nối nào từ ngoài vào máy.

### 4.2.5 Vòng đời một tài liệu




Hình 4.5: Biểu đồ trạng thái của một tài liệu. Chấm đen là trạng thái đầu; nhãn trên mũi tên là sự kiện, phần trong ngoặc vuông là điều kiện. Chỉ BCTC đã kiểm chứng hoặc đã duyệt tay được hiển thị trên thẻ và bảng xếp hạng.

### 4.2.6 Luồng xử lý một BCTC mới



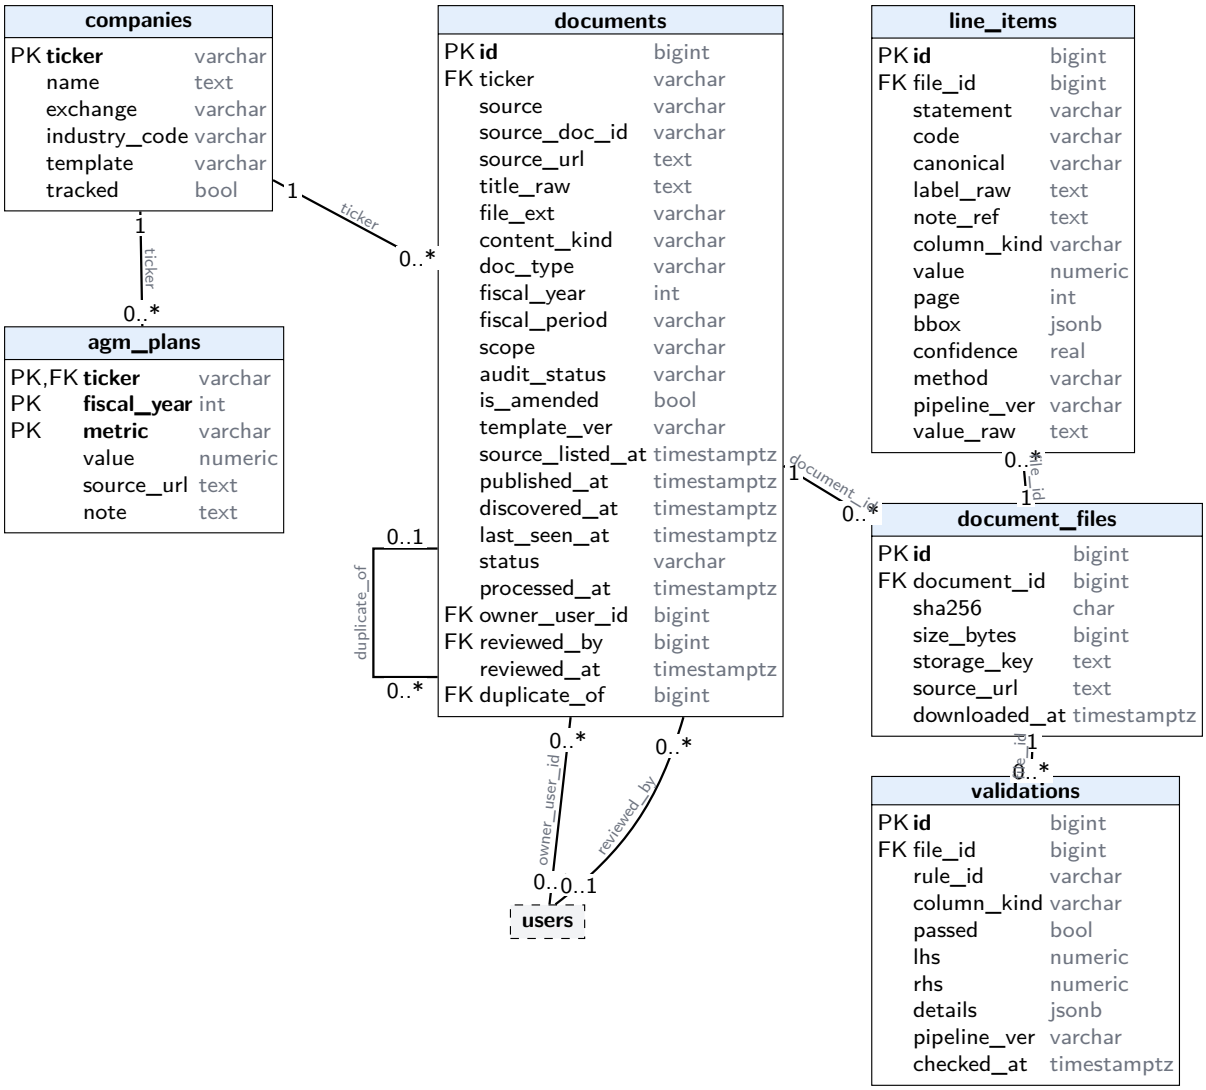

Hình 4.6: Biểu đồ tuần tự khi một BCTC mới xuất hiện (tài liệu mới gồm BCTC và công văn giải trình). Mũi tên liền đầu đặc là lời gọi, mũi tên đứt là giá trị trả về, mũi tên đầu hở là thông điệp không chờ trả lời; khung `opt` là đoạn chỉ chạy khi điều kiện trong ngoặc vuông đúng.

## 4.3 Thiết kế cơ sở dữ liệu

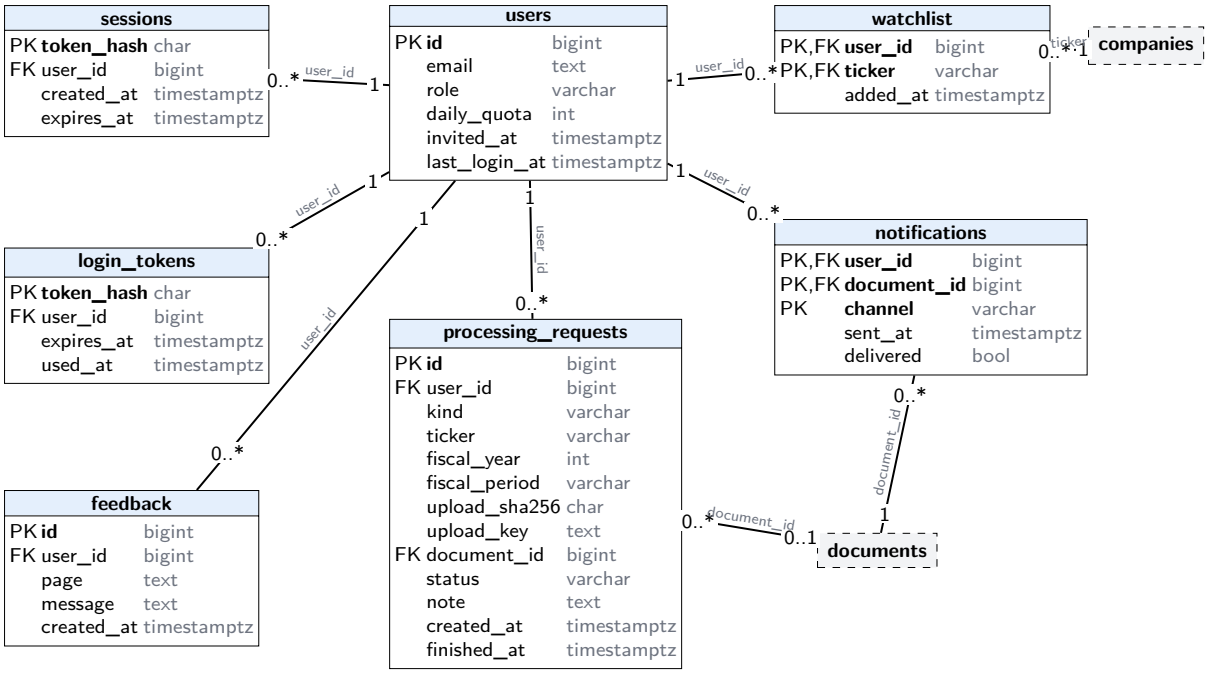
CSDL PostgreSQL gồm 12 bảng, chia hai nhóm: dữ liệu BCTC (Hình 4.7) và người dùng (Hình 4.8). Hai sơ đồ được **sinh tự động từ cấu trúc bảng trong CSDL thật**, nên luôn khớp với code. Mỗi hộp là một bảng gồm tên cột, khóa (PK: khóa chính, FK: khóa ngoại) và kiểu dữ liệu; mỗi đường nối là một khóa ngoại, hai đầu ghi bội số theo UML (`1`: đúng một, `0..1`: không hoặc một, `0..*`: không hoặc nhiều).

Một số điểm thiết kế:

- Bảng công bố lưu mỗi công bố (mã, loại, kỳ, phạm vi, trạng thái); bảng phiên bản file lưu từng file của công bố đó (băm SHA-256), nên BCTC công bố lại tạo dòng mới chứ không ghi đè.
- Bảng ô số lưu từng ô theo cột (quý này, cùng kỳ, lũy kế, đầu năm…), kèm chuỗi gốc, trang và phiên bản pipeline; bảng kết quả kiểm lưu kết quả từng ràng buộc. Toàn bộ đầu ra của mô hình và lịch sử đọc lại, sửa tay được lưu thêm thành bản ghi JSON theo từng file để kiểm tra lại mà không phải gọi mô hình.
- Công bố có ghi người tải lên là BCTC riêng của người dùng, không xuất hiện trong dữ liệu công khai.




Hình 4.7: Sơ đồ CSDL phần dữ liệu BCTC. Bảng nét đứt thuộc sơ đồ còn lại.




Hình 4.8: Sơ đồ CSDL phần người dùng. Bảng nét đứt thuộc sơ đồ còn lại.

## 4.4 Thu thập tài liệu

### 4.4.1 Lấy danh sách và nhận dạng tiêu đề

Bộ canh gọi API danh sách tài liệu của Vietstock (logic dựa trên mã nguồn mở Stock Report Agent [1], giấy phép MIT) cho các mã đang theo dõi. Từ tiêu đề tiếng Việt, bộ luật nhận dạng xác định bộ khóa: mã, loại báo cáo (quý, bán niên, năm), kỳ, phạm vi (hợp nhất, riêng, duy nhất), trạng thái soát xét hay kiểm toán, và có phải bản điều chỉnh hay không. Bộ luật được kiểm thử trên toàn bộ tiêu đề thật của VN30 năm 2025–2026. Lần chạy đầu nhận dạng đúng 174/174 tài liệu.

Bộ canh cũng lấy công văn giải trình KQKD (công ty phải gửi khi lợi nhuận biến động từ 10% so với cùng kỳ hoặc khi số sau soát xét khác số tự lập) và lưu thành một loại tài liệu riêng. Công văn không đi qua bước đọc bảng số; ở cuối mỗi lượt canh, mô hình đọc các công văn mới để lấy nguyên nhân hiện trên thẻ (mục 4.8.3). Tính đến 19/10/2026 có 91 công văn năm 2025–2026 (không tính bản trùng) của 20/30 mã VN30.

### 4.4.2 Nguồn thứ hai: trang công bố thông tin của HOSE

Chỉ dựa vào Vietstock thì hệ thống phụ thuộc vào một trang đăng lại: Vietstock có lúc đăng tiêu đề BCTC mà link file chưa dùng được, có lượt phản hồi chậm đến mức bỏ qua nhiều mã, và giờ Vietstock đăng không phải giờ công bố chính thức. Vì vậy bộ canh lấy thêm danh sách tệp mà mỗi công ty đăng trên trang của Sở Giao dịch Chứng khoán TP.HCM (HOSE), nơi niêm yết toàn bộ VN30. Mỗi tệp BCTC trên HOSE ghi rõ kỳ và thời điểm HOSE đăng; hợp nhất hay riêng được nhận theo tên tệp.

So trên 233 BCTC VN30 có ở cả hai nguồn (quý 4/2025 đến quý 3/2026), HOSE đăng trước Vietstock ở 161 BCTC, Vietstock đăng trước ở 62 và cách nhau dưới 15 phút ở 10. Chênh lệch trung vị nhỏ (HOSE sớm hơn 0,6 giờ), nhưng 10% số BCTC có trên HOSE sớm hơn từ 15,5 giờ trở lên, và 10% khác lại có trên Vietstock sớm hơn từ 7,1 giờ trở lên. Vì vậy hệ thống dùng cả hai nguồn, đọc BCTC từ nguồn nào có trước và đánh dấu bản đến sau là trùng, không đọc lại; giờ HOSE đăng được ghi làm giờ công bố chính thức. BCTC đã đăng tiêu đề quá 6 giờ mà cả hai nguồn đều chưa có file dùng được thì hệ thống gửi email cho quản trị.

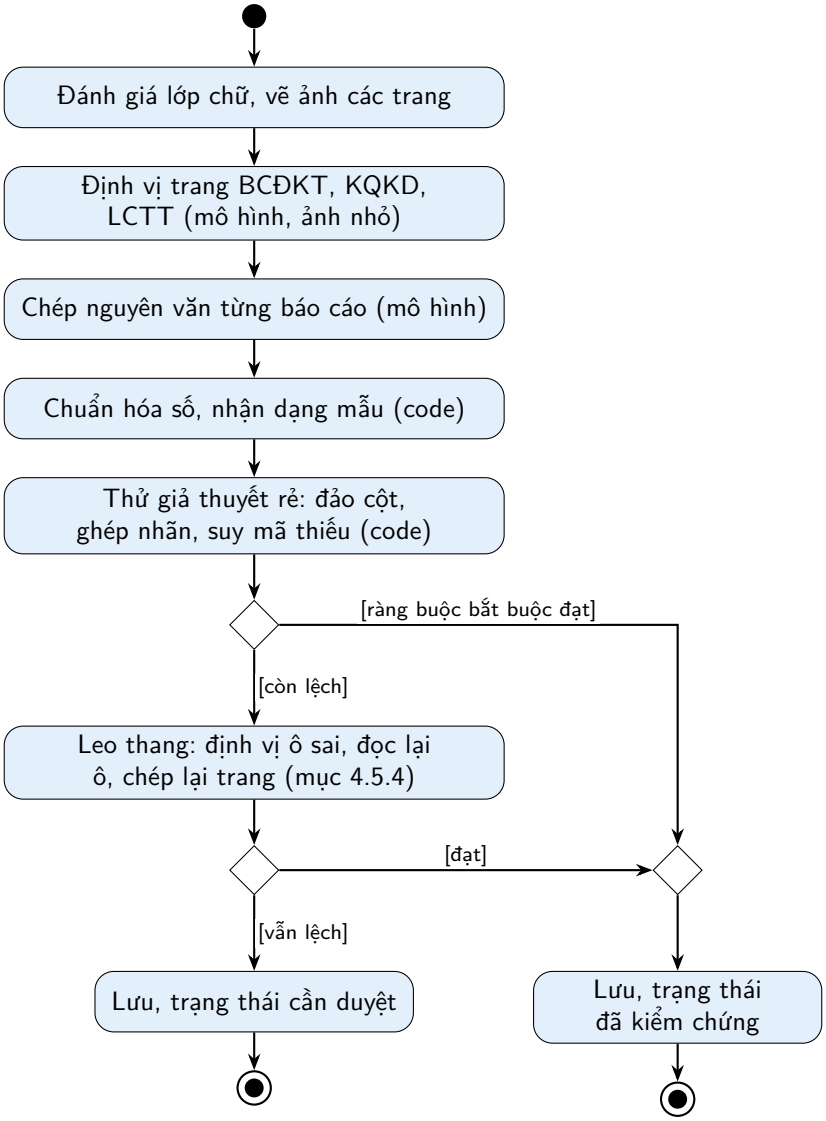
### 4.4.3 Lưu trữ và phiên bản

- Mỗi file được băm SHA-256. Cùng khóa nhưng khác hash là phiên bản mới, không ghi đè bản cũ.
- Cùng một file có thể được đăng dưới hai công bố khác nhau (ví dụ BCTC bán niên 2026 của GVR được đăng hai lần với cùng một file). Công bố sau được đánh dấu trùng và trỏ về công bố trước, không đọc lại, không tính hai lần vào thẻ hay phép đối chiếu giữa các kỳ.
- File nén (`.zip`, `.rar`) được giải nén và tách thành từng báo cáo.
- Lưu thời điểm nguồn đăng, thời điểm hệ thống thấy, và giờ công bố chính thức lấy từ HOSE.

Kho hiện có 643 tài liệu của 31 mã (VN30 và một mã người dùng yêu cầu thêm), trong đó 121 BCTC đã được đọc và 93 công văn giải trình.

## 4.5 Đọc và kiểm chứng BCTC

### 4.5.1 Quy trình




Hình 4.9: Biểu đồ hoạt động của quy trình đọc và kiểm chứng một BCTC. Hình thoi là nút rẽ nhánh (điều kiện ghi trong ngoặc vuông trên mỗi nhánh) hoặc nút gộp; chấm đen là điểm bắt đầu, vòng tròn có chấm là điểm kết thúc.

### 4.5.2 Mô hình chỉ chép, code mới hiểu số

Mô hình được yêu cầu chép đúng chuỗi in trên trang, ví dụ `(2.868.766)`, không tự đổi đơn vị hay tính toán. Đầu ra là JSON theo schema cố định (Listing 4.1). Code mới là phần phân tích chuỗi thành số:

- suy dấu phân cách hàng nghìn của cả tài liệu từ các nhóm 3 chữ số và phép cộng

kiểm tra;

- đọc đơn vị từ dòng "Đơn vị tính" và tiêu đề cột;
- hiểu số trong ngoặc là số âm;
- chuẩn hóa mã số; với ngân hàng, gán mã chuẩn cho từng dòng theo tên dòng đã bỏ dấu.

Đoạn mã 4.1: Một dòng KQKD sau khi mô hình chép (VCB quý 2/2026)

```
{"stt": "XIV", "code": null,
 "label": "Lợi nhuận thuần trong kỳ phân bổ cho cổ đông của Ngân hàng",
 "page": 11,
 "values": {"q_cur": "14.542.276", "q_prev_year": "8.831.885",
            "ytd_cur": "23.998.842", "ytd_prev_year": "17.528.114"}}
```

### 4.5.3 Giả thuyết rẻ trước khi gọi lại mô hình

Nhiều lỗi có dạng lặp lại và sửa được bằng code. Mỗi giả thuyết được "phân xử" bằng chính các ràng buộc: giữ phương án làm số ràng buộc đạt nhiều nhất mà không làm mất ràng buộc nào đang đạt.

- **Đảo cột STT và mã số** theo từng trang của từng báo cáo.
- **Nhãn ngân hàng bị xuống dòng:** ghép lại tên dòng rồi so khớp với danh sách nhãn.
- **Mã thiếu:** dòng không in mã được suy mã từ phép cộng (bằng đúng phần còn thiếu của một ràng buộc) hoặc từ tên dòng (LNST của cổ đông công ty mẹ, các dòng tổng KQKD của công ty chứng khoán).
- **Mã theo vị trí:** dòng không in mã nằm giữa hai dòng tổng được gán mã con của dòng tổng phía dưới, để kiểm phép "dòng tổng = tổng các dòng thành phần". Trên web, mã này được hiện mờ.
- **Dòng trùng mã:** nhiều dòng in cùng một mã thì được cộng lại.

### 4.5.4 Thang leo thang khi còn lệch

1. BCĐKT chưa có đủ tổng tài sản và tổng nguồn vốn, hoặc KQKD không có dòng LNST, thì chép thêm trang kế tiếp, vì có thể bước định vị bỏ sót trang (trang

nguồn vốn, trang cuối KQKD). Trang đã được giao cho một báo cáo mà lần chép đầu không ra dòng nào thì được chép lại riêng, mỗi trang một lần gọi.

2. **Tự định vị ô sai bằng ràng buộc, rồi đọc lại riêng các ô đó** (mục 4.6).
3. Đọc lại các ô thuộc ràng buộc còn lệch ở độ phân giải cao hơn. Chỉ giữ lần đọc lại nếu số ràng buộc lệch giảm và số ràng buộc đạt không giảm.
4. **Chép lại cả báo cáo** (BCĐKT, KQKD hoặc LCTT) khi báo cáo đó vẫn còn ràng buộc bắt buộc lệch, hoặc BCĐKT, KQKD chưa có ràng buộc nào đạt. Bậc này nhắm vào các lỗi mà đọc lại từng ô không sửa được: bỏ sót dòng, lệch hàng, chép nhầm cả cột, trang lộn ngược. Bậc này chép **mỗi trang một lần gọi**, với ảnh nét gửi đi không bị thu nhỏ (mục 4.6.4). Nếu vẫn lệch, hệ thống thử xoay từng trang thêm 180 độ, và chỉ giữ hướng xoay khi xác nhận được chữ đứng thẳng. Bản mới chỉ được giữ khi hiệu số "ràng buộc đạt trừ ràng buộc lệch" tốt hơn bản cũ và số ràng buộc đạt không giảm; chỉ so số ràng buộc lệch là chưa đủ, vì bản làm mất mã số kiểm được ít ràng buộc hơn nên trông như ít lệch hơn. Kết quả đo ở mục 5.10.
5. Vẫn lệch thì chuyển duyệt tay. Người duyệt xem ảnh trang cạnh bảng số, sửa từng ô. Mỗi lần sửa được ghi lại và trở thành **dữ liệu vàng** để đánh giá.

### 4.5.5 Duyệt tay

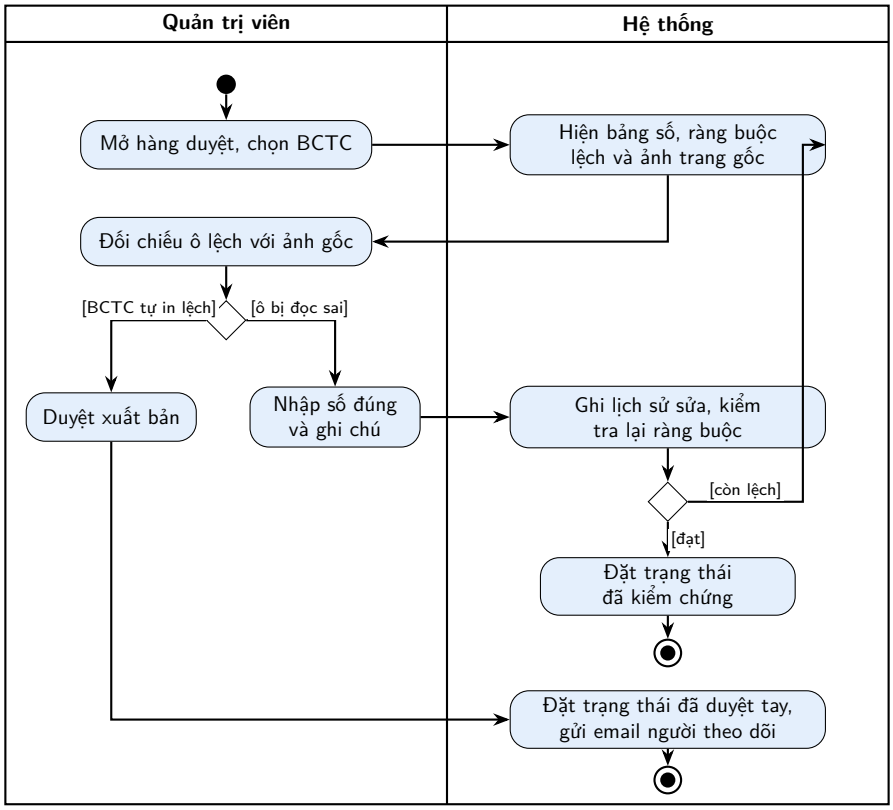
BCTC còn lệch sau mọi bậc leo thang được đưa vào hàng duyệt. Hình 4.11 chia việc theo hai làn: quản trị viên và hệ thống. Người duyệt sửa được một ô số hoặc mã số của một dòng, kể cả ở BCTC đã xuất bản; hệ thống kiểm lại ràng buộc, còn lệch thì BCTC trở về hàng duyệt. Chỉ các ô sửa tay mới được dùng làm dữ liệu vàng để đánh giá bước định vị ô sai (mục 5.9).

Ở BCTC đã xuất bản, một số ô vẫn cần người xem ảnh mà không chặn BCTC. Trang tài liệu gom chúng vào khung "Ô cần xem ảnh" (Hình 4.10) và ghi rõ lý do của từng ô, kèm con số: phép cộng không khớp; lệch với BCTC kỳ khác; hoặc hai lần đọc ra hai số. Lệch với BCTC kỳ khác có thể do đọc sai ở một bên, hoặc do chính công ty in hai bản khác nhau. Vì vậy khung này đưa thêm link sang BCTC kia để người duyệt xem ảnh cả hai bản. Nếu số đã đọc đúng như in, người duyệt bấm "đúng như ảnh". Xác nhận được ghi ở mọi ô của chỗ lệch, trên cả hai BCTC, và gắn với con số lúc đó; ô bị sửa sang số khác thì xác nhận hết hiệu lực. Bấm xác nhận không tính là sửa tay. Sau đó ô chuyển

sang “hai BCTC in khác nhau”, hoặc “người duyệt đã đối chiếu ảnh”.




Hình 4.10: Khung “Ô cần xem ảnh” ở BCTC quý 3/2026 của MSN. Dòng “chi phí đi vay” cột năm trước không khớp phép “quý bằng lũy kế trừ lũy kế quý trước”. Ảnh gốc cho thấy mỗi bản đều được đọc đúng: công ty đổi cách tính dòng này giữa BCTC quý 2 và BCTC bán niên.

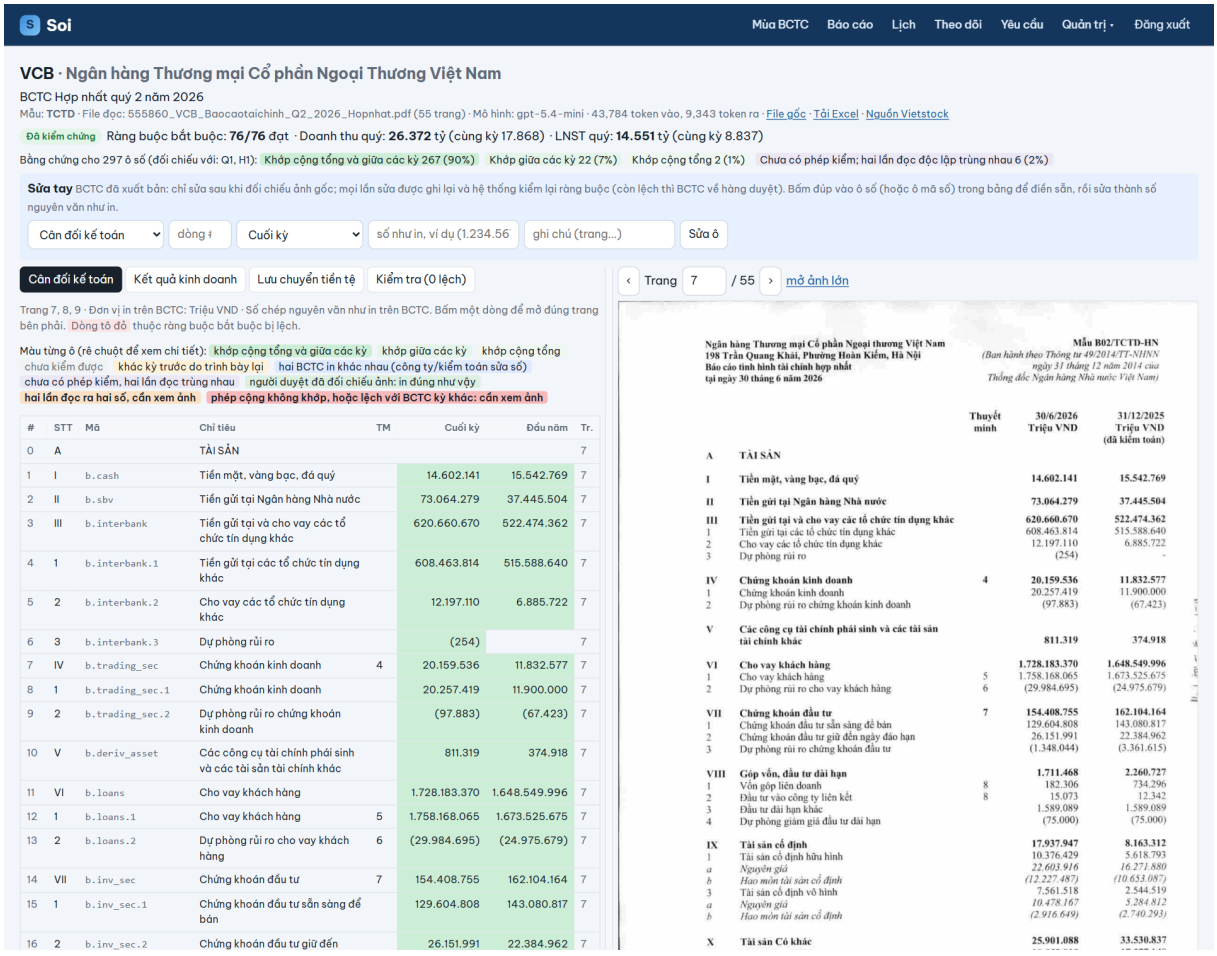



Hình 4.11: Biểu đồ hoạt động của việc duyệt tay, chia làn theo người thực hiện.

### 4.5.6 Bằng chứng cho từng ô

Sau khi kiểm chứng, mỗi ô số được xếp vào một loại bằng chứng: khớp cả phép cộng lẫn giữa các kỳ; chỉ khớp giữa các kỳ; chỉ khớp phép cộng; hai BCTC in khác nhau (doanh nghiệp hoặc kiểm toán sửa số); khác kỳ trước do trình bày lại; cần xem ảnh; hoặc chưa

kiểm được. Ô chưa kiểm được còn được so với lần đọc thứ hai và tách thành hai lần đọc trùng nhau hoặc khác nhau. Lần đọc thứ hai là bước cuối của quy trình, chạy sau khi đã báo tin cho người theo dõi để không làm chậm thông báo: nhà cung cấp mô hình còn lại chỉ chép lại những báo cáo còn ô chưa có phép kiểm nào xác nhận. Cùng lúc đó, các ô lệch với BCTC kỳ khác được đọc lại riêng ở ảnh nét hơn, trên cả hai bản. Đọc lại vẫn ra như cũ thì hai lần đọc độc lập trùng nhau, nên chỗ lệch được xếp là hai BCTC in khác nhau, không còn cần người xem. Khi đối chiếu quý 3 với quý trước, lũy kế 6 tháng được lấy từ BCTC quý 2 hoặc BCTC bán niên; khớp với một trong hai bản là đạt. Lý do là bản bán niên đã soát xét có thể đổi số hoặc cách tính một dòng so với bản quý 2. Giao diện tô màu từng ô theo loại bằng chứng (Hình 4.12).




Hình 4.12: Trang tài liệu: bên trái là bảng số đã đọc, tô màu theo bằng chứng; bên phải là ảnh trang BCTC gốc. Bấm một dòng để mở đúng trang; bảng cuộn trong khung riêng, kéo vạch ở giữa để đổi độ rộng hai bên.

### 4.5.7 Kiểm đủ dòng, không chỉ kiểm phép cộng

Phép cộng bắt được số đọc sai nhưng không bắt được việc thiếu cả một dòng. Nếu các dòng con bị bỏ sót mà dòng tổng vẫn được đọc đúng, hoặc dòng đứng cuối báo cáo (LNST, LNST của cổ đông công ty mẹ) không có, thì ràng buộc chứa dòng đó bị bỏ qua chứ không báo lệch. Hệ thống kiểm thêm hai điều, không gọi mô hình:

- **Dòng bắt buộc theo mẫu biểu.** KQKD phải có dòng LNST (doanh nghiệp, ngân hàng và công ty chứng khoán); có dòng lợi ích cổ đông không kiểm soát thì phải có dòng LNST của cổ đông công ty mẹ.
- **Dòng có ở BCTC khác của cùng công ty.** Cột đầu năm của BCĐKT giống nhau ở mọi quý trong năm, và cột cùng kỳ năm trước của KQKD, LCTT chính là số kỳ này của BCTC cùng kỳ năm trước. Dòng nào ở BCTC kia có số khác 0 và đã khớp phép cộng thì BCTC này phải có một dòng cùng mã, hoặc một dòng in đúng con số đó. Việc tìm theo con số là cần thiết vì cùng một công ty có thể đánh mã khác nhau giữa bản quý và bản bán niên. Ngoài ra, dòng KQKD, LCTT đã có số lũy kế ở quý trước thì quý này cũng phải có dòng cùng mã hoặc cùng tên.

Khi KQKD thiếu dòng LNST, hệ thống tự chép thêm trang ngay sau trang KQKD cuối (mục 4.5.4). Các trường hợp còn lại chỉ hiện cảnh báo "có thể thiếu dòng, cần xem lại", không chặn BCTC, vì công ty cũng có thể tự đổi cách trình bày giữa hai kỳ.

## 4.6 Công nghệ lõi: tự định vị và tự sửa ô đọc sai

### 4.6.1 Ý tưởng

Khi một phép cộng lệch, cách đơn giản là đọc lại *tất cả* các ô trong phép cộng đó. Cách này tốn tiền, và lần đọc lại cũng có thể sai. Ý tưởng của Soi là **dùng chính lưới ràng buộc để khoanh vùng ô sai trước**, rồi mới đọc lại, theo nguyên lý định vị lỗi của Fellegi–Holt [7]. Soi thêm hai điều chỉnh riêng cho lỗi đọc ảnh:

- Số đề xuất phải **giống số cũ về mặt chữ số**: khác nhiều nhất 2 chữ số theo khoảng cách Levenshtein, vì đọc nhầm thường chỉ sai 1–2 chữ số. Số đề xuất cũng phải nguyên theo đơn vị in trên BCTC.
- Đề xuất **phải được ảnh xác nhận**: đọc lại riêng ô đó mà không cho mô hình biết con số mong đợi, và chỉ nhận khi lần đọc ra đúng số đề xuất. Hai nguồn độc lập là

phép cộng và ảnh phải cùng chỉ một con số.

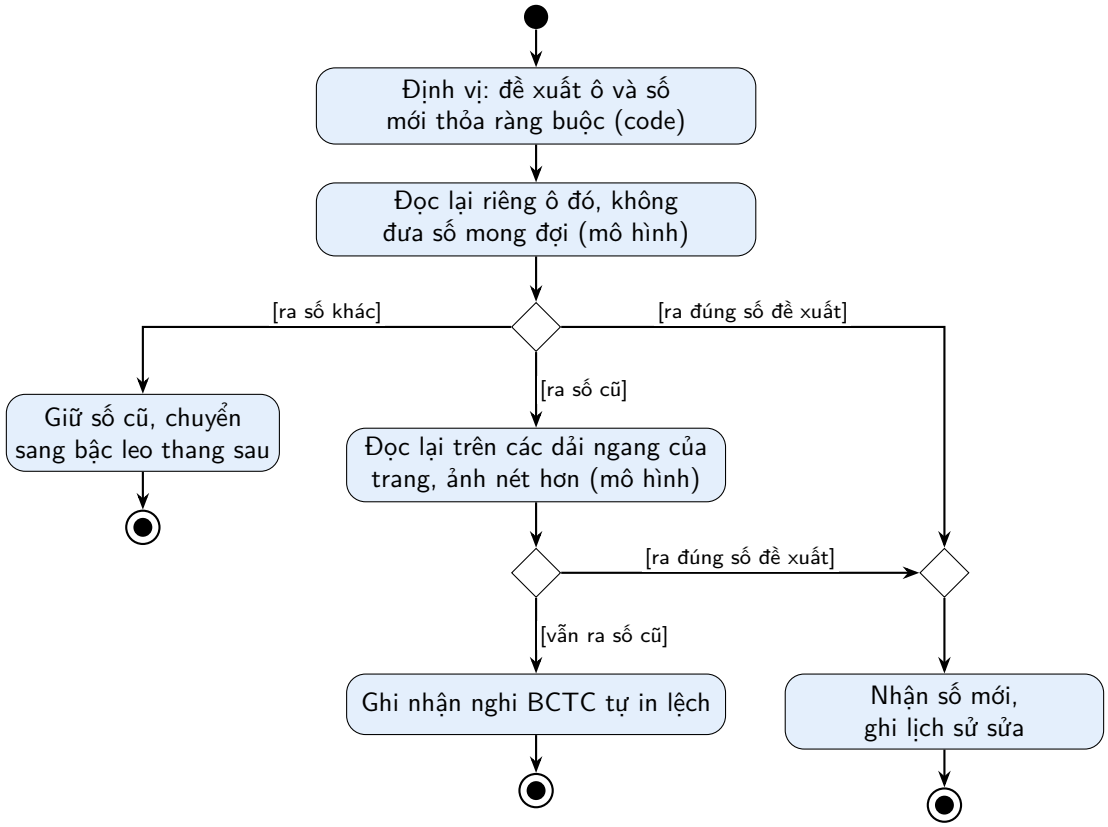
### 4.6.2 Thuật toán định vị

**Thuật toán 1** Định vị ô đọc sai bằng ràng buộc (rút gọn)

**Input:** bảng số $S$; tập ràng buộc $R$; tập ràng buộc đang lệch $F \subseteq R$; $\delta_r$ là độ lệch của $r$
**Output:** danh sách đề xuất (ô, số mới, độ tin)

$P \leftarrow \emptyset$
**for** ràng buộc $r \in F$, ô $c$ thuộc $r$ **do**
    $v \leftarrow$ giá trị làm $r$ khớp nếu thay $c$ ▷ $v = S[c] \pm \delta_r$
    **if** $v$ nguyên theo đơn vị in **and** số chữ số khác với $S[c] \leq 2$ **then**
        $S' \leftarrow S$ với $S'[c] = v$
        **if** $S'$ ít ràng buộc lệch hơn $S$ **and** không làm lệch ràng buộc đang đạt **then**
            thêm $(c, v,$ số ràng buộc được sửa$)$ vào $P$
xét thêm **cặp ô** cùng lệch một lượng (lỗi lan qua phép cộng giữa chúng)
chọn đề xuất sửa được nhiều ràng buộc nhất; nếu nhiều đề xuất ngang nhau và sửa *cùng một tập* ràng buộc thì gom thành **nhóm ngang nhau**
áp đề xuất, lặp lại với các ràng buộc còn lệch (tối đa 40 vòng)
**return** $P$ kèm độ tin: *cao* (sửa từ 2 ràng buộc trở lên), *vừa*, *thấp*

### 4.6.3 Xác nhận bằng đọc lại




Hình 4.13: Biểu đồ hoạt động của bước đọc lại để xác nhận một đề xuất. Với một nhóm đề xuất ngang nhau, hệ thống đọc lại cả nhóm và chỉ nhận khi đúng *một* ô ra số đề xuất.

**Vì sao không đưa con số mong đợi cho mô hình?**

Nếu nói với mô hình "ô này phải là 4.831", mô hình có xu hướng đồng ý. Kết quả khi đó không còn là bằng chứng độc lập. Soi chỉ hỏi "ô ở dòng X, cột Y ghi số gì", rồi so câu trả lời với đề xuất bằng code. Phép so bỏ qua khác biệt về dấu phân cách và dấu ngoặc.

### 4.6.4 Chuẩn bị ảnh cho bước đọc lại

Đọc lại chỉ có ích khi mô hình nhìn rõ hơn lần đầu. Ở mức mặc định, API của mô hình thu nhỏ ảnh lớn [10], nên vẽ trang to hơn rồi gửi đi không giúp gì; Soi gửi ảnh đọc lại ở mức không thu nhỏ. Với bản scan, thư viện vẽ PDF phóng ảnh bằng cách nhân bản điểm ảnh, làm chữ số bị răng cưa và dễ nhầm 3 với 8. Soi vẽ trang đúng độ phân giải của ảnh scan gốc rồi phóng một lần bằng nội suy Lanczos, tối đa 3 lần, vì phóng thêm không tạo ra thông tin mới. Soi không chuyển ảnh sang trắng đen và không dùng mô hình tăng độ

phân giải: trên bản scan chất lượng thấp, các bước xử lý ảnh truyền thống (ảnh xám, chuyển trắng đen) không cải thiện mà có khi còn làm OCR kém đi [8], còn mô hình tăng độ phân giải có thể tạo ra chi tiết không có thật trong vùng chữ [12]. Với chữ số tài chính, một nét giả là đủ biến chữ số này thành chữ số khác. Với file scan từ 100 dpi trở xuống, cách vẽ này được dùng ngay từ lần chép đầu, vì ô đọc đúng từ đầu thì không cần đọc lại. Kết quả đo ở mục 5.11.

### 4.6.5 Mở rộng sang ràng buộc giữa các BCTC

Một số lỗi không làm lệch phép cộng nào trong chính BCTC. Ví dụ đọc nhầm một dòng chi tiết không nằm trong ràng buộc bắt buộc. Khi đó hệ thống dùng thêm các ràng buộc giữa các kỳ (Hình 2.3): số đầu năm bằng số cuối năm trước, BCTC quý 2 khớp bán niên, quý 4 khớp năm. Nếu hai bản khác nhau, hệ thống đọc lại ô đó trên *cả hai* bản. Số mới chỉ được nhận khi nó làm hai bản khớp nhau mà không làm lệch ràng buộc bắt buộc nào.

## 4.7 Quản lý token và chi phí

Chi phí gọi mô hình được tính theo số token gửi vào và nhận về:

$$\text{Chi phí} = p_{\text{vào}} \times N_{\text{vào}} + p_{\text{ra}} \times N_{\text{ra}}, \tag{4.1}$$

trong đó $p$ là giá mỗi token theo bảng giá của nhà cung cấp, $N$ là số token. Với mô hình có bước suy luận, token suy luận được tính vào $N_{\text{ra}}$. Soi giảm cả hai đại lượng bằng các cách sau.

### 4.7.1 Giảm token vào

- **Chỉ gửi trang cần thiết:** bước định vị dùng ảnh nhỏ của các trang đầu; bước chép bảng chỉ gửi đúng các trang BCĐKT, KQKD, LCTT, không gửi cả tài liệu.
- **Đọc lại theo ô:** khi lệch, chỉ hỏi lại vài ô được bước định vị đề xuất, không chép lại cả báo cáo. Chép lại cả trang chỉ là bậc sau cùng trước khi chuyển duyệt tay.
- **Giả thuyết rẻ trước:** đảo cột, ghép nhãn, suy mã thiếu đều làm bằng code, không gọi mô hình.

### 4.7.2 Giới hạn token ra

Mỗi bước gọi mô hình có trần token ra riêng, khoảng 3–4 lần mức lớn nhất đo được, để chặn trường hợp mô hình trả lời dài bất thường. Đầu ra luôn theo khuôn JSON cố định nên mô hình không viết thêm lời thừa.

### 4.7.3 Đo và giới hạn chi phí

- Mỗi lần gọi được ghi số token vào, ra, thời gian và chi phí **theo từng bước**, vào bản ghi của BCTC và vào một **sổ chi phí** chỉ ghi thêm. Bản ghi của BCTC chỉ giữ lần đọc mới nhất, nên lần đọc bị ghi đè không còn dấu vết; từ 22/10/2026 tổng chi phí theo ngày, tháng, bước lấy từ sổ, gồm cả lần đọc lại, công văn, báo cáo của agent và các lần chạy đo. Trang "Chi phí" dành cho quản trị viên hiện chi phí tháng này so với trần, theo ngày, theo bước, theo người yêu cầu và các BCTC tốn nhiều nhất (Bảng 5.6 lấy chi phí từng BCTC từ bản ghi). Trang tài liệu hiện số token đã dùng cho BCTC đó.
- Mỗi người dùng có **hạn mức yêu cầu mới mỗi ngày**; yêu cầu trả ngay từ kho không tính vào hạn mức.
- Chi phí đọc theo yêu cầu người dùng và báo cáo của agent mỗi tháng không vượt **trần tháng** (mặc định 5 USD); vượt thì yêu cầu mới nằm chờ sang tháng sau, giao diện báo cho người dùng biết. Đọc theo lịch cho các mã đang theo dõi không tính vào trần.

## 4.8 Thẻ KQKD và giao diện

### 4.8.1 Thẻ KQKD

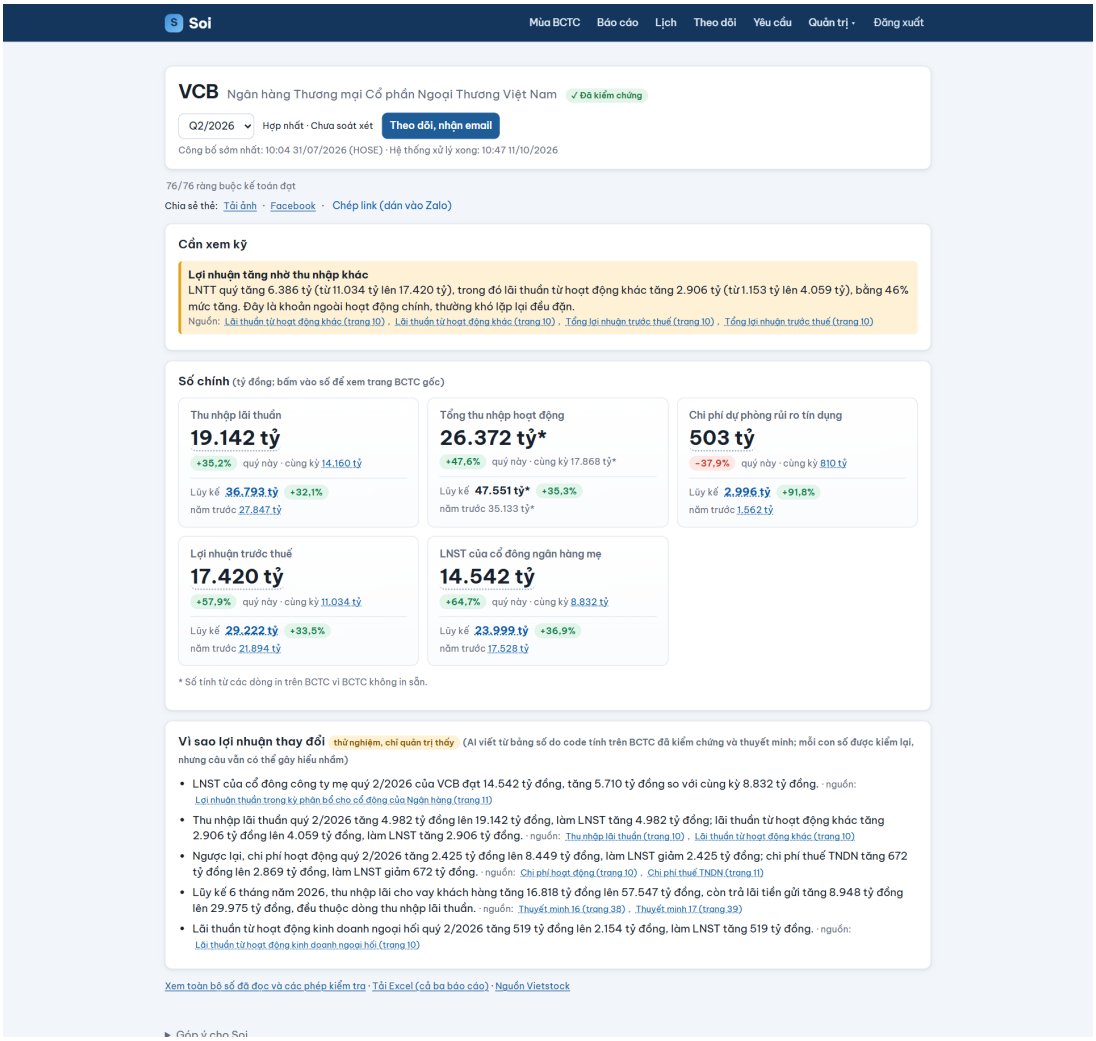
Thẻ được tính hoàn toàn bằng code từ số đã kiểm chứng. Mỗi giá trị trên thẻ mang theo nguồn: tài liệu, trang, dòng và chuỗi gốc. Doanh nghiệp thường có các chỉ tiêu doanh thu thuần, lợi nhuận gộp và LNST của cổ đông công ty mẹ. Ngân hàng có thu nhập lãi thuần, tổng thu nhập hoạt động, chi phí dự phòng, LNTT và LNST của cổ đông ngân hàng mẹ. Công ty chứng khoán (mẫu B02-CTCK) có cộng doanh thu hoạt động, cộng chi phí hoạt động, lợi nhuận kế toán trước thuế và LNST phân bổ cho chủ sở hữu; các cờ dựa trên lợi nhuận gộp và dòng tiền kinh doanh không áp dụng cho mẫu này và được ghi là chưa xét.

BCTC không có dòng LNST của cổ đông công ty mẹ nhưng có dòng không kiểm soát thì thẻ lấy LNST trừ phần không kiểm soát.

**Quy tắc hiển thị tăng trưởng:** chỉ in % khi cả hai kỳ đều lãi. Khi có kỳ lỗ, thẻ mô tả bằng lời, ví dụ "lỗ thu hẹp từ 6,8 tỷ còn 3,2 tỷ", thay vì in "+53,6%" gây hiểu nhầm.

Bảng 4.5: Các cờ "cần xem kỹ" trên thẻ. Cờ chỉ nêu số liệu kèm nguồn, không đưa nhận định đầu tư.

| **Cờ** | **Điều kiện (tóm tắt)** |
|---|---|
| Lỗ hoặc đổi dấu lợi nhuận | Một trong hai kỳ lỗ: % không có ý nghĩa |
| Tăng trưởng do nền thấp | Tăng trên 100% và LNST cùng kỳ dưới 1/3 trung bình 4 quý trước đó |
| Lợi nhuận phần lớn ngoài hoạt động chính | Hơn nửa LNTT không đến từ LN gộp − chi phí bán hàng, quản lý |
| Lợi nhuận tăng nhờ thu nhập khác | Lợi nhuận khác (ngân hàng: lãi thuần hoạt động khác) tăng từ 1/3 mức tăng LNTT và từ 10% LNTT quý |
| Hoàn nhập / chi phí dự phòng giảm mạnh | Ngân hàng: dự phòng âm, hoặc giảm quá nửa trong khi LNTT tăng |
| Mua bán công ty con, biến động công ty liên kết | Dòng LCTT về mua, bán công ty con; lãi liên doanh, liên kết tăng trên 3 lần |
| Có lãi nhưng dòng tiền kinh doanh âm | LNST lũy kế dương, lưu chuyển tiền thuần từ hoạt động kinh doanh âm |
| Số liệu bị sửa giữa các BCTC | Hai BCTC cùng ngày (quý 2 và bán niên…) in khác nhau ở các dòng chính; cờ ghi mức chênh và phần trăm |




Hình 4.14: Thẻ KQKD của VCB quý 2/2026. LNST tăng 64,7%, và cờ cho thấy gần một nửa mức tăng LNTT đến từ thu nhập hoạt động khác. Bấm vào mỗi số để mở trang BCTC gốc.

Khi người dùng mở thẻ của một mã ở kỳ mà mã đó chưa công bố BCTC (thường gặp đầu mùa), thẻ hiện kỳ gần nhất đã có số và ghi rõ kỳ đang chọn còn thiếu, thay vì để trống.

### 4.8.2 Vì sao lợi nhuận thay đổi: agent tìm nguyên nhân

Với mỗi BCTC quý đã kiểm chứng, bộ canh chạy thêm một agent nhỏ để viết vài câu giải thích vì sao LNST thay đổi so với cùng kỳ; đoạn này nằm ở mục "Vì sao lợi nhuận thay đổi" của thẻ, hiện đang thử nghiệm và chỉ quản trị viên thấy cho tới khi đo xong trên cả mùa BCTC quý 3/2026. Các bước:

1. **Tách mức thay đổi bằng code.** Đi ngược các ràng buộc kế toán của mẫu BCTC từ dòng LNST xuống các dòng thành phần (lợi nhuận gộp, thu nhập và chi phí tài

chính, chi phí bán hàng, dự phòng, thuế, phần của cổ đông không kiểm soát…), ra phần đóng góp của từng dòng. Vì các ràng buộc đó đã đạt, tổng các phần đóng góp phải bằng đúng mức thay đổi LNST; không bằng thì BCTC đó không được giải thích. Nhiều BCTC năm 2026 vẫn in mã dòng theo mẫu cũ dù đã sang mẫu mới, nên khi không khớp hệ thống thử mã dòng của mẫu còn lại.

2. **Agent chọn việc.** Mỗi lượt, mô hình xem bảng phần đóng góp và những gì đã thu thập rồi chọn một việc: đọc thuyết minh của một dòng, lấy nguyên nhân trong công văn giải trình (mục 4.8.3), hoặc dừng; tối đa 4 lượt và 0,03 USD mỗi BCTC.

3. **Đọc thuyết minh.** Số thuyết minh của dòng có sẵn trong KQKD đã đọc. Hệ thống tìm trang bằng cách cho mô hình đọc tiêu đề mục trên vài trang và chia đôi khoảng trang theo số mục; BCTC đánh số lại từ đầu trong mỗi phần (ví dụ "VI.14") thì tìm đầu phần trước. Mô hình chép bảng của mục; code chỉ dùng các khoản con khi chúng cộng đúng bằng dòng KQKD ở cả kỳ này và cùng kỳ, kể cả khi bảng gồm nhiều dòng KQKD (tìm khối có dòng bằng dòng KQKD và các dòng kề cộng ra nó). Thuyết minh quý có thể chỉ in số lũy kế, nên mỗi dòng ghi rõ kỳ của số.

4. **Viết và kiểm.** Code dựng bảng số (mỗi dòng có nguồn tới trang BCTC hoặc trang thuyết minh); mô hình viết 2–5 câu; bộ kiểm tra số của agent báo cáo kiểm từng câu, câu sai được viết lại tối đa 2 lần rồi bỏ.

### 4.8.3 Nguyên nhân từ công văn giải trình

Khi lợi nhuận biến động mạnh, công ty gửi công văn giải trình nêu nguyên nhân, thường kèm con số: doanh thu tăng bao nhiêu phần trăm, chi phí lãi vay giảm bao nhiêu tỷ. Thẻ KQKD hiện các nguyên nhân này ngay dưới phần số chính. Mô hình chỉ chép từng phần của công văn (BCTC hợp nhất hay riêng, riêng quý hay lũy kế, lợi nhuận kỳ này và cùng kỳ, % thay đổi) và từng nguyên nhân (lời của công ty, khoản mục BCTC được nhắc tới, con số, số đó là mức thay đổi hay mức đạt được, nói về cả công ty hay một mảng). Code đối chiếu mọi con số với BCTC đã kiểm chứng cùng kỳ, cùng phạm vi, cho phép sai lệch bằng mức làm tròn công ty dùng, và gắn một trong bốn nhãn: "số khớp BCTC" (chỉ con số được kiểm, lời giải thích đi kèm thì không); "đúng chiều tăng/giảm" khi công ty chỉ nói tăng hay giảm; "theo công ty, chưa kiểm được bằng số" khi số thuộc một mảng hay một công ty con mà BCTC không tách, hoặc không phải mức thay đổi (kế hoạch, sản lượng);

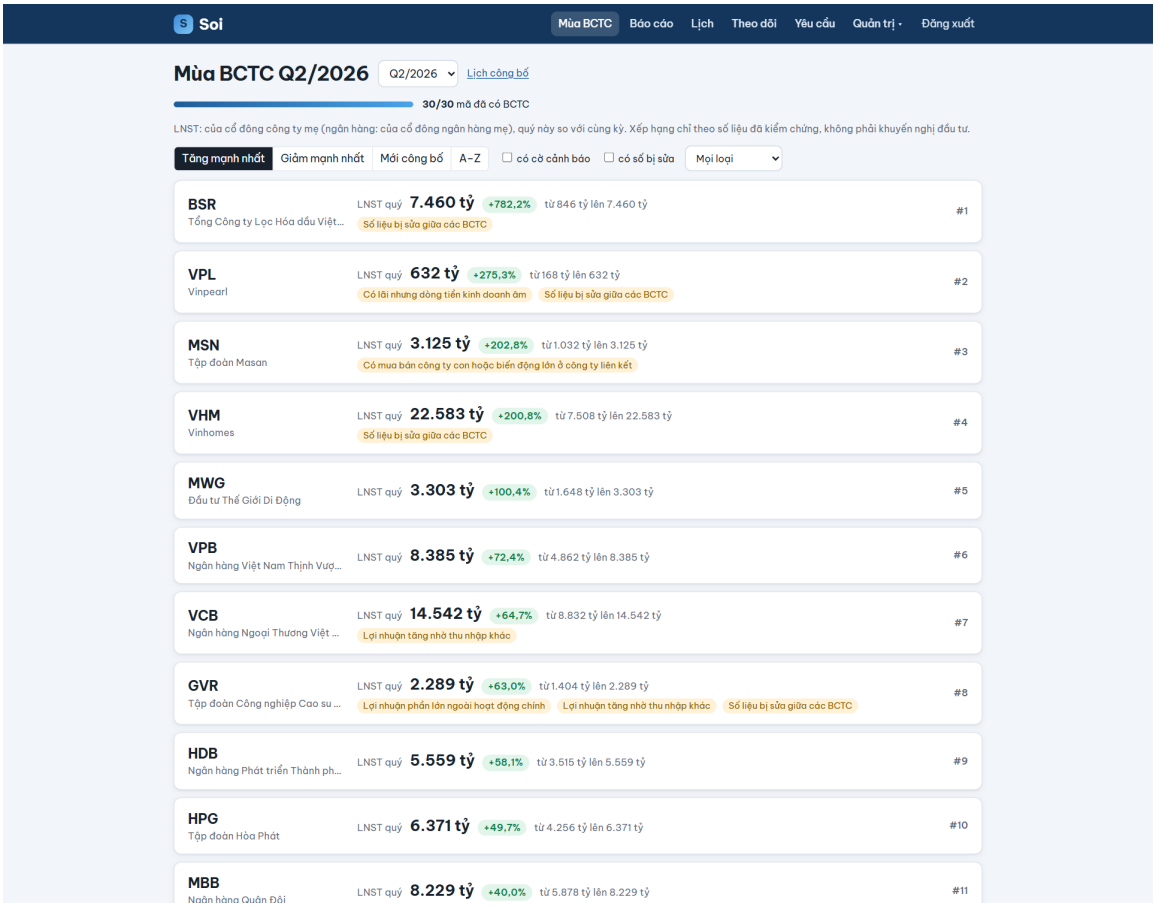
"lệch với BCTC" (kể cả khi chiều tăng/giảm ngược với BCTC). Nguyên nhân là lời của công ty: hệ thống chỉ kiểm con số, không đánh giá lời giải thích có đúng hay không.

Mỗi công văn được đọc một lần khi bộ canh tải về (khoảng 0,002 USD) và lưu lại; trang thẻ chỉ dùng bản đã lưu và chạy lại phép đối chiếu mỗi lần hiện, nên luôn theo số BCTC mới nhất, kể cả sau khi người duyệt sửa tay.

Trên 91 công văn tính đến 19/10/2026: 110/110 con số lợi nhuận và % thay đổi công ty nêu ở câu chính khớp BCTC. Trong 226 nguyên nhân, 128 khớp số, 4 khớp chiều tăng/giảm, 94 chưa kiểm được bằng số và không nguyên nhân nào lệch. 113 phần công văn không đối chiếu được vì nói về BCTC riêng công ty mẹ, hoặc về kỳ chưa có BCTC đã kiểm chứng. Một phần công văn có thể có nhiều nguyên nhân, nên số phần và số nguyên nhân đếm theo hai đơn vị khác nhau.

### 4.8.4 Bảng xếp hạng mùa BCTC

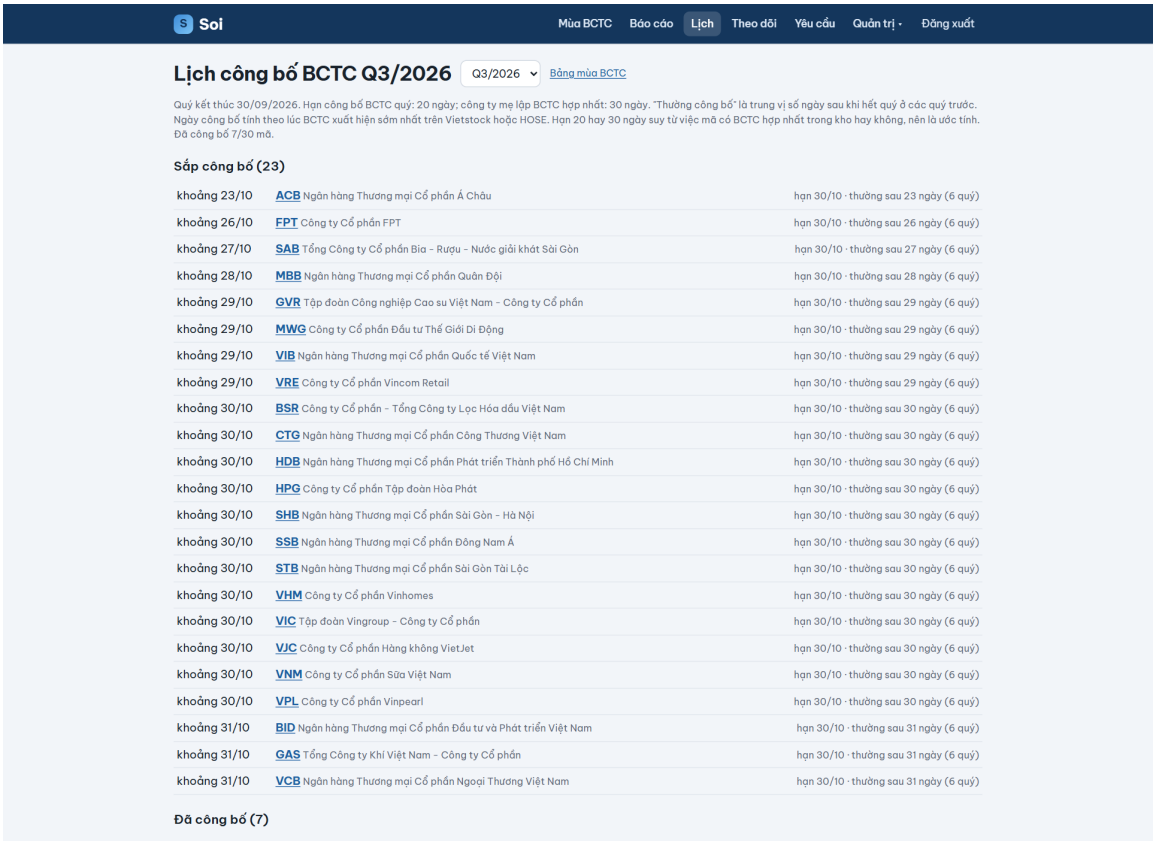
Bảng xếp hạng các mã theo tăng trưởng LNST quý so với cùng kỳ, chỉ gồm thẻ đã kiểm chứng. Người dùng lọc được theo loại (ngân hàng, doanh nghiệp), theo "có cờ" và theo "số bị sửa" (Hình 4.15). Mức tăng hiện màu xanh, mức giảm màu đỏ như quy ước của bảng giá chứng khoán; màu chỉ cho biết chiều của con số, không đánh giá tốt hay xấu. Các mã chưa công bố được gom vào một dòng cuối trang.



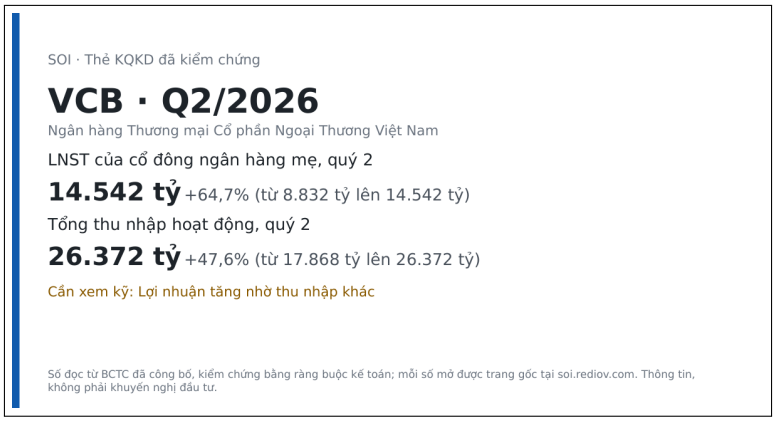

Hình 4.15: Bảng xếp hạng mùa BCTC quý 2/2026 (phần đầu trang).

### 4.8.5 Lịch công bố và ảnh chia sẻ

Lịch công bố cho biết hạn chót của từng mã (20 hoặc 30 ngày sau khi hết quý) và "ngày dự kiến". Ngày dự kiến là trung vị số ngày công bố sau khi hết quý của 8 quý gần nhất; ngày công bố là lúc BCTC xuất hiện sớm nhất trên Vietstock hoặc HOSE. Thẻ KQKD ghi lúc công bố sớm nhất, nguồn tương ứng và lúc hệ thống xử lý xong. Ảnh thẻ kích thước 1200×630 dùng để chia sẻ lên Facebook, Zalo; chỉ thẻ đã kiểm chứng mới có trang chia sẻ công khai.




(a) Lịch công bố quý 3/2026 (phần đầu trang)




(b) Ảnh thẻ để chia sẻ

Hình 4.16: Lịch công bố và ảnh thẻ chia sẻ.

### 4.8.6 Xuất file Excel

Từ thẻ KQKD hoặc trang tài liệu, người dùng tải được BCTC đã kiểm chứng dưới dạng file Excel, mỗi báo cáo một trang tính, cạnh mỗi cột số là cột bằng chứng của từng ô và số trang trong file gốc. Một trang tính riêng ghi BCTC gốc, giờ công bố, các ô đã sửa tay và lưu ý đây không phải khuyến nghị đầu tư, nên số đem ra khỏi hệ thống vẫn mang theo nguồn.

### 4.8.7 Người dùng và quyền riêng tư

Giai đoạn thử nghiệm chỉ dành cho người được mời, đăng nhập bằng link gửi qua email. Người dùng theo dõi mã để nhận email khi có BCTC mới, gửi yêu cầu đọc mã ngoài danh sách (có hạn mức mỗi ngày), hoặc tải lên BCTC riêng. Tài liệu tải lên chỉ chủ sở hữu thấy. Trước khi đọc, hệ thống xem hai trang đầu để kiểm tra file đúng là BCTC của mã và kỳ người dùng khai; file khác loại (ví dụ công văn giải trình kết quả kinh doanh) bị từ chối kèm lý do và không tính vào hạn mức. Mỗi email được mời nhận tối đa năm link đăng nhập mỗi giờ, để người khác không gõ email đó liên tục làm đầy hộp thư. Cuối mỗi trang có ô góp ý: nội dung được lưu kèm trang người dùng đang xem, gửi email cho quản trị viên và hiện trong danh sách góp ý ở trang quản trị.

## 4.9 Agent tạo báo cáo theo yêu cầu

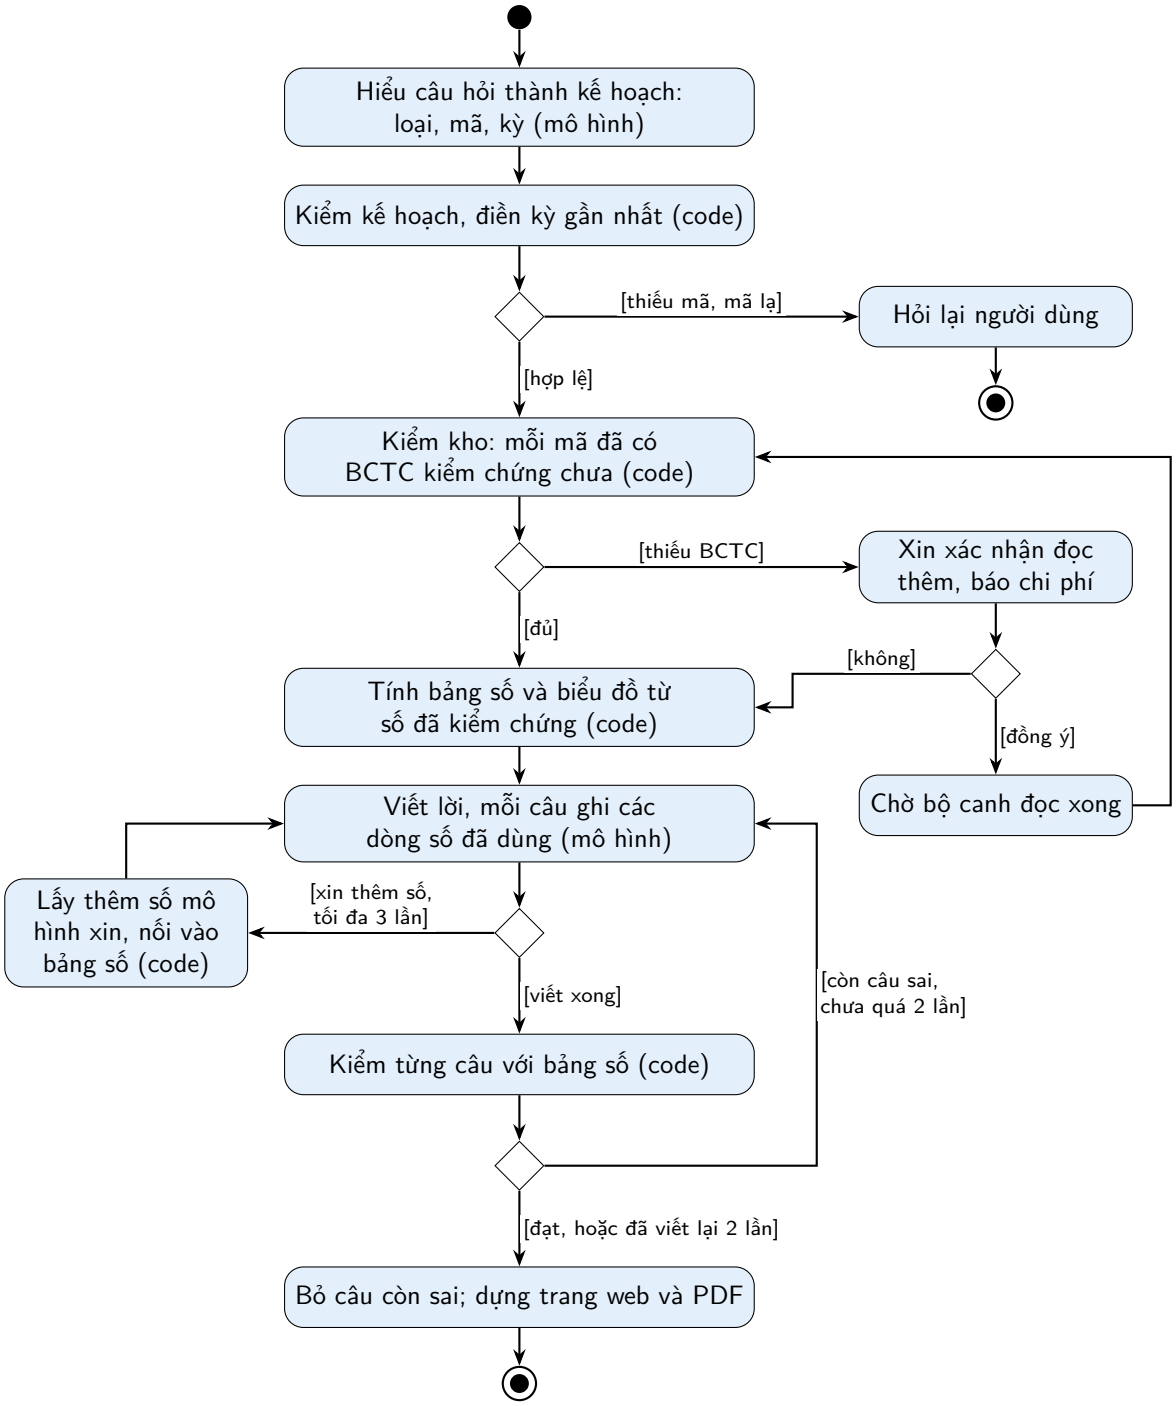
Người dùng gõ câu hỏi bằng lời thường và nhận về một báo cáo ngắn có lời văn, bảng số, biểu đồ. Agent trả lời năm loại câu hỏi:

- so nhiều mã cùng kỳ, ví dụ "so sánh KQKD quý 3/2026 của TCB, LPB và VPB";
- một mã so với cùng kỳ năm trước, ví dụ "FPT quý vừa rồi làm ăn thế nào";
- vị trí của một mã trong nhóm, ví dụ "LNST quý 2 của MBB đứng thứ mấy trong các ngân hàng";
- mã nào tốt nhất trong các mã đang theo dõi, không cần nêu mã, ví dụ "công ty nào có KQKD tốt nhất hiện nay, tại sao?";
- xu hướng qua nhiều quý (thêm sau khi đo, mục 4.9.4), ví dụ "LNST của TCB 4 quý gần nhất".

Câu hỏi không thuộc loại nào, hoặc thiếu mã, được hỏi lại kèm ví dụ của cả năm loại. Nguyên tắc vẫn như phần đọc BCTC: **mô hình chỉ hiểu câu hỏi và viết câu, mọi con số do code tính và code kiểm lại**.

### 4.9.1 Luồng xử lý

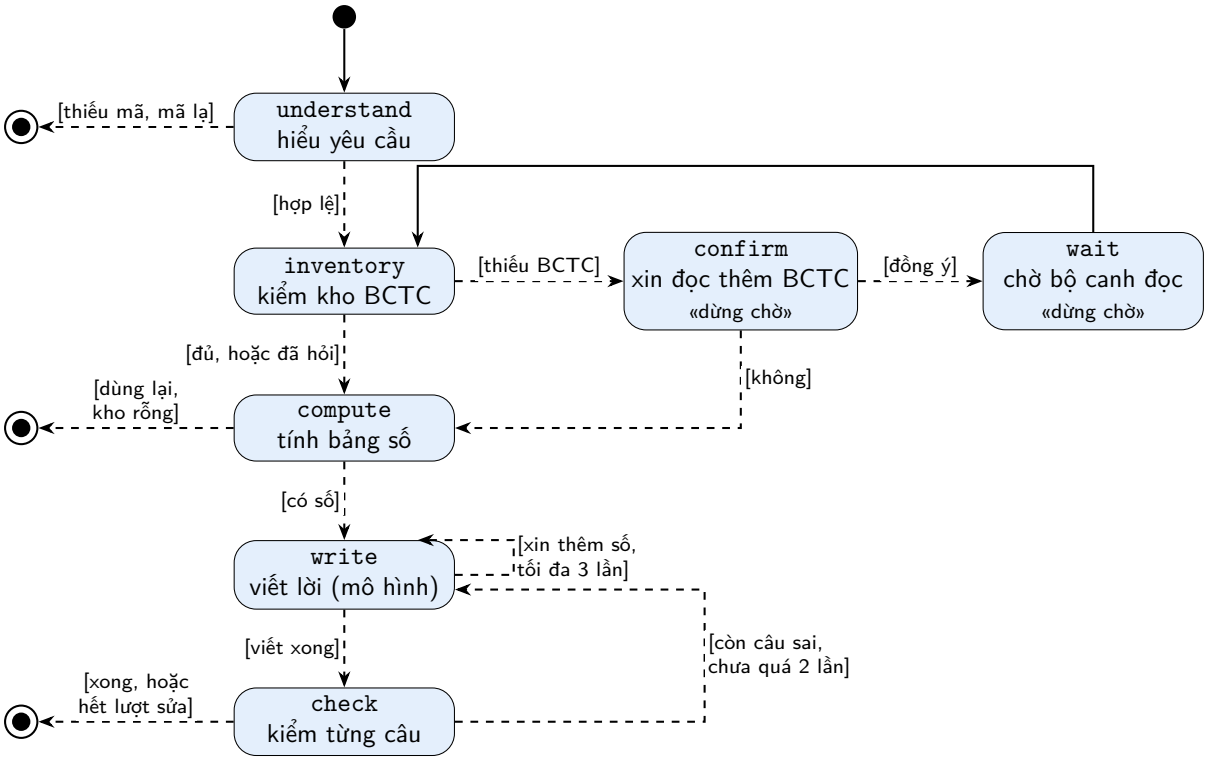
Agent là một đồ thị trạng thái (LangGraph) gồm các bước ở Hình 4.17. Trạng thái được lưu vào CSDL sau mỗi bước, nên báo cáo dừng chờ được (chờ người dùng xác nhận, chờ




Hình 4.17: Biểu đồ hoạt động của agent tạo báo cáo. Hình thoi là nút rẽ nhánh, điều kiện ghi trong ngoặc vuông.

bộ canh đọc thêm BCTC, có khi vài giờ) rồi chạy tiếp đúng chỗ, kể cả khi dịch vụ khởi động lại.

Hình 4.18 là chính đồ thị LangGraph mà agent chạy, sinh tự động từ code nên luôn khớp với code. Mỗi khối là một bước của đồ thị (tên bước giữ như trong code); các hoạt động ở Hình 4.17 được gom vào bảy bước này. Hai bước "dừng chờ" là nơi đồ thị tạm




Hình 4.18: Đồ thị LangGraph của agent, sinh từ đồ thị trong code. Mũi tên liền là chuyển cố định, mũi tên đứt là chuyển có điều kiện (điều kiện trong ngoặc vuông); chấm đen là điểm bắt đầu, vòng tròn có chấm là điểm kết thúc.

dừng và lưu trạng thái: chờ người dùng xác nhận, và chờ bộ canh đọc xong BCTC.

### 4.9.2 Bảng số và bộ kiểm tra số

Code dựng bảng số từ BCTC đã kiểm chứng; ô "cần xem ảnh" và số tính từ những ô đó không được đưa vào. Mỗi dòng (S1, S2,…) ghi sẵn mọi con số được phép nói, kèm trang BCTC gốc: kỳ này, cùng kỳ, % thay đổi, mức thay đổi; dòng so sánh ghi thứ tự các mã và chênh lệch; dòng xếp hạng ghi thứ hạng, trung vị nhóm. Mô hình không phải tự tính gì. Nguyên nhân lấy từ công văn giải trình chỉ giữ số khi số đó đã khớp BCTC.

Bộ kiểm tra số là code, không gọi mô hình. Với mỗi câu, nó kiểm:

- mỗi con số khớp một số trong các dòng câu đó ghi, sai số theo chữ số cuối như in ("7,9 nghìn tỷ" khớp 7.943 tỷ); "khoảng", "hơn", "dưới" được hiểu đúng nghĩa;
- số đứng ngay sau "hơn" và một mã ("VCB cao hơn CTG 11.740 tỷ") được hiểu là mức chênh giữa hai mã, nên bảng số phải có đúng mức chênh đó; đặt số của chính mã đứng sau vào chỗ này là lỗi, vì người đọc sẽ hiểu nhầm;
- từ tăng/giảm, lãi/lỗ, cao hơn/thấp hơn, cao nhất/thấp nhất và thứ hạng khớp dấu,

thứ tự trong bảng số, kể cả khi câu gọi công ty bằng tên (“Vietcombank”) thay vì mã, so hai chỉ tiêu của cùng một mã, hoặc đặt hai mã ở hai vế câu khác nhau; câu tự mâu thuẫn như “giảm từ 107 tỷ lên 757 tỷ” cũng bị bắt;

- nhãn của nguyên nhân lấy từ công văn giải trình đúng như bảng số: câu gọi một nguyên nhân là “chưa kiểm” không được dùng con số đã khớp BCTC của nguyên nhân đó, câu nói “số đã đối chiếu, khớp BCTC” không được dẫn nguyên nhân chưa kiểm;
- không có ngôn ngữ khuyến nghị (“nên mua”, “giá mục tiêu”…), không nhắc mã ngoài bảng số.

Câu sai được gửi lại mô hình kèm lý do để viết lại, tối đa 2 lần; vẫn sai thì bỏ, chỉ quản trị viên thấy câu bị bỏ.

### 4.9.3 Câu hỏi “mã nào tốt nhất”

“Tốt nhất” cần một tiêu chí đo được. Khi người dùng không nêu tiêu chí, agent xếp theo mức tăng LNST của cổ đông công ty mẹ so với cùng kỳ, ở quý gần nhất mà ít nhất 2/3 số mã đang theo dõi đã có BCTC kiểm chứng (đầu mùa BCTC mới có vài mã công bố thì vẫn dùng quý trước). Người dùng nêu tiêu chí khác, ví dụ “lãi nhiều nhất” hay “doanh thu tăng nhanh nhất”, thì xếp theo tiêu chí đó; với chi phí và tỷ lệ chi phí trên thu nhập thì thấp là tốt. Ngân hàng, công ty chứng khoán và các doanh nghiệp còn lại được xếp riêng, vì cấu trúc lợi nhuận khác nhau nên không so thẳng với nhau được. Mã lỗ ở một trong hai kỳ không có % thay đổi; mã đó được ghi riêng trong dòng xếp hạng, không bị bỏ đi mà không báo.

Bảng số gồm một dòng xếp hạng cho mỗi nhóm (đủ thứ tự các mã, trung vị nhóm, tiêu chí đã dùng) và đủ chỉ tiêu, cờ cảnh báo của thẻ KQKD cho 5 mã đứng đầu mỗi nhóm. Để trả lời “tại sao”, mô hình xin thêm nguyên nhân trong công văn giải trình của các mã đứng đầu (chỉ nguyên nhân đã khớp BCTC mới giữ số). Báo cáo nêu cả các cờ như nền so sánh thấp hay lợi nhuận đến từ ngoài hoạt động chính, để người đọc không coi một mức tăng rất lớn là dấu hiệu kinh doanh tốt. Mục đầu của báo cáo luôn ghi tiêu chí xếp hạng; “tốt nhất” chỉ có nghĩa theo tiêu chí đó, không phải đánh giá cổ phiếu.

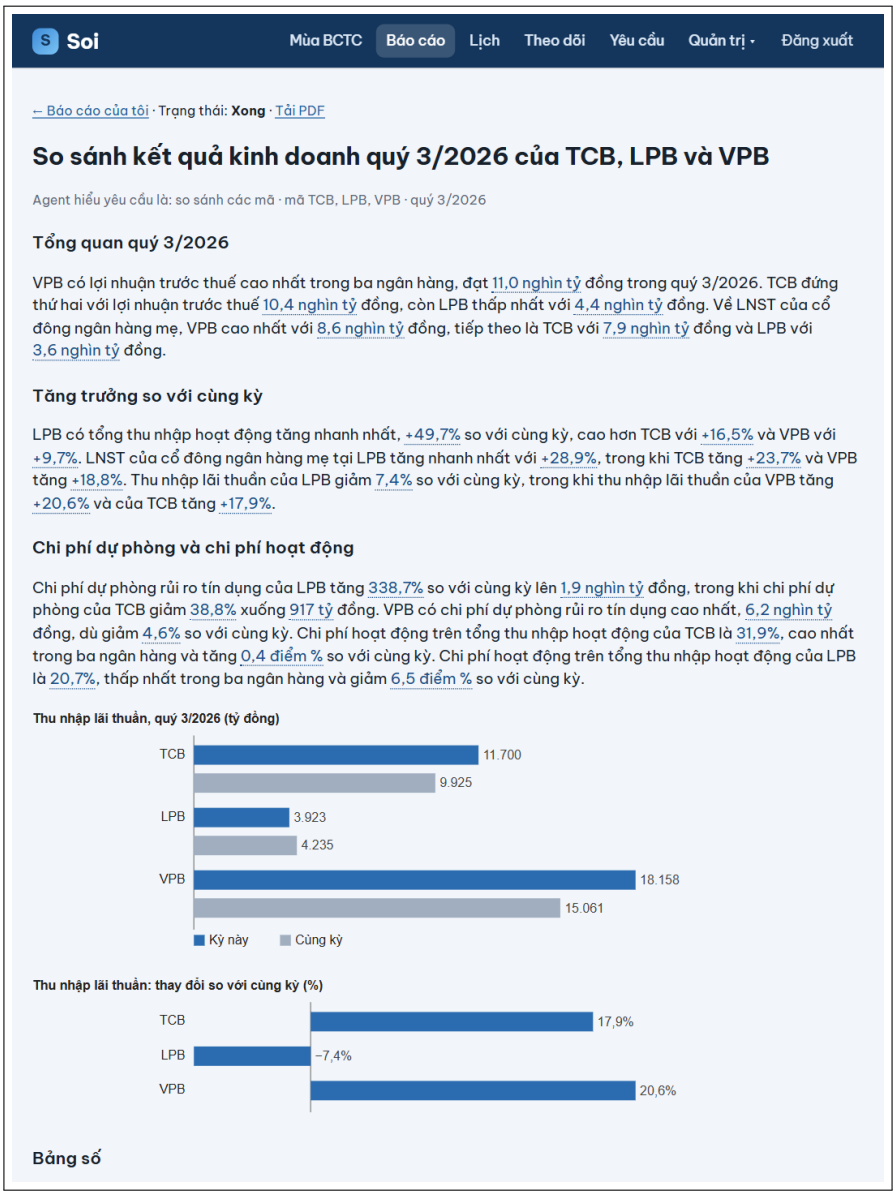
### 4.9.4 Xu hướng nhiều quý và các tỷ lệ ROE, NIM

Loại yêu cầu thứ năm hỏi một chỉ tiêu của một hay nhiều mã qua nhiều quý (mặc định 4 quý gần nhất có BCTC đã kiểm chứng). Code tính sẵn cho mỗi mã chiều thay đổi từng quý so với quý trước, số quý tăng hay giảm liên tiếp, quý cao nhất và thấp nhất, rồi đưa vào bảng số kèm biểu đồ đường. Bộ kiểm tra số có thêm luật cho câu xu hướng: "tăng 3 quý liên tiếp", "cao nhất ở quý 4/2025" phải đúng với chuỗi số trong bảng.

ROE và NIM chỉ tính khi người dùng hỏi. Tử số được quy năm (số riêng quý nhân 4, số lũy kế nhân 12 chia số tháng); mẫu số là bình quân số dư đầu và cuối kỳ trên BCĐKT. ROE dùng LNST và vốn chủ sở hữu của cổ đông công ty mẹ. NIM dùng thu nhập lãi thuần trên tài sản sinh lãi: tiền gửi tại NHNN, tiền gửi và cho vay các TCTD khác, chứng khoán kinh doanh, cho vay khách hàng, mua nợ, chứng khoán đầu tư, lấy đúng số dòng như in (đã trừ dự phòng). Thiếu một số dư, hoặc số dư nằm ở ô chưa được xác nhận, thì tỷ lệ để trống và ghi lý do, không thay bằng số gần đúng. Hai tỷ lệ này chưa có số cùng kỳ năm trước vì BCTC kỳ này không in số dư của năm trước.

### 4.9.5 Trang báo cáo

Mỗi con số trong lời văn là một liên kết tới dòng bảng số, và dòng bảng số dẫn tới trang BCTC gốc (Hình 4.19). Báo cáo tải được dạng PDF, có nhãn "nội dung do AI viết, không phải khuyến nghị đầu tư", chỉ người tạo và quản trị viên xem được. Mỗi người tạo tối đa 20 báo cáo một ngày; chi phí tính chung vào trần tháng của phần đọc theo yêu cầu, chạm trần thì không tạo báo cáo mới. Câu hỏi trùng mà số liệu chưa đổi thì dùng lại báo cáo cũ.




Hình 4.19: Trang báo cáo agent tạo cho câu hỏi “So sánh kết quả kinh doanh quý 3/2026 của TCB, LPB và VPB” (phần đầu; bảng số đầy đủ có 30 dòng).

# Chương 5

# Kết quả thực nghiệm và đánh giá

Mục đầu tiên trả lời câu hỏi chính: **hệ thống tự đọc đúng được bao nhiêu mà không cần người sửa**. Các mục sau là chi tiết của từng phép đo dùng để trả lời câu hỏi đó.

**Phạm vi đo:** trừ khi ghi khác, các phép đo trong chương này dùng chung 119 BCTC đã đạt kiểm chứng hoặc đã duyệt tay tính đến ngày 19/10/2026, gồm BCTC của 30 mã VN30 và một BCTC của một mã ngoài VN30 do người dùng yêu cầu, các kỳ từ quý 4/2025 đến bán niên 2026, tổng cộng 35.196 ô số. Các chỗ khác trong chương ghi gọn là "119 BCTC".

## 5.1 Kết quả chính: bao nhiêu số đúng mà không cần người sửa

Một ô được tính là "đúng mà không cần người sửa" nếu số hệ thống lưu là số in trên BCTC và không có người nào phải sửa ô đó. Câu hỏi này được trả lời bằng hai cách bổ sung cho nhau:

- **Đo trực tiếp bằng đáp án có sẵn** (mục 5.2): 11 BCTC được công ty xuất thẳng từ Excel, Word hoặc phần mềm nên trong file có sẵn chữ gốc, tức đáp án cho mọi ô. Hệ thống vẫn đọc các file này từ ảnh như bản scan, rồi so từng ô với chữ gốc. Đây là bằng chứng mạnh nhất, nhưng chỉ phủ 4 công ty.
- **Ước tính trên toàn bộ 119 BCTC** (35.196 ô), phần lớn là bản scan không có đáp án: ghép phép kiểm kế toán, lần đọc thứ hai và các lần người đối chiếu ảnh.

Bảng 5.1 tóm tắt cả hai.

Bảng 5.1: Lợi ích chính của Soi

| **Thước đo** | **Kết quả** |
|---|---|
| *Đo bằng đáp án có sẵn (11 BCTC, 3.107 ô)* | |
| Ô đúng mà không cần người sửa, ảnh gốc | **3.105/3.107 (99,94%)** |
| Ô đúng khi làm mờ ảnh giống bản scan 200 dpi và 120 dpi | 100% |
| Ô đúng khi làm mờ ảnh giống bản scan 72 dpi | 98,8% |
| *Ước tính trên 119 BCTC, theo BCTC* | |
| BCTC không cần người làm gì: hệ thống tự đọc, tự kiểm chứng, tự sửa | **97/119 (81,5%)** |
| BCTC người chỉ cần xem ảnh rồi duyệt, không sửa ô nào (chính BCTC in lệch, số đọc đúng) | 3/119 |
| BCTC người phải sửa ít nhất một ô | 19/119 |
| *Ước tính trên 119 BCTC, theo ô số* | |
| Ô đúng mà không cần người sửa (ước tính) | **khoảng 99,5%** |
| trong đó có phép kiểm tự động xác nhận | 95,1% |
| trong đó chưa có phép kiểm, hai lần đọc độc lập trùng nhau | 3,5% |
| trong đó chỉ có một lần đọc, chưa có bằng chứng nào | 0,9% |
| trong đó đọc đúng nhưng chính BCTC in lệch, người xem ảnh xác nhận | 0,1% |
| Ô người phải sửa sau khi xem ảnh gốc | 152 (0,4%) |
| Chi phí gọi mô hình để đọc một BCTC | 0,12 USD |

Hai cách cho kết quả nhất quán: đo trực tiếp được 99,94%, ước tính trên toàn bộ 119 BCTC được khoảng 99,5%. Phép đo trực tiếp được trình bày ở mục 5.2. Các dòng ước tính được hiểu như sau:

- **95,1% ô có phép kiểm tự động xác nhận** là phần chắc chắn nhất: số khớp một phép cộng của chính BCTC hoặc khớp BCTC kỳ khác, không cần người. Phép thử cấy lỗi (mục 5.6) cho thấy phép kiểm bắt được 93,8% lỗi nhầm một chữ số và gần như toàn bộ lỗi mất dấu âm hay thiếu chữ số; phần lọt gần như chỉ là chữ số hàng đơn vị, nhỏ hơn sai số làm tròn của chính BCTC. Một người đọc khác hãng chép lại toàn bộ (mục 5.7) chỉ tìm thêm được 5 ô sai trong nhóm này, khoảng 0,02%, và các ô đó đã được sửa.
- **3,5% ô chưa có phép kiểm nhưng hai lần đọc độc lập trùng nhau**: hai mô hình của hai hãng khác nhau cùng đọc sai thành đúng một con số là rất hiếm, nên các ô này được coi là đúng.
- **0,9% ô (306 ô) chỉ có một lần đọc**: chủ yếu là ô người đọc thứ hai không chép. Ở nhóm chưa có phép kiểm, người đọc thứ hai đã tìm ra lỗi ở khoảng 3% số ô; nếu nhóm 306 ô này sai cùng tỷ lệ thì còn khoảng 10 ô sai. Con số 99,5% ở trên đã trừ

phần ước tính này. Kể cả khi giả định cả 306 ô đều sai, tỷ lệ đúng vẫn không dưới 98,7%.

- **152 ô người phải sửa** nằm ở 18 BCTC (cộng một BCTC chỉ sửa mã số của dòng). 80 lượt sửa ở 8 BCTC do hệ thống tự báo (BCTC chờ duyệt, hoặc ô lệch so với BCTC kỳ khác); 78 lượt sửa ở 12 BCTC đã đạt kiểm chứng do người đọc thứ hai chỉ ra sau, chủ yếu là các khối dòng chép lệch một dòng nằm ngoài mọi phép cộng (mục 5.7). Hai nhóm cộng lại là 158 lượt sửa, nhiều hơn 152 ô vì 6 lượt sửa xóa số bị chép nhầm vào ô vốn để trống nên sau khi sửa không còn là ô số; 2 BCTC thuộc cả hai nhóm. Từ mùa quý 3/2026, lần đọc thứ hai chạy tự động nên các chỗ như vậy được hệ thống tự đánh dấu "cần xem ảnh".

Con số 99,5% đo công việc của người vận hành: trong tất cả số đã đọc, bao nhiêu không cần người sửa. Với **người dùng xem thẻ KQKD**, điều cần biết là số hiện trên thẻ thuộc nhóm nào. Trên 119 BCTC, thẻ hiện 1.460 số; 1.339 số lấy thẳng từ một ô đều có phép kiểm xác nhận hoặc đã được đọc lại xác nhận, 5 số là chỗ chính BCTC in lệch mà người duyệt đã xem ảnh, 116 số còn lại được code cộng từ nhiều ô của BCTC. Không số nào lấy thẳng từ một ô thuộc nhóm chỉ có một lần đọc. Các ô chưa có bằng chứng chỉ nằm ở bảng chi tiết của trang tài liệu và được tô màu riêng. Các con số trên thẻ được tính sau khi đã sửa lỗi lấy nhầm dòng LNST của cổ đông ngân hàng mẹ mà phép kiểm đủ dòng tìm ra (mục 5.5).

Hai con số 81,5% và 99,5% khác nhau vì đơn vị đếm khác nhau. Một BCTC có khoảng 300 ô; chỉ cần một ô phải sửa (hoặc người phải xem ảnh rồi duyệt) là cả BCTC bị tính "cần người". Lỗi lại dồn vào một số ít BCTC khó: riêng bán niên 2026 của GVR (file 72 dpi, 33 ô) và quý 4/2025 của VHM (trang lộn ngược, 29 ô) đã chiếm gần 40% số ô phải sửa. Ở 19 BCTC phải sửa, người chỉ sửa trung bình 8 ô mỗi BCTC thay vì nhập lại cả ba báo cáo.

## 5.2 Đo bằng đáp án có sẵn

### 5.2.1 Ý tưởng và bộ dữ liệu

Phần lớn BCTC được công bố dưới dạng bản scan (in ra, ký, đóng dấu rồi chụp lại), nên không có đáp án cho từng ô nếu không có người gán nhãn. Một số ít công ty xuất BCTC

thẳng từ Excel, Word hoặc phần mềm kế toán; khi đó file PDF có lớp chữ gốc, đúng từng chữ số kế toán đã gõ. Soi luôn đọc BCTC từ ảnh trang, kể cả khi file có lớp chữ, nên với các file này ta có đáp án cho mọi ô mà không cần người gán nhãn.

Loại file này rất hiếm. Trong 119 BCTC chỉ có 5 file; trong 77 BCTC quý 2 hoặc bán niên 2026 của các mã HOSE, HNX và UPCoM ngoài VN30 được quét thêm chỉ có 2 file; BCTC gần nhất năm 2026 của 33 mã VN100 khác không có file nào. Thông tin phần mềm tạo file cho thấy phần lớn số còn lại đi ra từ máy scan. Bộ đáp án gom được 11 BCTC của 4 công ty, gồm 6 BCTC ngân hàng (VPB từ quý 3/2025 đến quý 3/2026, ACB quý 1/2026) và 5 BCTC doanh nghiệp thường (GVR quý 4/2025; PLC quý 2, quý 3, quý 4/2025 và quý 2/2026), tổng cộng 3.107 ô số. Một file của TIG bị loại vì lớp chữ của nó do máy nhận dạng từ ảnh chứ không phải chữ gốc: có lỗi chính tả và số bị tách vỡ.

Đáp án được dựng lại từ vị trí chữ trên trang; cách dựng được chọn chỉ theo số dòng ghép được, không dựa vào việc số có khớp với kết quả đọc hay không. Số "0" và ô để trống được coi là như nhau, vì trên BCTC chúng cùng nghĩa.

### 5.2.2 Kết quả theo chất lượng ảnh

Để biết độ đúng giảm thế nào trên bản scan xấu, mỗi BCTC còn được dựng lại thành file chỉ gồm ảnh ở ba mức: giống bản scan tốt (200 dpi), trung bình (120 dpi, hơi mờ, có nhiễu) và xấu (72 dpi, mờ, nghiêng nhẹ, nén mạnh, gần với file bán niên 2026 của GVR). Mỗi file được đọc lại bằng đúng quy trình thật: chép bảng, kiểm tra ràng buộc, định vị và đọc lại ô sai. Chi phí khoảng 0,07 USD mỗi BCTC cho cả ba mức.

Bảng 5.2: Độ đúng từng ô trên 11 BCTC có đáp án, theo chất lượng ảnh

| **Chất lượng ảnh** | **Ô đúng** | **Tỷ lệ** |
|---|---|---|
| Ảnh gốc của file (đúng như hệ thống đã đọc) | 3.105/3.107 | 99,94% |
| Giống bản scan tốt (200 dpi) | 3.104/3.104 | 100% |
| Giống bản scan trung bình (120 dpi) | 3.102/3.102 | 100% |
| Giống bản scan xấu (72 dpi) | 3.064/3.102 | 98,8% |

Tổng số ô ở các mức chênh nhau vài ô vì ở bản làm mờ có ô "0" được đọc thành ô trống hoặc ngược lại, mà hai dạng này được tính là như nhau.

Ở ảnh gốc, 2 ô sai là một lỗi duy nhất: BCTC quý 1/2026 của ACB chỉ in lãi trên cổ phiếu ở hai cột lũy kế, nhưng lần đọc đầu chép số lũy kế năm nay sang cột quý năm

trước, nên một ô có số thừa và một ô bị trống. Lỗi này đã được phép kiểm "số quý bằng số lũy kế" và người đọc thứ hai cùng chỉ ra, và đã được sửa theo ảnh.

Ở mức 72 dpi có 38 ô sai. 27 ô nằm trong 3 BCTC mà hệ thống đã báo (phép kiểm lệch, hoặc có dấu hiệu thiếu dòng), nên trong quy trình thật chúng sẽ được đọc lại hoặc vào hàng duyệt. 11 ô còn lại lọt qua, thuộc hai loại:

- **Sai chữ số cuối**, hoặc sai ở dòng không thuộc phép cộng nào (cam kết ngoại tệ của ngân hàng, dòng chi tiết kiểu "Trong đó: chi phí lãi vay"). Đây đúng là hai giới hạn mà phép thử cấy lỗi đã chỉ ra (mục 5.6).
- **Vài dòng LCTT** của VPB quý 4/2025 mà đáp án dựng lại gộp chung với dòng tiêu đề; chưa tách được do hệ thống bỏ sót hay do cách dựng đáp án.

Phép đo này là nguồn gốc của phép kiểm đủ dòng (mục 4.5.7): ở bản 72 dpi của VPB quý 3/2026, hai dòng con bị bỏ sót mà phép cộng không báo; con số 11 ô lọt ở trên đã tính theo bộ phép kiểm mới. Lần đọc thứ hai không chạy trong phép đo này; trong quy trình thật nó còn bắt thêm một phần các ô ở dòng không thuộc phép cộng nào.

**Giới hạn:** bộ đáp án chỉ có 4 công ty (VPB chiếm 5/11 BCTC), chưa có công ty chứng khoán, và ảnh làm mờ chưa có con dấu đè lên số hay vết gấp như bản scan thật; vì vậy con số 99,94% được dùng cùng với ước tính trên toàn bộ 119 BCTC, không thay thế nó.

## 5.3 So sánh các phương pháp trích xuất trên cùng bộ đáp án

Các họ phương pháp ở mục 3.1 được đo trên đúng 11 BCTC có đáp án chữ gốc ở trên, với cùng các trang báo cáo, cùng ảnh trang ở cùng bốn mức chất lượng, cùng cách chấm và cùng bộ phép kiểm kế toán áp lên đầu ra của mỗi cách. Mỗi cách được chấm trên cùng 3.106 ô có số của đáp án (cách chấm ở mục 5.2 còn tính cả ô một cách đọc ra số mà đáp án không có, nên tổng ô hơi khác theo từng cách). Bốn cách được so với Soi: OCR bằng Tesseract tiếng Việt rồi dựng bảng bằng luật vị trí; bộ chuyển đổi tài liệu Docling (mô hình nhận dạng bảng kèm OCR, chạy trên CPU); OCR bằng Tesseract rồi cho mô hình ngôn ngữ (Claude Haiku 5.5, cùng mô hình Soi dùng) sắp văn bản thành bảng theo đúng khuôn của Soi; và đọc lớp chữ có sẵn. Lớp chữ có sẵn chính là nguồn dựng đáp án nên

chỉ ghi để tham khảo.

Bảng 5.3: Tỷ lệ ô đúng trên 3.106 ô đáp án (11 BCTC) theo phương pháp và chất lượng ảnh. Cột cuối: số BCTC qua hết phép kiểm ở ảnh gốc (không cần người xem) và số ô sai còn nằm trong các BCTC đó.

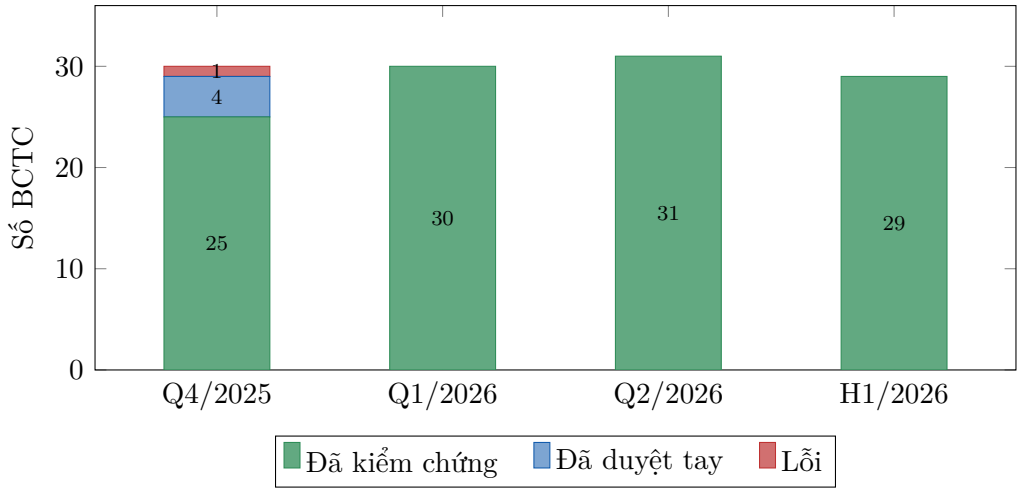
| **Phương pháp** | **Ảnh gốc** | **200 dpi** | **120 dpi** | **72 dpi** | **Qua phép kiểm** |
|---|---|---|---|---|---|
| Lớp chữ có sẵn (tham khảo) | 99,68% | – | – | – | 2 BCTC, 6 ô sai |
| Tesseract + luật dựng bảng | 91,98% | 90,37% | 77,95% | 3,22% | 0 |
| Docling | 66,97% | 68,90% | 62,91% | 3,80% | 0 |
| Tesseract + mô hình ngôn ngữ | 96,81% | 96,62% | 93,21% | 20,70% | 1 BCTC, 1 ô sai |
| Soi, lần đọc đầu | 99,97% | 99,87% | 99,81% | 97,04% | 11 BCTC, 2 ô |
| Soi, sau kiểm và sửa | 99,97% | 99,87% | 99,81% | 97,75% | 11 BCTC, 2 ô |

Số của Soi ở bảng này khác Bảng 5.2 vì hai lý do. Bảng này chấm trên bộ ô cố định: ở 200 và 120 dpi Soi không đọc sai ô nào, nhưng có 4 và 6 ô đáp án không ghép được với ô nào của bản đọc nên bị tính là chưa đúng. Ở 120 và 72 dpi, bảng này dùng bộ ảnh làm mờ chung cho mọi cách, có nhiễu khác bộ ảnh của Bảng 5.2; ở 120 dpi hai bộ ảnh cho cùng kết quả, ở 72 dpi bộ ảnh chung ra 97,75% thay vì 98,65%.

Ba điều rút ra. Thứ nhất, cách đọc bằng OCR mất dần khi ảnh xấu đi và gần như không dùng được ở 72 dpi (3–21% ô đúng), trong khi mô hình đọc ảnh vẫn đúng 97–98%. Thứ hai, cho mô hình ngôn ngữ sắp lại văn bản OCR nâng tỷ lệ đúng so với dựng bảng bằng luật (96,8% so với 92,0% ở ảnh gốc), nhưng vẫn còn 94 ô sai ở ảnh gốc; mô hình không nhìn ảnh nên không sửa được chữ số mà OCR đã đọc sai và chép theo, như dự đoán ở mục 3.1. Thứ ba, phép kiểm kế toán áp được cho mọi cách nhưng hiệu quả tùy cách: ở ảnh gốc, mọi ô sai của OCR dựng bảng bằng luật và 93/94 ô sai của OCR kết hợp mô hình ngôn ngữ nằm trong BCTC bị phép kiểm báo, nên người phải xem lại gần như mọi BCTC; với Docling, 373/677 ô sai lọt qua vì bảng bị vỡ, mất cột mã số nên nhiều phép kiểm không chạy được. Soi là cách duy nhất mà mọi BCTC ở ảnh gốc qua hết phép kiểm; hai ô sai ở đó là một ô bị bỏ sót và một ô đọc thừa, không phải số sai.

Về chi phí và thời gian ở ảnh gốc: OCR dựng bảng bằng luật mất khoảng 5 giây mỗi BCTC, Docling khoảng 54 giây (CPU), cả hai không tốn tiền; OCR kết hợp mô hình ngôn ngữ tốn khoảng 0,012 USD mỗi BCTC; Soi khoảng 0,022 USD ở ảnh gốc và 0,040 USD ở 72 dpi, do phải đọc lại nhiều ô hơn. Toàn bộ phép so sánh tốn khoảng 1,1 USD.

**Giới hạn:** cùng bộ đáp án nhỏ như mục 5.2 (4 công ty, 11 BCTC). Thông số của Tesseract và luật dựng bảng chỉ được chỉnh trên một BCTC. Mọi cách dùng chung các trang báo cáo do Soi định vị, nên phép so chỉ đo bước chép bảng, không đo bước tìm




Hình 5.1: Trạng thái 120 BCTC đã đọc tính đến 19/10/2026: 119 BCTC đạt kiểm chứng hoặc được duyệt tay (phạm vi đo của chương này), 1 BCTC lỗi, không còn BCTC nào chờ duyệt. Không tính một BCTC bán niên trùng file với công bố khác.

trang. Ở ảnh gốc, 5 trong 6 BCTC lấy từ kho của Soi được đọc bằng gpt-5.4-mini (trước khi đổi nhà cung cấp chính); ở 120 và 72 dpi, Soi đọc lại đúng bộ ảnh mà các cách khác dùng.

## 5.4 Độ đúng theo BCTC và theo từng ô

Hình 5.1 cho trạng thái các BCTC theo kỳ. Bốn BCTC quý 4/2025 "đã duyệt tay" (BSR, SSB, VPL, VHM) là trường hợp chính BCTC tự cộng lệch: lần đọc lại phóng to vẫn ra đúng số cũ, nên người duyệt ghi rõ lý do rồi duyệt. BCTC lỗi duy nhất (TCX quý 4/2025) là một công ty chứng khoán có cấu trúc trang khác thường.

Tỷ lệ BCTC đạt kiểm chứng chưa cho biết bao nhiêu ô số được xác nhận, vì một ô chỉ được kiểm khi nó nằm trong ít nhất một phép kiểm. Bảng 5.4 chia toàn bộ 35.196 ô số của 119 BCTC đã kiểm chứng hoặc đã duyệt theo cách ô đó được xác nhận. "Được xác nhận" nghĩa là số khớp ít nhất một phép kiểm (phép cộng trong chính BCTC, hoặc đối chiếu với BCTC kỳ khác), *không* có nghĩa là đã được người đối chiếu với ảnh gốc: chỉ 152 ô sửa tay là đã đối chiếu ảnh. Phép kiểm bắt được bao nhiêu phần trăm lỗi đọc thì đo riêng bằng cách cấy lỗi (mục 5.6); số ô thật sự sai còn lại thì ước lượng bằng một người đọc thứ hai độc lập (mục 5.7).

Bảng 5.4: Phân loại 35.196 ô số của 119 BCTC theo cách được xác nhận

| **Loại** | **Số ô** | **Tỷ lệ** |
|---|---|---|
| Đúng ngay lần đọc đầu, có phép kiểm xác nhận | 31.913 | 90,7% |
| Thuộc báo cáo phải chép lại trang, sau đó có phép kiểm xác nhận | 1.491 | 4,2% |
| Đọc lại riêng ô (định vị ô sai, đối chiếu kỳ) rồi mới khớp | 57 | 0,2% |
| Người duyệt sửa sau khi đối chiếu ảnh gốc | 152 | 0,4% |
| Phép kiểm vẫn lệch, người duyệt đã đối chiếu ảnh: chính BCTC in lệch | 33 | 0,1% |
| Chưa kiểm được: dòng không thuộc phép cộng nào của mẫu biểu | 762 | 2,2% |
| Chưa kiểm được: dòng có phép cộng nhưng hệ thống chưa khai báo | 788 | 2,2% |

Như vậy 95,5% số ô được phép kiểm xác nhận, hay 95,1% nếu không tính 152 ô người sửa (con số dùng ở mục 5.1). Ô chưa kiểm được có hai loại: dòng mà mẫu biểu không đặt vào phép cộng nào (mục ngoài bảng của ngân hàng chưa có số kỳ khác để đối chiếu, lãi trên cổ phiếu, dòng chi tiết kiểu "Trong đó: chi phí lãi vay" chỉ tách một phần của dòng phía trên ra để xem chứ không cộng vào tổng nào), và dòng có phép cộng mà hệ thống chưa khai báo, chủ yếu là dòng chi tiết của công ty chứng khoán. Các ô này được so với lần đọc thứ hai (mục 5.7). 33 ô vẫn lệch phép kiểm sau khi người duyệt đối chiếu ảnh và thấy chính BCTC in lệch (BSR, VHM, VPL, SSB quý 4/2025). Không còn ô nào bị phép kiểm chỉ ra nghi sai mà chưa xử lý: khi một ô khác BCTC kỳ khác, hệ thống đọc lại ô ở cả hai BCTC, và nếu cả hai lần đọc lại đều ra đúng số cũ thì chênh lệch được ghi nhận là số thật khác nhau. Bộ công thức chi tiết cho công ty chứng khoán khớp 100% trên 7 BCTC, cần xác nhận lại khi có thêm BCTC.

## 5.5 Kiểm đủ dòng

Chạy trên 119 BCTC, phép kiểm đủ dòng (mục 4.5.7) tìm ra lỗi ở 11 BCTC mà phép cộng để lọt: 7 BCTC ngân hàng ghi tên dòng LNST của cổ đông ngân hàng mẹ theo cách hệ thống chưa nhận ra, nên 18 số "LNST của cổ đông ngân hàng mẹ" trên thẻ thực ra là LNST chung, cao hơn số đúng từ 0,4% đến 4,6%; 3 BCTC công ty chứng khoán thiếu phần cuối KQKD hoặc in dòng tổng không kèm mã; 1 BCTC thiếu các trang ngoài bảng ($7 + 3 + 1 = 11$). Cả 11 BCTC đã được sửa; mỗi lần chép thêm trang thiếu tốn dưới 0,01 USD. Sau khi bổ sung các cách ghi tên, phép kiểm "LNST của cổ đông ngân hàng mẹ bằng LNST trừ phần không kiểm soát" khớp 110/110 cột trên mọi BCTC ngân hàng và được đưa vào nhóm bắt buộc. Sau khi sửa, phép kiểm còn báo 5/119 BCTC, đều do công ty tự đổi cách trình bày, nên cảnh báo thiếu dòng chỉ để người xem lại chứ không chặn

BCTC.

## 5.6 Phép kiểm bắt được bao nhiêu lỗi

Để đo khả năng bắt lỗi của bộ phép kiểm, hệ thống cấy lỗi giả vào các ô đang được xác nhận của 114 BCTC đã kiểm chứng rồi chạy lại toàn bộ phép kiểm, không gọi mô hình. Lỗi nhầm chữ số được lấy theo đúng tần suất nhầm thật học từ các lỗi đã sửa: một nửa số lỗi thật dùng để học tần suất, nửa còn lại dùng để sinh lỗi cấy. Bảng 5.5 cho kết quả theo từng kiểu lỗi.

Bảng 5.5: Tỷ lệ lỗi cấy bị phát hiện theo kiểu lỗi

| **Kiểu lỗi** | **Số lỗi** | **Phép cộng bắt buộc** | **Thêm phép kiểm khác** | **Tổng** |
|---|---|---|---|---|
| Nhầm một chữ số | 2.000 | 83,6% | 10,2% | 93,8% |
| Mất dấu âm (số trong ngoặc thành số dương) | 500 | 91,2% | 8,2% | 99,4% |
| Thiếu một chữ số | 500 | 91,0% | 9,0% | 100% |
| Đổi chỗ hai dòng cùng thuộc một phép cộng | 500 | 40,6% | 43,8% | 84,4% |

"Phép kiểm khác" gồm các công thức tham khảo và đối chiếu với BCTC kỳ khác. Hai giới hạn rút ra từ phép thử:

- **Lỗi ở chữ số hàng đơn vị** gần như là toàn bộ phần lọt của kiểu nhầm chữ số: sai số cho phép là một đơn vị cho mỗi số hạng (để chấp nhận việc làm tròn của chính BCTC), nên một lỗi nhỏ hơn mức đó không phân biệt được với làm tròn. Ảnh hưởng tối đa là 9 đơn vị tính của bảng.
- **Đổi chỗ hai dòng cùng thuộc một tổng** không làm đổi tổng, nên phép cộng chỉ bắt được khi hai dòng đó còn nằm trong phép cộng khác; một nửa còn lại được đối chiếu kỳ khác bắt (số đầu năm, quý bằng lũy kế trừ lũy kế quý trước). Lỗi này chỉ lọt khi không có BCTC kỳ khác của cùng công ty.

## 5.7 Người đọc thứ hai

Phép kiểm chỉ nói một ô có khớp hay không; để ước lượng số ô sai thật sự mà không phải đối chiếu từng ô với ảnh, toàn bộ 119 BCTC được một mô hình khác hãng với lần đọc đầu chép lại từ đầu (Claude Haiku 5.5 cho các BCTC trước đây do gpt-5.4-mini đọc), rồi

so từng ô với số đang lưu. Chi phí 1,39 USD. Ô hai bên khác nhau được phân xử bằng phép kiểm (thay số của người thứ hai vào; nếu làm lệch phép kiểm đang khớp thì người thứ hai đọc sai), phần còn lại đối chiếu ảnh gốc.

- **Nhóm đã được phép kiểm xác nhận** (33.611 ô): hai lần đọc trùng ở 97,7%; 322 ô người thứ hai không chép. Phần lớn chỗ khác là người thứ hai hiểu sai đơn vị tính của cả bảng ở hai BCTC ngân hàng (cùng dãy chữ số); các chỗ khác chữ số đều do người thứ hai đọc sai, trừ 5 ô do lần đọc đầu sai (hai ô ở chữ số hàng đơn vị nằm dưới con dấu, đúng kiểu lỗi mà phép thử cấy lỗi chỉ ra là lọt). Tỷ lệ sai của nhóm đã xác nhận vì vậy vào khoảng 5/33.000, tức 0,02%. Hai người đọc khác hãng cùng đọc sai thành đúng một số là rất hiếm, nên phần lỗi cả hai cùng bỏ sót không đáng kể.
- **Nhóm chưa kiểm được**: mọi chỗ hai bên khác chữ số đều do lần đọc đầu sai. Đáng chú ý là các lỗi lệch cả một khối dòng: phần ngoài bảng của SSB bán niên 2026 lệch một dòng (dòng tiêu đề không có số bị gán số của dòng dưới), phần thay đổi công nợ trong LCTT của MBB quý 1/2026 lệch một dòng vì dòng tổng tạm bị bỏ sót, và đoạn cuối khúc kinh doanh LCTT của SSI quý 2/2026 lệch một dòng. Các khối này nằm ngoài mọi phép cộng đã khai báo nên BCTC vẫn đạt kiểm chứng.

Tổng cộng 72 số và 6 mã số ở 11 BCTC được sửa theo ảnh nhờ người đọc thứ hai; ca thứ 11 là lỗi lãi trên cổ phiếu của ACB đã tả ở mục 5.2. Sau khi sửa, ở nhóm chưa kiểm được không còn ô nào hai người đọc khác chữ số.

Phép kiểm và người đọc thứ hai không phải hai lưới bắt lỗi độc lập: trong 154 ô đã biết là đọc sai có 5 ô cả hai cùng bỏ sót, vì lỗi khó thì khó với cả hai bên. Vì vậy số lỗi còn sót không suy ra được từ hai lưới này mà cần đáp án thật như ở mục 5.2.

### 5.7.1 Đọc lần hai trong quy trình xử lý BCTC mới

Từ mùa BCTC quý 3/2026, lần đọc thứ hai chạy tự động cho mọi BCTC mới (mục 4.5.6). Trên 119 BCTC, các báo cáo còn ô chưa kiểm được chiếm 395 trong 837 trang báo cáo, nên bước này tốn chưa tới một nửa so với chép lại toàn bộ. Trong 1.550 ô chưa kiểm được, 1.244 ô có hai lần đọc trùng nhau, gồm 264/279 ô lãi trên cổ phiếu và 342/368 ô ngoài bảng của ngân hàng. Ô hai lần đọc khác nhau được tô màu "cần xem ảnh" và báo cho quản trị, nhưng **không** làm BCTC mất trạng thái đạt kiểm chứng: người đọc thứ

hai không nhất thiết đọc tốt hơn, nên nếu chặn theo nó thì mỗi lỗi của chính nó sẽ giữ cả BCTC lại chờ duyệt.

## 5.8 Chi phí

Mỗi BCTC có một bản ghi cộng dồn token của mọi lần gọi mô hình cho chính BCTC đó, nên chi phí ở đây là **chi phí đọc một BCTC** đúng như khi hệ thống chạy thật; chi phí **phát triển** (các lần chạy thử, thử nghiệm riêng) **không** nằm trong đó. Số liệu đáng tin nhất là **29 BCTC quý 4/2025** (bản lỗi của TCX không có bản ghi chi phí), đợt đầu tiên chạy trọn bằng quy trình hiện tại và có ghi chi phí theo từng bước. 90 BCTC các kỳ còn lại được đọc bằng quy trình cũ rồi đọc lại một phần bằng quy trình hiện tại; chi phí của chúng dùng để đối chiếu.

Bảng 5.6: Chi phí trung bình mỗi BCTC theo bước, quy trình hiện tại (29 BCTC quý 4/2025, mô hình gpt-5.4-mini)

| **Bước** | **Lần gọi** | **Token vào** | **Token ra** | **USD** |
|---|---|---|---|---|
| Định vị trang | 1,2 | 23.917 | 770 | 0,021 |
| Chép BCĐKT, KQKD, LCTT | 3,0 | 22.702 | 9.498 | 0,060 |
| Chép lại trang còn lệch | 2,7 | 10.110 | 5.658 | 0,033 |
| Đọc lại ô (định vị ô sai, đối chiếu kỳ) | 0,7 | 2.383 | 292 | 0,003 |
| **Tổng mỗi BCTC** | **7,6** | **59.112** | **16.218** | **0,117** |

Trên 29 BCTC này, trung vị là 0,084 USD và 90% số BCTC tốn dưới 0,173 USD; trung bình ở ngân hàng 0,096 USD, ở doanh nghiệp thường 0,136 USD. 90 BCTC các kỳ còn lại tốn trung bình 0,108 USD, trung vị 0,083 USD. Trung vị thấp hơn trung bình vì một số BCTC khó tốn gấp 2–3 lần: phải chép lại nhiều trang, hoặc chính BCTC in lệch nên hệ thống đọc lại nhiều lần trước khi chuyển duyệt tay. Để hình dung, một hệ thống theo cách OCR rồi cho mô hình ngôn ngữ đọc văn bản (Stock Report Agent [1]) gửi 272.054 token vào mỗi báo cáo và tốn 0,04 USD với Gemini 2.5 Flash Lite, vì cả văn bản OCR được gửi cho nhiều bước. Soi gửi trung bình 60.803 token vào mỗi BCTC, ít hơn khoảng 4,5 lần, nhưng tốn hơn vì đọc ảnh đắt hơn đọc văn bản và vì Soi đọc lại để kiểm chứng. Hai con số dùng hai mô hình khác nhau trên hai bộ BCTC khác nhau nên chỉ cho thấy cỡ chi phí, không phải phép so sánh cùng điều kiện.

Mỗi mã, mỗi kỳ Soi chỉ đọc một BCTC dùng cho thẻ (ưu tiên hợp nhất). Với 0,10–0,12 USD mỗi BCTC, chi phí gọi mô hình khi vận hành vào khoảng 3–3,5 USD mỗi mùa quý

cho VN30 và 10–12 USD cho VN100, chưa gồm đọc theo yêu cầu người dùng (đã có trần riêng).

## 5.9 Định vị ô đọc sai

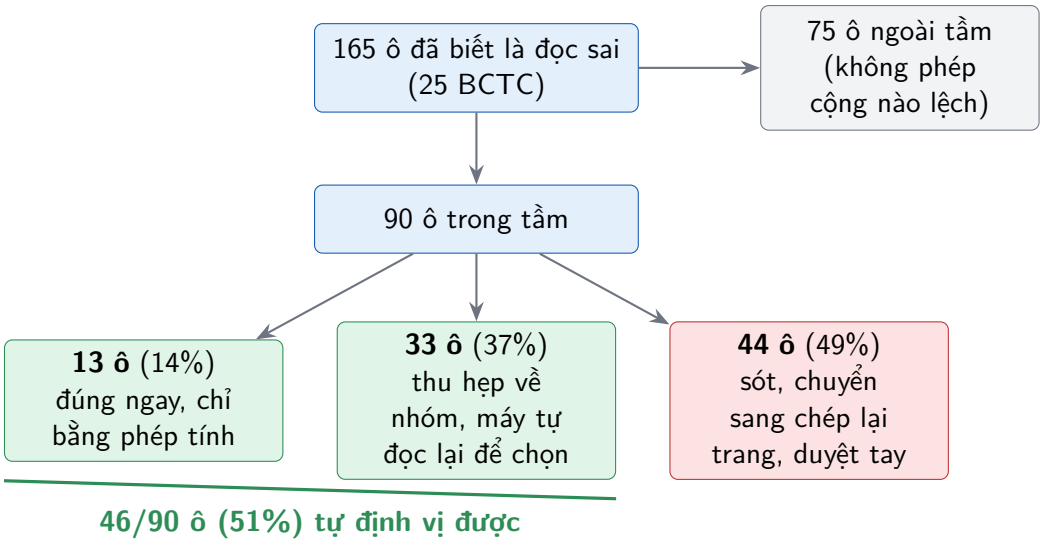
### 5.9.1 Bộ đề và cách thử

Trong các lần chạy, hệ thống đã gặp **165 ô số bị đọc sai** ở 25 BCTC mà ta biết cả số sai lẫn số đúng: hoặc người duyệt đã sửa tay sau khi xem ảnh gốc, hoặc lần đọc lại đã ra số đúng và BCTC sau đó đạt kiểm chứng. Thí nghiệm như sau: lấy từng BCTC, **đặt lại số sai vào đúng ô cũ**, chạy bước định vị (chỉ dùng phép tính trên các ràng buộc, không gọi mô hình), rồi so đề xuất với số đúng.

Bộ đề này **nghiêng về các ca khó**: một ô chỉ vào bộ đề khi quy trình lúc đó chưa tự xử lý được, phải sửa tay hoặc phải đọc lại. Các ô đọc sai mà quy trình đã tự sửa ngay thì không có trong đề.

### 5.9.2 Bốn loại kết quả

Ô **ngoài tầm** không nằm trong phép cộng bắt buộc nào bị lệch, nên không phương pháp nào dựa trên phép cộng nhận ra được; các ô này được loại khỏi phép đo. Ô **đúng ngay** được chỉ ra đúng ô và đúng số chỉ bằng phép tính. Ô **cần đọc lại cả nhóm** nằm trong một nhóm vài ô cùng làm khớp phép cộng: ví dụ tài sản ngắn hạn đang lệch đúng 1 tỷ đồng, có thể do tiền đọc nhầm 6,231 tỷ thành 5,231 tỷ, hoặc tồn kho đọc nhầm 13,4 tỷ thành 12,4 tỷ; hệ thống tự đọc lại các ô trong nhóm (không cho biết số mong đợi) và nhận ô duy nhất ra đúng số đề xuất. Ô **sót** không có đề xuất nào và đi tiếp sang chép lại trang, rồi duyệt tay.




Hình 5.2: Kết quả định vị ô đọc sai trên bộ đề 165 ô. Trong 42 nhóm cần đọc lại có tổng cộng 191 ô, khoảng 4–5 ô mỗi nhóm; đọc lại vài ô tốn khoảng 0,003 USD mỗi BCTC. Nếu bỏ BCTC bán niên của GVR (file 72 dpi, xem mục dưới), tỷ lệ tự định vị được là 30/57 ô (53%).

### 5.9.3 Phân tích các ca ngoài tầm, ca sót và đề xuất sai

75 ô ngoài tầm là các dòng không thuộc phép cộng bắt buộc nào, phần lớn do người đọc thứ hai tìm ra (mục 5.7); các chỉ tiêu dùng trên thẻ KQKD đều nằm trong phép cộng bắt buộc. 44 ô sót phần lớn là trường hợp nhiều ô sai cùng lúc trong một phép cộng, trái với giả thiết mỗi phép cộng chỉ có một ô sai, và dồn ở ba BCTC khó: bán niên 2026 của GVR (file 72 dpi, 17 ô), VHM (trang lộn ngược và chép nhầm dòng, 17 ô), SSI quý 2/2026 (cả đoạn LCTT lệch một dòng, 8 ô); 2 ô còn lại là số bị chép sang cột hoặc dòng khác ($17 + 17 + 8 + 2 = 44$). 5 đề xuất sai đều ở các BCTC của VHM nói trên và không đề xuất nào được nhận trong các lần chạy thật, vì lần đọc lại ảnh không ra đúng số đó.

Trên các lỗi cấy nhầm một chữ số mà phép cộng bắt được (mục 5.6), bước định vị chỉ ra đúng một ô và đúng số ở 32% trường hợp; còn lại ô đúng nằm trong một nhóm trung bình 6 ô, và chỉ 1 trong 1.671 lần đề xuất nhầm ô. Khi xếp nhóm theo tần suất nhầm chữ số thật, ô đúng đứng đầu nhóm ở 68% lỗi cấy (42% nếu xếp theo số chữ số phải đổi) và ở 22/33 lỗi thật; thứ tự này dùng để chọn khi lần đọc lại xác nhận nhiều hơn một ô và để gợi ý ô cần xem trước cho người duyệt.

## 5.10 Chép lại cả báo cáo

Thống kê từ nhật ký lưu trong từng BCTC: mỗi lần chép lại ghi số ràng buộc đạt và lệch trước, sau, và bản mới có được giữ hay không.

Bảng 5.7: Bậc chép lại cả báo cáo trên 119 BCTC (khoảng 360 báo cáo BCĐKT, KQKD, LCTT)

| **Chỉ tiêu** | **Số báo cáo** |
|---|---|
| Phải chép lại (vẫn lệch sau khi đã đọc lại từng ô) | 46 |
| Bản chép lại tốt hơn nên được giữ | 16 (35%) |
| trong đó báo cáo được chép lại đạt mọi ràng buộc bắt buộc của nó | 16/16 |
| trong đó nhờ xoay trang 180 độ | 4 |
| Bản chép lại không tốt hơn, giữ bản cũ | 30 |

Khi được giữ, bản chép lại sửa triệt để: cả 16 báo cáo đều hết lệch, và 1.491 ô số của chúng (4,2% toàn bộ ô, đúng dòng tương ứng của Bảng 5.4) được phép kiểm xác nhận; con số này không tính các ô của cùng báo cáo về sau còn phải đọc lại riêng hoặc sửa tay. Các lỗi được sửa là loại mà đọc lại từng ô không sửa được: bỏ sót dòng, trang lộn ngược, cả báo cáo trước đó không kiểm được ràng buộc nào. Mặt hạn chế là 30/46 lần chép lại không giúp gì; phần lớn các báo cáo đó về sau hết lệch nhờ đọc lại ô, sửa quy tắc hoặc sửa tay, còn 4 báo cáo là do chính BCTC in lệch. Bậc này chiếm khoảng 0,033 USD mỗi BCTC (Bảng 5.6).

## 5.11 Chuẩn bị ảnh cho bước đọc lại

Thí nghiệm dùng lại các ô đã biết là đọc sai của mục 5.9, cộng thêm số ô đối chứng bằng nhau: các ô đúng lấy ngẫu nhiên trên cùng trang, để đo xem cách vẽ mới có làm hỏng ô đang đúng hay không. Mỗi trang được hỏi một lần cho mỗi cách vẽ. Ô sai và ô đối chứng được trộn lẫn, và mô hình không được biết số mong đợi.

Bảng 5.8: Đọc lại 71 ô sai và 71 ô đối chứng (27 trang của 16 BCTC, gpt-5.4-mini; không tính 3 trang lưu sai góc xoay)

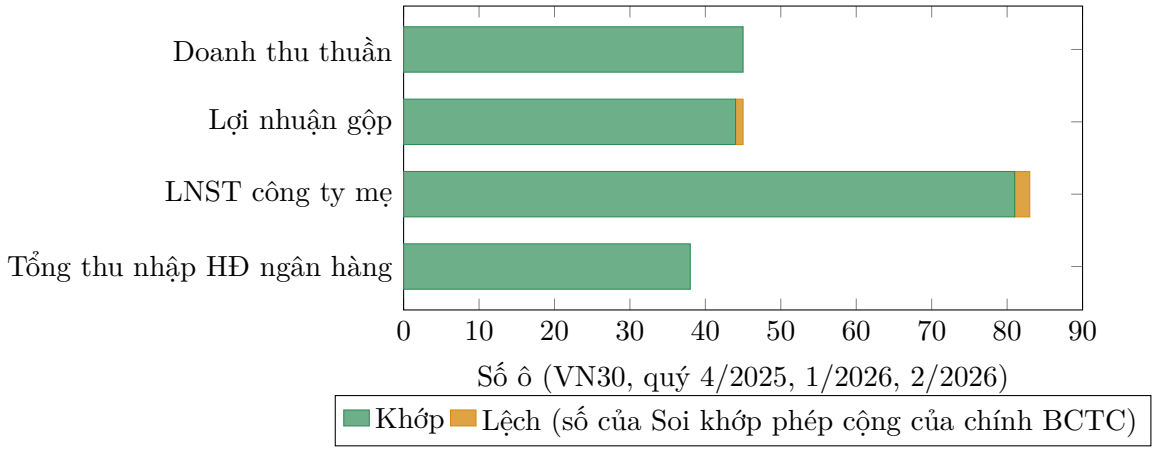
| **Cách vẽ ảnh** | **Ô sai đọc ra đúng** | **Ô đối chứng vẫn đúng** |
|---|---|---|
| Cũ: vẽ trang cạnh dài 3000 điểm ảnh, API tự thu nhỏ | 38/71 (54%) | 64/71 (90%) |
| Mới: vẽ theo độ phân giải scan gốc, phóng Lanczos, gửi ảnh không thu nhỏ (mục 4.6.4) | **57/71 (80%)** | **67/71 (94%)** |

So từng ô: cách mới đọc đúng 23 ô sai mà cách cũ đọc sai, chỉ 4 ô theo chiều ngược lại (kiểm định dấu, $p < 0{,}001$). Ở ô đối chứng, cách mới đúng thêm 6 ô và sai thêm 3 ô; khác biệt này không có ý nghĩa thống kê, tức là cách mới không làm hỏng ô đang đúng. Lợi ích dồn vào file scan từ 100 dpi trở xuống: ô sai đọc ra đúng tăng từ 24/53 lên 43/53; với file scan nét hơn, kết quả không đổi (14/18). Mỗi lần gọi tốn khoảng gấp đôi token, nhưng bước đọc lại chỉ chiếm khoảng 3% chi phí đọc một BCTC (Bảng 5.6). Mỗi cách chỉ chạy một lần, nên kết quả từng trang còn dao động; khác biệt tổng thể giữa hai cách thì đủ lớn để kết luận.

Kiểm lại trong quy trình thật: trả các ô đã biết về số sai cũ trên 4 BCTC mờ (GVR bán niên, VHM quý 1/2026, HDB, LPB; 51 ô), rồi chạy bước "định vị → đọc lại → chỉ nhận khi khớp". Cách cũ tự sửa đúng 11 ô, cách mới 20 ô; cả hai cách đều không nhận nhầm ô nào, chi phí gần như nhau (0,11 và 0,12 USD cho cả 4 BCTC). Thí nghiệm này cũng cho thấy ba trang KQKD của VHM quý 4/2025 đã được chép trên ảnh lộn ngược do lưu sai góc xoay; đây là nguyên nhân của nhiều ô sót ở mục 5.9, và từ đó bậc chép lại tự thử xoay từng trang (mục 4.5.4).

## 5.12 Đối chiếu với nguồn dữ liệu công khai

Sau mỗi mùa BCTC, một chương trình đối chiếu so các chỉ tiêu trên thẻ với bảng KQKD theo quý của một trang dữ liệu tài chính công khai. Số của nguồn ngoài **chỉ dùng nội bộ**, không hiển thị trên Soi.




Hình 5.3: Đối chiếu với nguồn ngoài: 208/211 ô khớp. 3 ô lệch (VJC quý 1/2026 chênh 2 nghìn đồng; VHM quý 4/2025 chênh 200 triệu đồng) đều là trường hợp số của Soi thỏa ràng buộc của chính BCTC.

Lần đối chiếu đầu tìm ra một lỗi lấy nhầm dòng LNST của cổ đông công ty mẹ ở một BCTC không in mã cho dòng này: mọi ô đều đọc đúng nên phép kiểm không bắt được. Lỗi đã được sửa bằng cách gán mã theo tên dòng, và đối chiếu nguồn ngoài trở thành bước cố định sau mỗi mùa BCTC.

## 5.13 Agent tạo báo cáo: hiểu yêu cầu

Bộ đo gồm 66 câu hỏi tiếng Việt, mỗi câu kèm kế hoạch đúng: 60 câu tự soạn và 6 câu do người dùng thử viết theo cách của họ. Các câu phủ cả bốn loại yêu cầu (8 câu hỏi mã nào tốt nhất, trong đó 1 câu có nêu sẵn mã) và nhiều cách nói: trang trọng, nói tắt, không dấu, sai chính tả nhẹ, gọi bằng tên công ty, nói kỳ bằng chữ ("9 tháng", "quý vừa rồi"). Có cả các câu khó: thiếu mã, mã không tồn tại, mã ngoài danh sách theo dõi, kỳ chưa có trong kho, câu xin khuyến nghị mua bán. Hai nhà cung cấp chạy cùng bộ câu, cùng lời dặn, cùng ngày cố định (21/10/2026).

Bảng 5.9: Agent hiểu yêu cầu trên 66 câu hỏi (đếm theo câu)

| | **Claude Haiku 5.5** | **gpt-5.4-mini** |
|---|---|---|
| Hệ thống làm đúng yêu cầu (sau khi code kiểm kế hoạch) | 65/66 | 64/66 |
| trong đó 6 câu người dùng thử viết | 6/6 | 5/6 |
| trong đó 8 câu hỏi mã nào tốt nhất | 8/8 | 6/8 |
| Kế hoạch mô hình trả về đúng mọi trường | 64/66 | 63/66 |
| Chi phí mỗi câu (USD) | 0,0004 | 0,0019 |

"Làm đúng yêu cầu" nghĩa là sau bước code kiểm kế hoạch, hệ thống làm đúng việc người hỏi muốn: đúng mã, đúng kỳ, đúng loại câu hỏi, đúng nhóm và tiêu chí xếp hạng với câu hỏi mã nào tốt nhất, hoặc hỏi lại khi thiếu mã. Ba câu hệ thống làm sai:

- Claude Haiku 5.5 bỏ mã PLX (ngoài danh sách theo dõi) ở câu "GAS và PLX ai tốt hơn quý 2", nên báo cáo chỉ nói về GAS thay vì đi tìm PLX;
- gpt-5.4-mini hiểu "tốt nhất" ở hai câu là xếp theo độ lớn LNST thay vì theo mức tăng. Báo cáo vẫn ghi rõ tiêu chí đã dùng ở mục đầu, nên người đọc thấy ngay.

Ở hai câu còn lại có kế hoạch thô lệch, kết quả vẫn đúng: một câu nói cả năm mà mô hình ghi "riêng quý" (code luôn tính cả năm theo lũy kế), và một câu thiếu mã mà mô hình ghi sai loại câu hỏi (hệ thống vẫn hỏi lại mã).

Lời dặn của bước này được chỉnh hai lần trên chính bộ câu: lần đầu sau lần chạy đầu

trên 53 câu tự soạn (thêm cách hiểu "9 tháng", "năm 2025" và mã ngoài danh sách); lần hai khi thêm loại câu hỏi mã nào tốt nhất (thêm một câu dặn: câu hỏi chung chung không nêu công ty thì không phải câu xếp hạng). Vì vậy kết quả có phần lạc quan. Giữa hai lần chạy trước và sau lần chỉnh thứ hai, số câu sai của mỗi nhà chênh nhiều nhất một câu nhưng câu sai đổi chỗ, vì mô hình không trả lời giống hệt nhau mỗi lần; chênh lệch một, hai câu giữa hai nhà nằm trong mức dao động này.

## 5.14 Agent tạo báo cáo: viết lời và kiểm số

Phép đo chạy trọn agent (bảng số, viết, kiểm, viết lại) trên 58 câu của bộ đo có mã thuộc danh sách theo dõi và kỳ đã có trong kho, với kế hoạch đúng lấy từ đáp án để hai nhà cung cấp viết trên cùng một bảng số. Bốn câu hỏi quý 3/2026 của các công ty chưa công bố được đo trên bản dời sang quý 2/2026. Số liệu là BCTC đã kiểm chứng tính đến 22/10/2026.

Bảng 5.10: Agent viết lời và kiểm số trên 58 câu hỏi (đếm theo báo cáo và theo câu văn)

| | **Claude Haiku 5.5** | **gpt-5.4-mini** |
|---|---|---|
| Báo cáo xong, đủ số | 58/58 | 58/58 |
| Câu văn sai ở lần viết đầu | 23/588 (3,9%) | 39/408 (9,6%) |
| Câu văn còn sai sau 2 lần viết lại, bị bỏ | 12 | 31 |
| Câu văn trong báo cáo cuối | 562 | 385 |
| Chi phí viết mỗi báo cáo (USD) | 0,0035 | 0,0078 |
| Thời gian viết mỗi báo cáo (giây) | 22 | 8 |

Hai cột đếm theo câu văn nên mẫu số khác nhau: Claude Haiku 5.5 viết dài hơn (trung bình khoảng 10 câu mỗi báo cáo so với 7). Lỗi ở lần viết đầu của Claude Haiku 5.5 chủ yếu là so sánh không có dòng so sánh tương ứng (22 lỗi); của gpt-5.4-mini là số không có trong các dòng câu đã ghi (31 lỗi) và so sánh (18 lỗi).

Câu còn lại đã qua bộ kiểm tra, nhưng bộ kiểm tra không bắt được mọi lỗi. Để đo phần này, mỗi câu trong 116 báo cáo xong được cố ý làm sai theo từng kiểu (đổi số lệch 10%, đảo tăng/giảm, đảo so sánh, đảo lãi/lỗ, đổi thứ hạng, chèn câu khuyến nghị, chèn mã lạ) rồi cho bộ kiểm tra xem lại. Các báo cáo được chia đôi theo câu hỏi: nửa thứ nhất (56 báo cáo) dùng để tìm các kiểu lỗi bị lọt và sửa bộ kiểm tra; nửa thứ hai (60 báo cáo, 497 câu) để riêng, chỉ dùng để đo sau khi sửa xong. Bảng 5.11 là kết quả trên nửa để riêng.

Bảng 5.11: Bộ kiểm tra số trên 497 câu của 60 báo cáo để riêng, mỗi câu bị làm sai theo từng kiểu (đếm theo lần làm sai)

| **Kiểu lỗi cố ý đưa vào** | **Bị bắt** |
|---|---|
| Đổi một con số lệch 10% | 415/418 |
| Đảo tăng/giảm | 311/320 (97%) |
| Đảo so sánh (cao hơn/thấp hơn, cao nhất/thấp nhất) | 113/122 (93%) |
| Đảo lãi/lỗ | 23/24 |
| Đổi thứ hạng | 39/40 |
| Chèn câu khuyến nghị | 497/497 |
| Chèn mã chứng khoán lạ | 497/497 |
| Câu gốc (đúng) bị bắt nhầm | 1/497 |

Các mẫu số khác nhau vì mỗi kiểu chỉ áp dụng được cho câu có chỗ để làm sai (câu không có từ so sánh thì không đảo so sánh được). Những lỗi bộ kiểm tra hay để lọt trước khi sửa là: so một mã với trung vị nhóm, câu có cả tăng lẫn giảm trong một vế, hai từ so sánh trong một vế, câu nói ngược với chính nguyên nhân hay cờ cảnh báo câu dẫn. Như vậy số liệu trong lời văn gần như luôn đúng, còn từ chỉ chiều và so sánh vẫn có thể lọt vài phần trăm lỗi; người đọc luôn bấm được vào từng số để xem dòng bảng số và trang BCTC gốc.

## 5.15 So với trợ lý AI đa năng

Tám câu của bộ đo, đủ bốn loại câu hỏi và một câu xin khuyến nghị, được hỏi nguyên văn cho mô hình đa năng của hai hãng cùng hạng giá (Claude Sonnet 5.5 và gpt-5.4), cùng bật tìm web, cùng lời dặn ngắn (trả lời bằng đoạn văn, nêu số liệu cụ thể, hôm nay là 21/10/2026). Code chấm từng số tiền và % trong câu trả lời: số được thử với mọi mã và mọi chỉ tiêu nhắc trong cùng câu, rồi so với số đã kiểm chứng. “Đúng” là khớp kỳ được hỏi (kỳ này, cùng kỳ, mức hoặc % thay đổi); “khác kỳ” là khớp số của kỳ hay cách so khác (lũy kế thay vì riêng quý, so với quý trước); “sai” là không khớp cặp mã–chỉ tiêu nào trong câu; “không kiểm được” là số của khoản ngoài danh mục (tổng tài sản, dư nợ, tỷ lệ hoàn thành kế hoạch…) hoặc của công ty ngoài danh sách theo dõi. Cùng bộ chấm chạy trên báo cáo của agent cho cùng 8 câu để kiểm chính bộ chấm: không số nào của agent bị chấm “sai” hay “khác kỳ”.

Bảng 5.12: Trợ lý AI đa năng có tìm web và agent Soi trên cùng 8 câu hỏi (đếm theo con số)

| | **Claude Sonnet 5.5 có tìm web** | **gpt-5.4 có tìm web** | **Agent Soi viết bằng Haiku 5.5** | **gpt-5.4-mini** |
|---|---|---|---|---|
| Con số trong câu trả lời | 109 | 68 | 186 | 136 |
| đúng | 48 | 11 | 146 | 117 |
| của kỳ khác | 19 | 11 | 0 | 0 |
| sai | 1 | 3 | 0 | 0 |
| không kiểm được | 41 | 43 | 40 | 19 |
| Trả lời có khuyên mua bán | 1 | 1 | 0 | 0 |
| Chi phí cho 8 câu (USD) | 1,32 | 0,54 | 0,02 | 0,08 |

Trợ lý đa năng tìm được số đúng ở nhiều chỗ, nhưng có ba vấn đề mà người dùng khó tự nhận ra. Thứ nhất, nhiều số là của kỳ khác với kỳ được hỏi (19/109 và 11/68), ví dụ trả lời lũy kế 6 tháng khi được hỏi quý 2, hay mức tăng so với quý trước khi câu hỏi là so với cùng kỳ. Thứ hai, có số sai hẳn: gpt-5.4 tự trừ hai con số để suy ra LNTT quý 2/2026 của VCB "khoảng 12,8 nghìn tỷ" trong khi BCTC ghi 17.420 tỷ, và ghi LNTT 6 tháng của TCB là 22.842 tỷ, tăng 33,5% (BCTC: 18.540 tỷ, tăng 22,5%; 33,5% là mức tăng của VCB); Claude Sonnet 5.5 ghi tổng thu nhập hoạt động của VCB quý 2/2026 tăng 18,8% so với cùng kỳ trong khi mức đúng là 47,6%. Thứ ba, với câu xin khuyến nghị, cả hai trợ lý đều gợi ý mua (mua chia nhiều đợt, chờ giá điều chỉnh). Agent chỉ nói số có trong bảng số, mỗi số dẫn về trang BCTC gốc, và không đưa lời khuyên mua bán. Trợ lý có tìm web tốn 0,54–1,32 USD cho 8 câu, chủ yếu do nội dung trang web được đưa vào mô hình; agent tốn 0,02–0,08 USD (chưa tính chi phí đọc BCTC, vốn làm một lần khi BCTC được công bố và dùng chung cho mọi câu hỏi). Đây là phép so trên 8 câu, đủ để thấy các kiểu lỗi chứ chưa đủ để nêu tỷ lệ lỗi chung của trợ lý đa năng.

# Chương 6

# Kết luận và hướng phát triển

## 6.1 Kết luận

Đến giữa tháng 10/2026, Soi đã có đủ chuỗi xử lý: thu thập BCTC, đọc bằng mô hình thị giác, kiểm chứng bằng ràng buộc kế toán, tự định vị và sửa ô đọc sai, đọc lần hai bằng mô hình khác hãng, tính thẻ KQKD có cờ cảnh báo, và giao diện web. Trên 11 BCTC có sẵn đáp án, hệ thống đọc đúng 99,94% ô mà không cần người (98,8% khi ảnh xấu như bản scan 72 dpi). Trên 119 BCTC, chủ yếu của nhóm VN30, hệ thống tự xử lý trọn 97 BCTC (81,5%) mà không cần người, và ước tính khoảng 99,5% ô số đúng mà không cần người sửa (95,1% có phép kiểm tự động xác nhận). Người chỉ phải sửa 152 ô, trung bình 8 ô ở mỗi BCTC cần sửa thay vì nhập lại khoảng 300 ô. Chi phí đọc trung bình khoảng 0,12 USD mỗi BCTC (khoảng 3–3,5 USD cho cả nhóm VN30 mỗi mùa BCTC quý). Đối chiếu với nguồn ngoài cho thấy số liệu khớp ở 208/211 ô, và cả 3 ô lệch đều có lời giải thích từ chính BCTC.

Điểm khác biệt của hệ thống không nằm ở mô hình ngôn ngữ, vì ai cũng dùng được mô hình như nhau. Điểm khác biệt là **lớp kiểm chứng**: mỗi con số đều có nguồn, đều đã qua kiểm tra, và có lịch sử sửa lỗi tích lũy qua từng mùa. Agent tạo báo cáo được đặt lên trên lớp này theo cùng nguyên tắc: mô hình hiểu câu hỏi và viết câu, code tính số và kiểm lại từng con số, từng từ tăng/giảm trong lời văn. Agent trả lời năm loại câu hỏi, trong đó có xu hướng nhiều quý (kèm ROE, NIM khi được hỏi) và câu không nêu mã như "công ty nào có KQKD tốt nhất". Trên 66 câu hỏi mẫu, agent hiểu đúng yêu cầu ở 65 câu với Claude Haiku 5.5 và 64 câu với gpt-5.4-mini; trên 58 câu chạy trọn, cả hai nhà đều viết xong mọi báo cáo. Bộ kiểm tra bắt gần như mọi lỗi số liệu; trên phần câu để riêng,

còn lọt khoảng 3% lỗi tăng/giảm và 7% lỗi so sánh. So với trợ lý AI đa năng có tìm web trên cùng 8 câu, agent không đưa số sai, số của kỳ khác hay lời khuyên mua bán, với chi phí thấp hơn nhiều.

## 6.2 Hướng phát triển

Các mục dưới đây đã có trong kế hoạch nhưng chưa thực hiện. Mỗi mục sẽ được viết đầy đủ khi hoàn thành.

### 6.2.1 Đo độ đúng trên cả mùa BCTC quý 3/2026

*(Dự kiến, chưa thực hiện.)*

### 6.2.2 Đo thời gian từ lúc công bố tới lúc có thẻ trong mùa quý 3/2026

*(Dự kiến, chưa thực hiện.)*

### 6.2.3 Đo agent tìm nguyên nhân trên cả mùa quý 3/2026, lấy công văn giải trình làm đáp án

*(Dự kiến, chưa thực hiện.)*

### 6.2.4 Chỉ số tài chính trên thẻ KQKD: biên lợi nhuận gộp, ROE, NIM

*(Dự kiến, chưa thực hiện.)*

### 6.2.5 Mở rộng lên VN100

*(Dự kiến, chưa thực hiện.)*

### 6.2.6 Thuyết minh làm nguồn ràng buộc thứ hai cho dòng không có phép cộng (lãi trên cổ phiếu, chi phí lãi vay, mục ngoài bảng)

*(Dự kiến, chưa thực hiện.)*

### 6.2.7 Xác suất đúng cho từng ô và bước kiểm chứng tự chọn công cụ theo lợi ích trên chi phí

*(Dự kiến, chưa thực hiện.)*

### 6.2.8 Mở rộng bộ đáp án (thêm công ty chứng khoán, bản scan thật có con dấu)

*(Dự kiến, chưa thực hiện.)*

### 6.2.9 Sàng lọc doanh nghiệp tăng trưởng và kiểm định lịch sử (backtest)

*(Dự kiến, chưa thực hiện.)*

### 6.2.10 Radar sự kiện công bố thông tin và bản tin sáng theo danh mục

*(Dự kiến, chưa thực hiện.)*

### 6.2.11 Kênh phân phối: Facebook, Zalo, MCP

*(Dự kiến, chưa thực hiện.)*

### 6.2.12 Số liệu người dùng thật và chạy suốt ngày đêm trên máy chủ ảo

*(Dự kiến, chưa thực hiện.)*

# Tài liệu tham khảo


[1] Bui Nguyen Khai. Stock Report Agent with Confidence-Gated Hybrid OCR, báo cáo IT3940E Project III. Mã nguồn: `https://github.com/buinguyenkhai/stock-report-agent-20251` (giấy phép MIT), 2026.

[2] Bộ Tài chính. Thông tư 200/2014/TT-BTC hướng dẫn chế độ kế toán doanh nghiệp, 2014.

[3] Bộ Tài chính. Thông tư 334/2016/TT-BTC về chế độ kế toán áp dụng đối với công ty chứng khoán, 2016.

[4] Bộ Tài chính. Thông tư 96/2020/TT-BTC hướng dẫn công bố thông tin trên thị trường chứng khoán, 2020.

[5] Bộ Tài chính. Thông tư 99/2025/TT-BTC hướng dẫn chế độ kế toán doanh nghiệp, hiệu lực từ 1/1/2026, 2025.

[6] Ton de Waal, Jeroen Pannekoek, and Sander Scholtus. *Handbook of Statistical Data Editing and Imputation*. Wiley, 2011.

[7] Ivan P. Fellegi and David Holt. A Systematic Approach to Automatic Edit and Imputation. *Journal of the American Statistical Association*, 71(353):17–35, 1976.

[8] Octavian M. Machidon and Alina L. Machidon. Comparing OCR Pipelines for Folkloristic Text Digitization. arXiv:2507.19092, 2025.

[9] Ngân hàng Nhà nước Việt Nam. Thông tư 49/2014/TT-NHNN về chế độ báo cáo tài chính đối với các tổ chức tín dụng, 2014.

[10] OpenAI. Images and vision: image input detail levels and sizing. `https://developers.openai.com/api/docs/guides/images-vision`, truy cập 14/10/2026, 2026.

[11] Quốc hội. Luật Trí tuệ nhân tạo số 134/2025/QH15, hiệu lực từ 1/3/2026, 2025.

[12] Keren Ye, Ignacio Garcia Dorado, Michalis Raptis, Mauricio Delbracio, Irene Zhu, Peyman Milanfar, and Hossein Talebi. TextSR: Diffusion Super-Resolution with Multilingual OCR Guidance. arXiv:2505.23119, 2025.